



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

中南大学

参赛队号

20250900001

队员姓名

1.

彭铸

2.

阳挺

3.

郑徐瀚宇

中国研究生创新实践系列大赛 “华为杯”第二十三届中国研究生 数学建模竞赛

题 目： 算力约束下大语言模型能力提升的广义标度律与资源优化

摘 要：

在算力预算与高质量语料供给受限的条件下，大语言模型的能力提升不再仅取决于参数量和训练 Token 数的扩张，还受到数据价值、领域组成与非规模技术进步的共同影响。本文从多领域语料的质量评价、冲突消解与配比效应出发，构建融合参数规模、训练 Token 数、语料质量与领域配比的广义标度律，并在训练、质量治理与长上下文计算的共同预算约束下优化资源配置。进一步通过训练损失与综合评测表现的桥接关系，分解规模扩张和非规模技术因素对能力增长的贡献，预测开放权重模型的能力前沿。

针对问题一：多领域语料的质量信号量纲、方向和可靠性不同，训练来源份额又受总和为 1 的约束，直接使用原始指标或独立份额难以区分质量差异与来源替换。本文对七个领域的 22 项信号进行方向审计和域均衡标度，按九个信息簇聚合为样本及领域质量分，再利用域内条件残差定位指标冲突，并按证据可靠性实施局部修正。对于 17 域训练配比，以 ILR-Ridge 建立逐目标损失预测模型，以多任务稀疏 Scheffé 模型分析来源替换和交互，并比较不同训练规模下的配比排序。质量分与 210 条人工复核结果的 Spearman 相关为 0.666，高冲突的前 10% 样本贡献了 64.8% 的总绝对修正量，说明冲突治理主要改变异常尾部而非整体排序。配比模型在真实检验集的 13 个评估目标上取得平均 $R^2 = 0.765$ ，配比排序相关由 60M 规模的 0.810 降至 1B 规模的 0.608，表明来源配置具有预测价值，但其排序不能无条件跨规模沿用。

针对问题二：经典标度律将训练 Token 视为同质资源，不同模型体系的原始损失又存在尺度偏移，因而难以直接辨识质量、配比与规模的共同作用。本文以真实训练轨迹锚定经典律，通过仿射变换统一异源损失尺度，采用可分离非线性最小二乘估计规模参数，并根据跨来源误差与稳定性实施自适应结构早停。在此基线上，以质量加权份额和中心化对数比表示组成响应，先固定经典指数，再通过参考规模回归、跨规模幅度投影和因子对比辨识广义律，整体质量效应则由单独变化质量的实验校准。跨模型族观测的归一化 R^2 为 0.9240，广义律在 13 个评估目标、三个已观测规模上的留出相对 RMSE 为 5.54%，中心化配比效应 R^2 为 0.9006，说明组成信息补充了单纯规模项无法解释的损失变化。单独变化质量的校准数据主拟合 R^2 为 0.9568，该结果刻画的是观测范围内的整体质量响应。在 $N = 10^9$ 、 $D = 250$ 亿 Token 的参考工作点，质量由 0.6 提升至 0.7 的等损失 Token 节省量为 13.97 亿，叠加可行的一个百分点配比调整后跨目标中位数为 14.06 亿。该替代量是质量-配比耦合假设下的情景推算，而非实际训练所得的普适 Token 等价率。

针对问题三：参数扩张、数据增量、质量治理和长上下文共同消耗算力，单独优化其中一项可能偏离有限预算下的最佳配置。本文以前两问辨识的逐目标损失响应构造等权优化目标，把配比约束在 512 组真实训练配方的凸包内，联合求解参数量、Token 数、治理质量和来源份额。成本函数同时计入基础训练、增量质量治理与外生上下文对应的注意力开销，并通过多起点约束求解、四组消融、成本情景对照和有限候选最大后悔值检验配置的稳定性。在 11 档预算、5 档上下文和 3 种质量成本函数构成的 165 个情景中，相对同预

算规模基线的平均损失改善为 4.16%–5.81%，但其中 162 个情景至少有一个评估目标退步，说明平均收益不等于逐领域共同受益。注意力成本与基础训练成本相当的临界上下文长度为 30000，联合配置也未形成跨情景稳定的结构转移，因此资源配置结论必须同时考虑任务权重、质量治理成本和上下文需求。

针对问题四：前三问得到的验证损失不能直接与现实模型的综合评测得分比较，单纯拟合两条时间趋势也无法分离算力扩张与其他技术变化。本文以六项任务的等权得分和三个月滚动高分位定义开放权重模型的能力前沿，利用来源校准的单调 Loss–Benchmark 桥连接最优损失与能力尺度，再将历史增长分解为规模机制项和非规模综合残差。对于超出共同观测支持域的部分，以饱和和末端斜率延续构造贡献的部分识别集合，并在同一状态方程下推演算力平台情景，使用滚动起点回测检查短期预测。观测期能力前沿提高 8.307 分，固定样本下规模贡献份额仅能限定在 0%–8.52%，表明非规模综合因素在该识别集合中承担主要增长，但不能据此归因于某项单一技术。算力平台情景的 12 个月点预测为 53.358 分，预测区间主要受未来非规模状态影响，且短期点预测误差未低于简单保持基线，因此该模型的主要价值在于有边界的结构反事实分析，而非宣称更优的短期预测精度。

关键词： 大语言模型；数据质量；标度律；资源配置；能力预测

目录

一、 问题重述	6
1.1 问题背景	6
1.2 问题重述	6
1.3 总体技术路线	7
二、 符号说明	8
三、 数据说明与预处理	8
3.1 数据来源与用途	8
3.2 数据整理与统一	9
3.3 数据划分与使用范围	9
四、 问题一：数据质量评价、冲突消解及领域配比	9
4.1 问题分析与统一建模框架	9
4.2 多维数据质量评价	10
4.2.1 多源质量信号的统一表征与方向审计	10
4.2.2 基于域均衡信息簇的层次质量评价	11
4.2.3 质量评价的多层一致性检验	12
4.3 质量冲突识别与可靠性校正	14
4.3.1 基于域感知交叉残差的质量冲突识别	14
4.3.2 基于证据可靠性的质量分数校正	14
4.3.3 冲突校正的局部性与稳健性检验	14
4.4 领域配比响应与跨尺度边界	15
4.4.1 配比数据标准化与质量先验辨识	15
4.4.2 基于多任务稀疏 Scheffé 的配比响应建模	16
4.4.3 领域份额的替换效应与互补结构	16
4.4.4 配比规律的跨尺度迁移检验	16
4.5 本问结论	17
五、 问题二：广义标度律及语料规模—质量、配比替代	18
5.1 经典标度律的扩展动因与分析框架	18
5.1.1 经典标度律的局限	18
5.1.2 数据结构与可辨识约束	19
5.1.3 分阶段修正的标度律扩展框架	20
5.2 损失尺度归一化与锚定分阶段标度律建模	20
5.2.1 经典标度律基线的辨识与适用边界	20
5.2.2 质量加权组成响应的广义律构造	23
5.2.3 锚定分阶段广义标度律参数辨识与跨规模验证	24
5.3 语料规模—质量、配比替代	25
5.3.1 各因素边际效用与弹性分析	26
5.3.2 广义标度律指导下的语料规模—质量、配比替代	26
5.3.3 规模—质量、配比替代边界	29

六、 问题三：算力约束下的资源联合优化及结构性转移识别	29
6.1 问题分析与联合优化框架	29
6.2 算力约束下的多维资源联合配置	30
6.2.1 基于质量桥接的联合资源配置建模	30
6.2.2 基于真实配方凸包的约束求解	32
6.2.3 多预算配置结果与逐域权衡分析	33
6.2.4 联合配置的消融与数值稳健性检验	35
6.3 质量成本与上下文长度的配置影响	37
6.3.1 基于边际弹性的资源替代关系	37
6.3.2 基于端点归一化的质量成本比较	38
6.3.3 注意力临界长度与上下文敏感性检验	39
6.4 跨预算资源配置的结构性转移识别	40
6.4.1 基于质量边界与配方支持集的转移识别	40
6.4.2 结构转移的多情景检验与阈值敏感性分析	40
6.5 本问结论	41
七、 问题四：技术演进分解及能力前沿预测	41
7.1 问题分析与统一状态框架	41
7.2 开放权重模型综合能力度量	41
7.2.1 基于多任务一致性验证的综合能力表征	42
7.2.2 基于滚动分位的能力前沿建模	43
7.2.3 能力前沿的多维稳健性检验	43
7.3 Loss-Benchmark 能力映射	44
7.3.1 Loss-Benchmark 桥接样本的可比性分层	44
7.3.2 基于来源偏差不变约束的单调能力桥接	44
7.3.3 桥接模型的留出检验与误差分析	45
7.4 规模扩张与非规模技术进步贡献分解	45
7.4.1 训练算力前沿的滚动分位建模	45
7.4.2 基于最优损失机制锚定的规模能力反事实	46
7.4.3 共同支持边界下的贡献部分识别与稳健性检验	46
7.5 算力放缓下的能力前沿预测	48
7.5.1 算力平台与技术漂移的双状态建模	48
7.5.2 基于统一状态方程的能力前沿情景预测	48
7.5.3 基于单因素方差缩减的预测不确定性归因	49
7.5.4 预测模型的滚动起点回测与基线检验	49
7.6 本问结论	51
八、 结论、局限与推广	51
8.1 主要结论	51
8.2 局限与适用边界	51
8.3 推广方向	52
参考文献	53
附录 A 核心程序代码	54
1.1 问题一核心代码	54

1.2	问题二核心代码	54
1.3	问题三核心代码	57
1.4	问题四核心代码	57

一、 问题重述

1.1 问题背景

大语言模型的训练通常需要同时考虑参数规模和训练 Token 数。参数量增加会抬高每个 Token 的计算成本，训练数据不断增加时，损失下降的幅度也会逐渐变小。给定算力预算后，扩大模型可能意味着减少训练量，增加训练量也可能要求控制模型规模。因此，只讨论参数或数据的单方面扩张，难以说明算力是否得到了合理使用。

训练 Token 的价值也并不相同。语料来源不同，事实准确性、知识覆盖、重复率和噪声水平便可能不同，相同数量的 Token 未必带来相同的损失改善。高质量内容需要筛选、清洗和组织，专业领域的可用数据还受到供给限制。训练语料由多个来源构成，在总 Token 数既定时，提高一个领域的占比必然压低其他领域的占比。数据选择因而不只是决定训练多少 Token，还涉及不同知识领域之间如何分配。

语料质量提升和长上下文训练又会占用原本可用于模型与数据规模的预算。筛选、去重及质量治理需要投入资源，序列变长还会增加注意力计算。同一预算下，投入某一环节的算力越多，留给其他环节的空间就越小。要判断有限算力应如何分配，就需要把模型参数、训练数据、语料质量、领域配比和上下文需求放在一起考虑。

这些配置问题主要涉及一次训练的投入。把视角转向模型的长期演进，架构改进、优化方法、数据工程和后训练同样会改变最终能力。预训练损失能够反映模型在预测任务上的表现，却不能完整代表指令遵循、推理和专业知识等方面的能力。仅凭模型规模或损失曲线，因而难以说明历史能力增长来自何处。若未来训练算力的增速放缓，还需要判断能力增长能否延续，以及规模扩张之外的技术变化可能发挥多大作用。

1.2 问题重述

有限算力下的模型能力提升涉及训练语料、损失规律、预算分配和实际任务表现。前两问研究数据与训练损失的关系，第三问据此讨论资源如何分配，第四问考察损失变化与能力增长之间的联系。具体任务如下。

1. **数据质量评价与领域配比建模。**不同来源的质量指标在尺度、方向和覆盖范围上并不一致，需要形成可比较的样本与领域质量评分。对指标判断相互矛盾的文本，还需识别冲突、考察证据是否可靠，并判断冲突处理会怎样影响质量排序。在训练来源份额总和为 1 的条件下，研究领域配比与各评估目标损失的关系，区分来源替换和来源组合的作用。
2. **广义标度律与数据替代。**不同模型和训练轨迹的原始损失未必处于同一尺度，需要先确定可比的损失口径，再考察经典标度律对规模收益的描述能否跨来源成立。在此基础上，把整体质量 Q 和领域配比 p 纳入参数量 N 、训练 Token 数 D 与损失 L 的关系，建立广义标度律。整体质量提高与固定来源质量下的配比调整不能混为一谈，还需分别考察两者的边际作用，并在给定目标损失时确定它们与训练数据量的替代范围。
3. **算力预算下的资源联合优化。**基础训练、质量治理和长上下文都会消耗算力，需要在预算和配比可行性约束下，联合确定参数量、训练 Token 数、整体质量与领域份额。上下文长度由任务需求和架构条件给定，需要考察它对其余投入的挤占。比较不同预算和质量成本下的配置结果，判断收益如何变化，以及预算增加时是否出现稳定的配置转折。
4. **技术演进与能力前沿预测。**训练损失不能直接代表模型在实际任务上的能力，需要利用多项评测结果建立可比较的能力尺度，并连接损失与评测得分。结合历史模型的训练算力和发布时间，考察能力增长中有多少可由规模扩张解释，以及其他技术变化可能发挥的作用。在算力增长放缓的情景下预测开放权重模型的能力前沿，同时说明任务差异、数据口径和预测期限带来的不确定性。

1.3 总体技术路线

全文按语料价值、训练损失、预算配置和实际能力的顺序展开，四问之间的关系见图 1.1。首先统一质量指标的方向与尺度，处理相互冲突的信号，形成样本、领域和训练来源的质量描述。再把训练配比与评估损失对应起来，在来源份额之和固定的条件下分析配比变化的作用。这一步为后续标度律提供质量特征和配比的可行范围，并保留各评估目标的损失差异。固定来源质量下的配比变化不被解释为独立的质量改善。

在统一损失尺度后，先从训练轨迹辨识经典标度律，确定参数量与训练 Token 数的规模基线。随后把配比响应加入这一基线，并借助单独变化质量的实验校准整体质量效应。经典律的规模指数在广义律中保持固定，使有限的配比实验主要用于识别组成响应及其跨规模变化。所得损失函数以参数量、训练 Token 数、整体质量和领域配比为输入，也为质量、配比与数据规模之间的等损失比较提供统一口径。

将这一损失函数用于算力配置时，同时计入基础训练、质量治理和长上下文的计算成本。配比限制在已有训练配方覆盖的范围内，上下文长度按任务需求给定。对各档预算求得联合配置及对应损失，再与同预算下只调整规模的方案比较，判断质量和配比调整是否带来额外的模型收益。

最后，利用多项评测构造可比较的能力尺度，并用同时具有损失和评测记录的模型建立二者之间的联系。第三问得到的预算与损失关系由此转化为规模投入可能带来的能力变化，历史能力增长中未被该机制解释的部分另行保留。在算力增长放缓的情景下，分别考虑算力路径与其余变化，推演未来的能力前沿。超出观测范围的配置和预测只作为条件情景解释，不与实测结果混同。



图 1.1 总体技术路线

二、符号说明

以下列出题目给定的核心变量及各问主要模型中反复使用的符号，局部统计量在相应公式处说明。

表 2.1 主要符号说明

符号	含义	使用章节
L_{mk}, L	配方 m 在目标 k 上的验证集交叉熵损失及其简写	第 4–7 节
$\mathbf{p}, p_i$	训练来源配比及来源 i 的份额, $p_i \geq 0$ 、 $\sum_i p_i = 1$	第 4–6 节
N, D, C	模型参数量、训练 Token 数及总 FLOPs 预算	第 5–7 节
x_{ij}	样本 i 的第 j 项质量信号	第 4 节
$Q_i^*, \mathbf{Q}$	冲突校正后的样本质量及训练来源质量向量, 本例 $\mathbf{Q} = \mathbf{Q}^{(17)}$	第 4、5 节
$\phi(\mathbf{p})$	跨评估目标的总体配比表现, 越大越优	第 4 节
E, A, B	不可约损失及参数项、数据项的幅度系数	第 5 节
α, β	参数量与数据量的经典标度指数	第 5 节
$\varphi(\mathbf{Q}, \mathbf{p})$	给定评估目标的组成损失修正, 区别于 $\phi(\mathbf{p})$	第 5、6 节
η, ζ	组成响应随参数量和数据量变化的指数	第 5 节
Q, Q_0, γ_Q	整体质量等级、问题二的质量校准点及质量响应指数	第 5、6 节
g_x, ϵ_x	因素 x 的边际降损与损失弹性	第 5 节
$L_{\text{ctx}}, \eta_{\text{attn}}$	外生给定的上下文长度及注意力成本系数, 题面将后者记作 η	第 6 节
$L_{\text{ctx}}^{\text{crit}}$	注意力开销与基础训练开销相当的临界长度, 等于 $6/\eta_{\text{attn}}$	第 6 节
C_{train}, C_Q	基础训练与质量治理的算力开销	第 6 节
C_{attn}	长文本注意力的算力开销	第 6 节
$Q_{\text{base}}, g(Q), h(Q)$	题面问题三的质量基线 Q_0 在本文记为 Q_{base} , g 为质量成本, h 为增量成本	第 6 节
γ, λ	题给质量成本函数的幅度与形状常数, 正文代入数值; 驻点式中的 λ 另表示预算乘子	第 6 节
J	各评估目标损失的平均值, 作为资源配置目标	第 6 节
Y_i, F_t	模型 i 的综合评测得分及时间 t 的能力前沿	第 7 节
$C_t, L^*(C)$	时间 t 的算力前沿及预算 C 下的最优损失	第 7 节
$H(L)$	从训练损失到综合能力得分的映射	第 7 节
$B(C), T_t$	规模机制对应的能力及未由该机制解释的综合变化	第 7 节

三、数据说明与预处理

3.1 数据来源与用途

本文按证据功能而非文件顺序组织数据。语料质量评价以多维质量信号抽样及扩展记录 (A1–A3) 为基础; 领域配比与验证损失由成对的训练表 (A4、A5) 建立关联, 并以同尺度及跨尺度检验表 (A6–A11) 评估泛化。更大规模的配比与损失表 (A12–A15) 属于子集配方和外推估计, 仅用于考察趋势的稳健性; 跨领域质量映射采用参考对应关系 (A16), 其不确定性在解释时保留。

规模基线锚定于真实训练日志 (B1), 再以半合成的族外日志 (B2)、插值轨迹 (B3)、

跨模型族观测（B4）及文献数据（B5）进行分层检验。独立质量变化由校准生成的质量实验（B6、B7）提供；含大规模推算的扩展表（B8）不作为直接观测验证。超大模型的参数资料与预估损失（B9、B10）也分别承担情景设定和外推对照的角色，不能混作同等级证据。能力演进分析可依托多维排行榜及其替代版本（C1、C2）、时序记录（C3）、模型元数据（C4）、损失-评测桥接样本（C5、C6）和逐任务结果（C8）；上下文长度的可行范围则参考架构元数据（C7）。上述来源在建模中分别用于估计、验证或情景分析，半合成、插值与估算结果均不等同于独立实测。

3.2 数据整理与统一

质量信号先按指标含义统一为“越高越好”，再将各领域经验分布等权合成为公共标尺；由抽样语料确定的标量化和变换规则在同源扩展语料中保持不变。样本质量经领域聚合后，通过参考映射构成训练来源的质量描述 $\mathbf{Q}^{(17)}$ 。这一向量与后文表示整体治理等级的标量 Q 含义不同：在配比记录中各来源 $Q_i^{(17)}$ 固定， $p_i Q_i^{(17)}$ 不能提供独立改变质量的信息。

配方表与损失表按共同标识逐行对应；17 个训练来源份额满足单纯形约束，13 个评估目标的损失保留各自口径。问题一的总体配比指标在训练样本内逐目标进行中位数-MAD 标准化。问题二以主训练日志的交叉熵损失为参考尺度，对其他模型来源只校准其仿射位置与幅度，不直接合并原始损失。参数量与 Token 数在计算成本中统一换算为绝对个数，以免十亿单位与 FLOPs 混用。

3.3 数据划分与使用范围

配比响应由训练配方及对应损失估计，同尺度和跨尺度的真实检验表用于评价迁移；更大规模的估算损失仅用于情景外推。同源扩展质量语料用于检查抽样评价的代表性，不作为独立重复实验。经典标度律的参数由主训练日志估计，其他来源参与结构选择与分层比较，但不回流重估主律参数；因此结构选择所用数据与完全未接触的外部测试须加以区分。

广义律按配方划分拟合与留出样本：逐行配对的规模使用相同配方划分，另一观测规模独立划分，避免同一配方在训练与检验间泄漏。两组质量实验存在精确的样本包含关系，只能提供子集一致性对照；含大规模推算的质量表与预估损失不计作直接观测。问题三以此前辨识的损失响应进行条件优化，其预算情景结果也不等同于新增的模型训练实验。

四、 问题一：数据质量评价、冲突消解及领域配比

4.1 问题分析与统一建模框架

问题一包含语料质量度量与领域配比效应识别两个相互衔接的任务。附件 A1–A3 给出样本级多维质量信号，A4–A15 给出训练领域配方及其验证损失，两类数据分别对应“语料质量如何度量”和“领域资源如何配置”两个层面。直接对质量信号求均值时，领域样本量差异和指标冗余会共同改变评价结果。直接回归领域份额时，单纯形约束又会使单个系数失去独立边际效应的含义。由此，模型需要依次处理质量尺度统一、异常证据校正与组成响应辨识三个环节。

本文建立由质量表征、冲突校正和配比响应组成的递进模型。首先通过域均衡公共标尺与信息簇合成构造初始质量 $Q^{(0)}$ 。随后学习各领域内部稳定的指标关系，以交叉拟合残差识别异常证据，并通过可靠性重加权得到修正质量 Q^* 。最后将 Q^* 经 A16 映射为 17 个训练域的质量描述 $\mathbf{Q}^{(17)}$ ，在质量先验可辨识性检验后，以多任务混合响应估计总体配比效应 $\phi(\mathbf{p})$ 、替换效应 S 和互补结构 C^{mix} 。三阶段之间保持同一质量口径，前一阶段的输出构成后一阶段的输入。

图 4.1 概括了从多维质量信号到问题二数据接口的完整链路。质量评价回答不同语料在统一尺度上的相对位置，冲突校正回答具体样本中哪些证据值得信任，配比模型则回答

固定来源质量下份额重分配如何改变验证损失。该划分避免将领域身份、质量提升和配比变化混为同一效应。




图 4.1 问题一从多维质量证据到领域配比效应的统一分析框架

4.2 多维数据质量评价

A1 含 51,230 条样本、7 个领域和 22 项质量信号。A2、A3 分别是 arxiv 和 github 的同源扩展集合，各含 17,523 条和 203,752 条样本，并完整包含 A1 对应领域的 1,419 条与 10,000 条样本。两组扩展数据沿用 A1 的字段口径和采集来源，用于检验抽样质量分布的代表性。

本节依次完成质量信号表征、域均衡层次合成和多层一致性检验。其核心任务是在保留领域间真实差异的同时，控制样本量不平衡和重复评价信号造成的权重偏移，并使最终质量分数始终具有“数值越大、质量越高”的统一解释。

4.2.1 多源质量信号的统一表征与方向审计

22 项信号包含 8 个列表字段和 14 个标量字段。列表字段按原始含义先行标量化，二分类 logits 经 softmax 转为目标类别概率，六级有序 logits 取期望等级并按 5 归一化，QuRating 的四个异质量纲分量先分别作百分位变换再取均值。原始数据完整性良好，仅 modernbert_reasoning 与 modernbert_professionalism 分别出现 13 条和 5 条无效 logits，以所属领域的中位数填补，占总样本比例不足 0.04%。

标量化只解决量纲差异，尚不能保证方向一致。本文逐项登记 22 项信号的质量方向，将其划分为正向、负向和中心适宜三类。WordLength、Sentences、WordCount、Entropy 与 Uppercase 采用中心适宜规则，其余指标按单调方向处理。方向设定的证据与消融结果见 4.2.3 节。表 4.1 汇总 22 项信号的短名、含义、字段形态、标量化方式以及统一表示 s_{ij} 的分布特征，信息簇归属与方向判定见图 4.2。

表 4.1 22 项质量信号的统一表征与分布特征

信号短名	含义	字段形态	标量化方式	$\bar{s}$	σ_s	η_j
NoAlpha	非字母词比例	标量	直接使用	0.516	0.310	0.49
Uppercase	大写字母比例	标量	直接使用	0.835	0.280	0.47
TermPunct	句末标点比例	标量	直接使用	0.498	0.298	0.60
Ad-Prob	无广告概率	列表 2	softmax 取 $P(\text{no-ad})$	0.491	0.291	0.20
MB-Reason	推理性	列表 6	期望等级 /5	0.404	0.251	0.60
UniqueWords	词汇多样性	标量	直接使用	0.624	0.224	0.62
DSIR-Math	数学域倾向	标量	直接使用	0.626	0.223	0.64
DSIR-Books	书籍域倾向	标量	直接使用	0.625	0.225	0.63
DSIR-Wiki	维基域倾向	标量	直接使用	0.626	0.223	0.64
FineWebEdu	教育价值	列表 1	取列表唯一评分	0.447	0.279	0.24
MB-Prof	专业性	列表 6	期望等级 /5	0.452	0.268	0.69
Fluency	语言流畅度	列表 2	softmax 取 $P(\text{fluent})$	0.477	0.293	0.30
QuRating	综合文本质量	列表 4	四分量分位均值	0.447	0.203	0.39
MB-Clean	洁净度	列表 6	期望等级 /5	0.435	0.283	0.44
MB-Read	可读性	列表 6	期望等级 /5	0.434	0.292	0.38
WordLength	平均词长	标量	直接使用	0.795	0.311	0.31
Numerical	数字字符比例	标量	直接使用	0.461	0.290	0.16
Sentences	句子数	标量	直接使用	0.857	0.270	0.38
WordCount	词数	标量	直接使用	0.858	0.271	0.42
Entropy	一元词熵	标量	直接使用	0.855	0.272	0.40
Top2Gram	二元重复集中度	标量	直接使用	0.420	0.282	0.27
Top3Gram	三元重复集中度	标量	直接使用	0.444	0.306	0.18

说明，字段形态中“列表 m ”表示该字段为长度 m 的列表。 $\bar{s}$ 与 σ_s 为统一表示 s_{ij} 在 A1 全样本上的均值与标准差。 η_j 为指标 j 的领域间方差占比。中心适宜指标在中间 60% 分位区间取满分，其 $\bar{s}$ 相应偏高。表内按信息簇 C1–C9 分组排列。

4.2.2 基于域均衡信息簇的层次质量评价

A1 中 book 仅 171 条、arxiv 为 1,419 条，而 c4、github、stackexchange、wikipedia 均接近 10^4 条。若以全样本经验分布作为统一标尺，大样本领域将获得更高权重。若分别在域内归一化，又会抹去领域之间的真实差异。因此，对指标 j 在领域 d 内建立经验分布 F_{jd} ，并令七个领域等权参与公共参考尺度，即

$$F_j^{\text{bal}}(x) = \frac{1}{7} \sum_{d=1}^7 F_{jd}(x). \quad (4.1)$$

在此基础上，将不同方向的指标统一为 $s_{ij} \in [0, 1]$ ，具体形式为

$$s_{ij} = \begin{cases} F_j^{\text{bal}}(x_{ij}), & j \in \mathcal{P}, \\ 1 - F_j^{\text{bal}}(x_{ij}), & j \in \mathcal{N}, \\ \min \left\{ \frac{F_j^{\text{bal}}(x_{ij})}{0.20}, \frac{1 - F_j^{\text{bal}}(x_{ij})}{0.20}, 1 \right\}, & j \in \mathcal{M}, \end{cases} \quad (4.2)$$

其中 $\mathcal{P}, \mathcal{N}, \mathcal{M}$ 分别表示正向、负向和中心适宜指标集合。中心适宜函数在中间 60% 分位区间取满分，仅对结构极端样本进行惩罚。

统一表征后，以域均衡权重计算 22 项信号的 Spearman 相关矩阵，并以 $1 - |\rho|$ 为距离进行层次聚类。综合轮廓系数和 120 次分层 bootstrap 的配对稳定度，数据驱动选择 $K = 9$ 个信息簇。对第 k 个信息簇 G_k ，以簇内绝对相关矩阵的最大特征向量形成非负权重 a_{jk} 。不同信息簇采用等权合成，即

$$H_{ik} = \sum_{j \in G_k} a_{jk} s_{ij}, \quad Q_i^{(0)} = \frac{1}{K} \sum_{k=1}^K H_{ik}, \quad K = 9. \quad (4.3)$$

这种层次合成先在同类信号中提取共识，再汇总不同质量语义，从而削弱重复评价对综合分数的影响。图 4.2 表明，域均衡相关矩阵呈明显的簇状结构，顶部色带给出信息簇归属，右侧给出领域间方差占比 η_j 与指标方向。多个 DSIR 与模型评分信号的 η_j 超过 0.60，说明其变化更多来自领域身份而非通用质量，因此这些指标只参与综合评价，不单独解释为领域质量的因果来源。




图 4.2 22 项质量信号的冗余结构与领域异质性

4.2.3 质量评价的多层一致性检验

领域级质量以域内 $Q_i^{(0)}$ 的均值表示，并在固定评价规则下采用分层 bootstrap 构造 95% 置信区间。表 4.2 给出七域点估计、分布中心和同源扩展检验，图 4.3 则展示领域排序及方向假设的主要证据。

表 4.2 七域初始质量评价及同源扩展检验

领域	n	A1 均值	95% CI	ΔQ	W_1
arxiv	1,419	0.7076	[0.7055, 0.7098]	-0.001740	0.002437
commoncrawl	9,640	0.6056	[0.6043, 0.6067]	—	—
stackexchange	10,000	0.6024	[0.6011, 0.6038]	—	—
wikipedia	10,000	0.5950	[0.5934, 0.5968]	—	—
c4	10,000	0.5548	[0.5529, 0.5566]	—	—
book	171	0.4994	[0.4875, 0.5115]	—	—
github	10,000	0.4786	[0.4771, 0.4802]	-0.000054	0.000384
总体	—	$Q_{\text{micro}} = 0.5707$		$Q_{\text{macro}} = 0.5776$	

说明，A1 均值为初始质量 $Q^{(0)}$ 的域内均值，95% CI 由分层 bootstrap 给出。 ΔQ 为 A2/A3 全量均值减 A1 对应领域均值， W_1 为 Wasserstein 距离。A2/A3 与 A1 同源，该结果用于检验抽样代表性。

arxiv 的平均 $Q^{(0)}$ 最高，github 最低。github 的人工复核相关仅为 0.071，明显低于其他领域，说明代码和技术文本与现有评价信号之间存在较强的领域失配。该排名仅表示统

一评价口径下的相对位置，不作语料本身优劣的绝对判断。A1 的微平均与宏平均接近，说明样本量不平衡未改变总体水平判断。book 样本量最小，其置信区间也最宽。冻结 A1 的标量化规则、公共 ECDF、信息簇及簇内权重后应用于 A2/A3，arxiv 和 github 的均值差分别为 -1.74×10^{-3} 和 -5.4×10^{-5} ，对应的 Wasserstein 距离也很小，表明 A1 对两类同源扩展集合具有较好的代表性。

方向设定与聚合方式的消融结果见表 4.3。最终“五中心”方案在保持七域排序稳定的同时，将 210 条分层人工复核与 $Q^{(0)}$ 的 Spearman 相关提高到 0.666。全部结构指标均按正向处理时，七域排序相关降至 0.429。等权方法和 CRITIC 与本文方法的样本排序相关分别为 0.901 和 0.920，说明主要质量结构具有较高共识。全局 PCA 的一致性明显较低，表明以单一主成分压缩 22 项信号会损失部分质量语义。

表 4.3 质量评价方案的消融与一致性检验

检验类型	方案	七域排序	样本排序	人工复核
方向设定	旧八中心方案	1.000	0.880	0.616 [0.54, 0.68]
	最终五中心方案	1.000	1.000	0.666 [0.61, 0.72]
	中心指标减为四个	0.893	0.993	0.656 [0.60, 0.71]
	全部按正向处理	0.429	0.772	0.634 [0.56, 0.70]
聚合基线	等权	0.929	0.901	0.619 [0.55, 0.69]
	CRITIC	0.929	0.920	0.625 [0.55, 0.69]
	全局 PCA	0.750	0.622	0.449 [0.36, 0.53]

说明，三列均为 Spearman 相关 ρ_s 。人工复核列为 210 条分层样本上的 95% 分层 bootstrap 区间，样本按领域与质量层次分层抽取，排序相关均以最终五中心方案为基准。




图 4.3 七域质量评价结果与评价规则可信度

表 4.3 的人工复核列同时给出 210 条复核样本上的 95% 分层 bootstrap 区间。最终五中心方案相对 CRITIC、等权和旧八中心方案的复核相关差值分别为 0.041、0.047 和 0.050，对应区间分别为 [0.009, 0.073]、[0.013, 0.080] 和 [0.017, 0.083]，均不包含 0。方向审计与层次合成带来的提升因而不能由抽样噪声解释，但提升幅度仍然有限。相对“中心指标减为四个”的差值为 0.010，区间 $[-0.003, 0.022]$ 包含 0，两种方案在人工复核一致性上不可区分。保留五个中心适宜指标的依据是其完整的结构语义。相对“全部按正向处理”的差值

区间同样包含 0，但该方案使七域排序相关由 1.000 降至 0.429，表明其领域层面结果缺乏稳定性。

由此得到的 $Q^{(0)}$ 保留了样本之间的质量次序和领域差异，可作为下一节冲突校正的基准分数，其数值仅用于统一评价口径下的相对比较。

4.3 质量冲突识别与可靠性校正

$Q^{(0)}$ 的层次合成默认各项证据均可直接参与评价，但代码、公式密集文本和特殊格式文档可能使个别评价器偏离所属领域的正常关系。此时，绝对得分较低不等同于证据冲突，多个指标之间无法由领域常态解释的不一致才构成校正依据。

本节先以域感知交叉残差识别局部异常，再将冲突程度转化为证据可靠度，并据此更新信息簇权重。该处理不对高冲突样本直接扣分，而是降低异常证据对综合质量的影响，从而形成修正质量 Q^* 、证据可信度 U 和冲突度 C 。

4.3.1 基于域感知交叉残差的质量冲突识别

以上一节的域均衡相关结构为基础，仅保留 $|\rho| \geq 0.10$ 且在 300 次分层 bootstrap 中稳定率不低于 0.95 的指标关系，共得到 135 条稳定边。对每项指标，用其稳定邻居和领域信息建立 Elastic Net 预测器，并按七域进行 5 折 cross-fitting，使每个样本的条件期望均由未包含该样本的训练折给出。记交叉预测残差为 $e_{ij} = s_{ij} - \hat{s}_{ij}^{(-i)}$ ，并在所属领域内按 MAD 标准化。若异常度进入对应“指标-领域”经验残差分布的上 2.5% 尾部，则置 $I_{ij} = 1$ 。样本级冲突度同时计入异常覆盖范围和异常强度，即

$$\begin{aligned} r_{ij} &= \frac{|e_{ij}|}{1.4826 \text{MAD}_{d_i}(e_{\cdot j}) + \varepsilon}, \\ p_{ij}^{\text{conf}} &= 1 - F_{j,d_i}^R(r_{ij}), \quad I_{ij} = \mathbf{1}\{p_{ij}^{\text{conf}} < 0.025\}, \\ C_i &= \sqrt{\left(\frac{1}{22} \sum_j I_{ij}\right) \left(\frac{\sum_j I_{ij} r_{ij}}{\sum_j I_{ij} + \varepsilon}\right)}. \end{aligned} \quad (4.4)$$

该定义以各指标在各领域中的正常波动为参照，因此不会把代码、公式密集文本等领域特征仅因数值差异而判为冲突。

4.3.2 基于证据可靠性的质量分数校正

冲突不直接从样本总分中扣除，而是作用于对应证据的可靠度。设 τ_{j,d_i} 为指标 j 在领域 d_i 的冲突阈值，定义

$$R_{ij} = \begin{cases} 1, & I_{ij} = 0, \\ \exp\{-0.5(r_{ij} - \tau_{j,d_i})_+\}, & I_{ij} = 1, \end{cases} \quad Q_i^* = \sum_{k=1}^K v_{ik}^* H_{ik}, \quad v_{ik}^* = \frac{\sum_{j \in G_k} a_{jk} R_{ij}}{\sum_{\ell=1}^K \sum_{h \in G_\ell} a_{h\ell} R_{ih}}. \quad (4.5)$$

各信息簇可靠度的均值记为 U_i 。当不存在冲突时， $v_{ik}^* = 1/K$ ，故 $Q_i^* = Q_i^{(0)}$ 。出现局部异常时，仅相应信息簇的权重发生变化。

4.3.3 冲突校正的局部性与稳健性检验

冲突校正后， Q^* 与 $Q^{(0)}$ 的全样本 Spearman 为 0.9992，说明总体质量次序基本保持不变。修正量则明显向高冲突样本集中。Top 10%、Top 5% 和 Top 1% 冲突样本的 $|Q^* - Q^{(0)}|$ 中位数分别为 0.00435、0.00655 和 0.0118，且 Top 10% 样本贡献了 64.8% 的总绝对修正量。图 4.4 中的分箱中位线进一步显示，冲突程度升高后修正幅度呈持续上升趋势。

高严重度冲突主要集中在 Entropy、Sentences、Uppercase、WordCount 和 WordLength 等结构信号，表明异常主要来自文本结构偏离所属领域的常态。领域层面的平均冲突度在




图 4.4 冲突修正的局部性与异常来源

GitHub 中最高 (0.180)，在 Book 中最低 (0.138)。该差异反映评价证据的一致性，而不用比较领域质量高低。将 A1 学得的关系结构、残差尺度和阈值冻结后应用于 A2/A3，严重冲突仍集中在同类结构信号。作为对照，本文冲突度与“指标方差”和“最大两两差”的 Spearman 仅为 0.132 和 0.172。当显著性阈值在 0.01–0.10、可靠性衰减系数在 0.3–1.0 内变化时， Q^* 排序与主方案的 Spearman 始终不低于 0.994。因此，冲突校正主要影响高冲突尾部，并未改变质量评价的主体结构。本阶段输出 (Q_i^*, U_i, C_i) ，分别记录修正后的质量、证据可信度和冲突程度。

4.4 领域配比响应与跨尺度边界

A4/A5 提供 512 组 1M 训练配方及其 13 域验证 Loss。A6/A7 构成 1M 同尺度真实检验，A8/A9 和 A10/A11 分别提供 60M、1B 真实检验，A12–A15 则给出 10B、70B 外推结果。17 个训练比例满足 $p_i \geq 0$ 和 $\sum_i p_i = 1$ ，任一领域份额增加都会压缩其他领域，13 个验证域又具有不同的 Loss 基准。

本节先统一多任务损失尺度并检验质量先验是否具有独立信息，再分别建立面向预测和机制解释的配比响应模型。在此基础上，通过方向导数定义领域份额替换效应，通过二阶交互项识别互补结构，最后以配比距离和跨规模排序检验模型的适用边界。

4.4.1 配比数据标准化与质量先验辨识

不同验证域的 Loss 先在 A5 内按验证域进行中位数–MAD 标准化，再定义总体配比表现，即

$$z_{mk} = \frac{L_{mk} - \text{median}(L_{\cdot k})}{1.4826 \text{ MAD}(L_{\cdot k})}, \quad \phi(\mathbf{p}) = -\frac{1}{13} \sum_{k=1}^{13} \hat{z}_k(\mathbf{p}). \quad (4.6)$$

$\phi(\mathbf{p})$ 越大，表示该配方在 13 个验证域上的总体表现越优。

上一阶段得到的七域 Q^* 经 A16 映射到 17 个训练域，记为 $\mathbf{Q}^{(17)} = (Q_1^{(17)}, \dots, Q_{17}^{(17)})$ 。由于 $\sum_i p_i Q_i^{(17)}$ 是 $\mathbf{p}$ 的确定函数，直接作为额外线性项会与配比变量共线。因此以指数倾斜 $\tilde{p}_i(\gamma) \propto p_i \exp[\gamma(Q_i^{(17)} - \bar{Q})]$ 检验质量先验。交叉验证的最优值为 $\gamma = 0$ ，且 $\gamma > 0$ 时误差略有增加，说明 A4/A5 无法把“领域身份”与“领域质量”的独立作用分开识别。据此，配比响应模型不引入质量先验。质量的独立边际效应转由校准生成的质量变化实验 (B6、B7) 估计，大规模扩展结果 (B8) 仅用于审视外推边界。

4.4.2 基于多任务稀疏 Scheffé 的配比响应建模

为显式刻画领域及领域组合的作用，对第 k 个验证域建立二阶 Scheffé 混合响应

$$\hat{z}_k(\mathbf{p}) = \sum_{i=1}^{17} \beta_{ik} p_i + \sum_{1 \leq i < j \leq 17} \gamma_{ijk} p_i p_j, \quad k = 1, \dots, 13. \quad (4.7)$$

17 个主效应和 136 个交互项在 13 个任务上联合拟合，以组稀疏约束筛选跨任务稳定结构，并用 Ridge 项稳定相关系数。一阶 Scheffé 和 ILR-Ridge 作为对照。1M 真实检验结果见表 4.4。

表 4.4 1M 真实检验集上的配比响应模型比较

模型	标准化 RMSE	平均 R^2	标准化 MAE	用途
一阶 Scheffé	0.522	0.619	0.435	线性混合基准
多任务稀疏 Scheffé	0.444	0.710	0.361	机制解释
ILR-Ridge	0.420	0.765	0.337	数值预测

说明，RMSE 与 MAE 均在式 (4.6) 的标准化空间中计算，以训练集 1.4826 MAD 为一个误差单位，数值不具有原始 Loss 量纲。 R^2 为 13 个验证任务的平均值。总体宏观配比指标 G 在 1M 检验集上的 R^2 为 0.391。

ILR-Ridge 的点估计最优。其标准化 RMSE 为 0.420，表示预测误差约为训练集稳健标准差的 0.42 倍，与平均 $R^2 = 0.765$ 的结果一致。按各任务的 MAD 尺度逆变换后，原始 Loss 的宏平均 RMSE 为 0.327，平均 MAE 为 0.263。重复 5 折交叉验证下，其相对多任务 Scheffé 的 R^2 差值均值为 0.038，95% CI 为 $[-0.012, 0.081]$ ，区间包含 0。因此后续数值预测采用 ILR-Ridge，领域替换和交互机制采用多任务稀疏 Scheffé 解释，两类模型分别承担预测和机制分析任务。

4.4.3 领域份额的替换效应与互补结构

在单纯形约束下，“增加领域 i ”必然伴随其他领域份额减少，因此主效应系数不能直接解释为独立边际收益。在参考配比 $\mathbf{p}$ 附近，定义从领域 j 向领域 i 转移份额的边际效应和两领域的总体互补指数，即

$$S_{i \leftarrow j}(\mathbf{p}) = \frac{1}{13} \sum_{k=1}^{13} \left(\frac{\partial \hat{z}_k}{\partial p_i} - \frac{\partial \hat{z}_k}{\partial p_j} \right), \quad C_{ij}^{\text{mix}} = -\frac{1}{13} \sum_{k=1}^{13} \gamma_{ijk}. \quad (4.8)$$

$S_{i \leftarrow j} < 0$ 表示在当前配比附近将份额从 j 转移到 i 有助于降低总体 Loss。 $C_{ij}^{\text{mix}} > 0$ 表示两域共同出现时的 Loss 低于线性混合预期。前者描述份额替换，后者描述非加性交互。

为控制稀疏配方造成的大系数伪影，正文只解释同时满足三项条件的关系，即两域训练覆盖充分、bootstrap 符号稳定率不低于 0.95、效应量位于训练支持范围。约 52% 的替换关系和 46% 的互补关系通过该门槛。通过门槛的关系中，DM-Math $\rightarrow$ HackerNews 的替换效应为 -2.68，显示稳定的 Loss 改善信号。arXiv-GitHub 则表现出稳定互补。相反，enron_emails 的平均份额仅 0.0022、最大份额 0.026、非零占比 0.31，其大幅替换效应超出充分支持范围，因此不进入机制结论。图 4.5 将替换矩阵和通过资格门槛的互补/冗余关系合并展示，灰色斜线区域表示证据不足。

4.4.4 配比规律的跨尺度迁移检验

同尺度预测精度不能直接代表跨规模可迁移性，因此分别考察配比空间外推和模型规模迁移。在配比空间内，以 Hellinger 距离衡量测试配方到最近训练配方的距离。1M 检验




图 4.5 领域配比的替换机制与互补结构

集最近邻距离的中位数为 0.299，90% 分位数为 0.375，且预测误差随距离增大而整体上升，说明模型的机制解释应限制在训练配方支持区域附近。

模型规模迁移通过不同尺度下的配方排序一致性衡量。表 4.5 和图 4.6 显示，60M 和 1B 的 Spearman 相关分别为 0.810 和 0.608，均保持为正，但随规模扩大明显减弱。10B、70B 的 Loss 为较小规模幂律外推结果，其排序相关和预测-观测斜率均转为负值。因此，现有数据支持真实 1M–1B 范围内的有限迁移，不支持将小模型上的配比规律视为尺度不变关系。

表 4.5 领域配比效应的跨尺度一致性

模型规模	数据性质	样本数	排序相关 ρ_s	两两一致率	回归斜率
60M	真实检验	256	0.810	0.805	0.912
1B	真实检验	64	0.608	0.711	0.348
10B	外推 Loss	63	-0.584	0.293	-0.339
70B	外推 Loss	63	-0.617	0.279	-0.370

说明，排序相关为各尺度配方排序与 1M 预测排序的 Spearman 相关，两两一致率为配方两两比较方向一致的比例，回归斜率为预测-观测回归的斜率。10B/70B 的 Loss 来自小规模实验的幂律外推，仅用于识别尺度失效边界，不作为真实大模型训练验证。

4.5 本问结论

问题一形成四项主要结论。第一，域均衡公共标尺与信息簇层次合成能够在样本量不平衡条件下保留领域差异，最终质量方案与分层人工复核的 Spearman 相关为 0.666，同源扩展集合的分布差异很小。第二，域感知冲突校正保持了总体质量次序， Q^* 与 $Q^{(0)}$ 的全样本 Spearman 为 0.9992，修正量主要集中于高冲突尾部。第三，质量先验在现有配比实验中的最优强度为 $\gamma = 0$ ，表明领域身份与来源质量的独立作用无法由 A4/A5 进一步分离。




图 4.6 配比模型的预测有效域与跨尺度迁移边界

第四，配比响应在真实 1M–1B 范围内保持正向迁移，但 10B 和 70B 外推结果发生方向反转，因而不支持尺度不变的配比规律。

上述结论沿同一数据接口逐层传递。初始质量 $Q^{(0)}$ 给出统一评价尺度，域感知可靠性校正将其更新为 Q^* ，A16 进一步形成 17 域质量描述 $Q^{(17)}$ ，配比模型则输出总体效应 $\phi(\mathbf{p})$ 、替换效应 $S_{i \leftarrow j}$ 和互补指数 C_{ij}^{mix} 。其中 U 与 C 记录质量证据的不确定性，配比支持范围和跨尺度检验限定机制结论的外推边界。这些输出共同构成问题二广义标度关系的数据侧输入。

五、 问题二：广义标度律及语料规模—质量、配比替代

问题二先以经典标度律确定规模基线并检验跨来源适用性，再引入语料质量与领域配比刻画同等规模下的损失差异，最后分析给定目标损失时的资源替代。整体思路见图 5.1。

5.1 经典标度律的扩展动因与分析框架

5.1.1 经典标度律的局限

经典标度律通常将训练 Token 视为同质资源，重点描述参数规模和数据规模对模型损失的影响。然而，随着高质量语料逐渐稀缺，不同数据在信息密度、噪声水平、知识覆盖和任务相关性方面呈现出显著差异，单纯增加参数量或训练 Token 数已不足以准确解释模型能力的增长规律。如果忽略这种数据异质性，模型不仅会高估低质量数据的边际价值，还会掩盖领域结构失衡造成的性能瓶颈，从而难以回答数据质量提升、领域配比调整与模型规模扩张之间能否相互替代这一关键问题。因此，将数据质量和领域配比纳入标度律，是从“规模驱动”转向“规模与数据价值协同驱动”的必要拓展，也是实现有限算力下精细化资源配置的理论基础。

这一局限在固定规模的比较中尤为清楚，当模型参数量和训练 Token 数相同时，经典律给出相同的损失基线，却不区分语料来源的替换与质量等级的改变。故规模项可以刻画投入增加的平均趋势，不能单独解释同等训练规模下的损失差异。本文以验证损失为可建模的响应量，讨论的“替代”也首先是达到相同目标损失所需资源的变化，而非将损失改善直接等同于所有下游能力的提升。




图 5.1 问题二的整体分析框架：经典规模基线及跨来源检验、质量与配比的广义律构造，以及边际响应和等损失替代分析。

5.1.2 数据结构与可辨识约束

配比实验为区分规模效应与组成效应提供了直接依据。表 5.1 按观测规模汇总了真实训练记录。在固定 N, D 的条件下，各配方在 13 个评估目标上的损失仍有明显离散。例如，主拟合组的目标内相对损失跨度中位数为 38.4%，同规模留出组为 35.6%。经典标度律对同一规模的配方给出相同预测，因而需要额外的组成响应解释这部分差异。不过，每个配方仅有一次训练记录，表中离散度是描述性统计，不能全部归因为配比的因果效应。

表 5.1 配比实验的规模结构与固定规模下的损失离散度

模型规模 N	训练量 D	配方数	相对损失跨度中位数
10^6 (主拟合)	10^9	512	38.4%
10^6 (留出)	10^9	256	35.6%
6×10^7	10^9	256	38.0%
10^9	2.5×10^{10}	64	16.4%

注：先对每个评估目标计算配方间损失的 $(P_{90} - P_{10})/P_{50}$ ，再取 13 个目标的中位数；同规模留出组与 6×10^7 组的 256 个配方逐一对应， 10^9 组未与其配对。每个配方仅有一次训练记录。

设训练数据来自 m 个领域，配比 $\mathbf{p}$ 满足 $p_i \geq 0$ 与 $\sum_{i=1}^m p_i = 1$ ，任一份额增加都伴随其他来源缩减。本文 17 个训练来源只对应 6 个不同的分级质量值，且来源质量 $Q_i = Q_i^{(17)}$ 在配比实验中固定。因此，质量加权份额 $p_i Q_i$ 可描述质量与投入的联合暴露，却不能从这些记录中独立识别提高同一来源质量的效应；将配比压缩为平均质量 $\sum_i p_i Q_i$ 还会抹去同质量来源之间的内容差异。

规模辨识也受观测设计约束。真实记录只有三个不同的 (N, D) 锚点，前两个共享 $D = 10^9$ ，最大规模点则同时提高 N 与 D ；可逐一比较的跨规模配方仅有上述 256 组。由

此可以考察同数据量下组成响应随模型规模的变化，却不足以无约束地重新估计经典规模指数和全部交互指数。加之不同评估目标及模型来源的原始损失尺度不同，后续分别锚定规模基线、校准损失尺度，并用独立变化质量等级的实验辨识整体质量响应，避免将来源替换误写为质量提升。

5.1.3 分阶段修正的标度律扩展框架

基于上述约束，本文采用“经典规模基线—组成响应—独立质量校准”的分层建模框架。首先，对多来源损失进行尺度归一化，利用自适应结构早停识别稳健的经典标度指数。随后针对任意评估目标，在规模基线上叠加配比响应项，以质量加权份额 $p_i Q_i$ 表示分级质量与投入的联合暴露，以中心化对数比特征刻画单纯形上的相对组成，并允许响应幅度随 N 、 D 变化。该设计保留了经典标度律对规模收益递减的解释，同时允许相同质量等级的不同来源产生不同的损失变化。受规模锚点数量限制，扩展模型沿用下文辨识的经典指数，而不从配比实验中重新辨识所有规模参数。图 5.2 概括了经典律参数估计与广义律分阶段辨识之间的衔接。

整体质量等级 Q 的作用则由单独变化质量的实验标定，并以参考质量 Q_0 与已辨识的规模—配比关系衔接。这样，组成响应与质量响应各有对应的信息来源，也能清楚标识二者联合变化所依赖的结构假设。在此基础上，固定模型规模和目标损失，比较不同 Q 与可行配比 $\mathbf{p}$ 下所需的训练 Token 数 D ，才能定义语料规模—质量、配比的等损失替代。该替代是给定工作点及模型适用范围内的条件关系，其边界将在后文单独讨论。




图 5.2 广义标度律的三阶段参数辨识：标准律锚定规模指数，分阶段估计组成响应与基线，再由规模因子对比确定响应幅度指数。

5.2 损失尺度归一化与锚定分阶段标度律建模

5.2.1 经典标度律基线的辨识与适用边界

为刻画模型规模、训练数据量与验证损失之间的基本数量关系，本文以真实训练日志（B1）辨识经典标度律，并将族外日志、插值轨迹及跨族和文献样本（B2–B5）保留为不同层级的检验证据。所采用的经典形式为

$$L(N, D) = E + AN^{-\alpha} + BD^{-\beta}, \quad (5.1)$$

其中， N 表示模型参数数量， D 表示训练 Token 数， L 表示验证集交叉熵损失。 E 是规模趋于充分时仍无法消除的不可约损失， A 与 B 分别控制参数规模项和数据规模项的幅度， α 与 β 则刻画两类资源的边际收益衰减速度。为保证模型具有明确的物理含义，估计过程中施加

$$0 \leq E < \min_i L_i, \quad A > 0, \quad B > 0, \quad \alpha > 0, \quad \beta > 0 \quad (5.2)$$

等约束。由式 (5.1) 可知，随着 N 或 D 增大，预测损失单调下降，但改善幅度逐渐减小，因而能够自然描述大模型训练中的收益递减现象。

损失尺度归一化 不同模型体系可能采用不同的分词器、验证语料和损失统计口径，即使其学习曲线具有相似形状，原始 Loss 的位置和尺度也可能存在系统差异。若直接比较原始损失，模型族之间的整体平移或缩放会被误判为标度结构失效。为此，本文将主拟合来源的 Loss 定义为参考尺度，并假设第 j 个外部来源的观测损失满足仿射观测关系

$$L_{ji}^{\text{obs}} = a_j + b_j L_{ji}^{\text{ref}} + \varepsilon_{ji}, \quad b_j > 0, \quad (5.3)$$

其中， a_j 描述损失基线差异， b_j 描述损失单位或动态范围差异， ε_{ji} 为无法由统一尺度解释的结构残差。相应地，将外部观测映射到参考尺度：

$$\tilde{L}_{ji} = \frac{L_{ji}^{\text{obs}} - a_j}{b_j}. \quad (5.4)$$

主拟合来源取 $a_0 = 0$ 、 $b_0 = 1$ ，因此其训练过程保持在原始可解释的 Loss 尺度上。其他来源经式 (5.4) 归一化后再参与验证与结构选择。

为防止利用同一批验证标签完成校准后又在原样本上评价，本文采用按训练轨迹或模型族分簇的交叉归一化。对于待评价簇 c ，仅使用其余簇估计

$$(\hat{a}_j^{(-c)}, \hat{b}_j^{(-c)}) = \arg \min_{a \in \mathbb{R}, b > 0} \sum_{i: g(i) \neq c} \left[L_{ji}^{\text{obs}} - (a + b \hat{L}_{ji}^{\text{ref}}) \right]^2, \quad (5.5)$$

再使用 $\hat{a}_j^{(-c)}$ 和 $\hat{b}_j^{(-c)}$ 归一化留出簇。该处理只消除来源间的仿射尺度差异，不改变留出轨迹的排序、曲率和局部偏差，因而归一化后的剩余误差仍能反映标度规律的跨体系可迁移性。为保持评价透明性，本文同时保留未经校准的原始尺度误差，并将其解释为“结构误差与观测尺度偏移”的合成结果。

可分离非线性最小二乘法 式 (5.1) 对五个参数整体而言是非线性模型，但当指数 (α, β) 给定后， E 、 A 和 B 构成线性参数。令

$$\mathbf{y} = (L_1, \dots, L_n)^\top, \quad \boldsymbol{\theta} = (E, A, B)^\top, \quad (5.6)$$

并构建设计矩阵

$$\mathbf{X}(\alpha, \beta) = \begin{bmatrix} 1 & N_1^{-\alpha} & D_1^{-\beta} \\ 1 & N_2^{-\alpha} & D_2^{-\beta} \\ \vdots & \vdots & \vdots \\ 1 & N_n^{-\alpha} & D_n^{-\beta} \end{bmatrix}. \quad (5.7)$$

于是，在任意候选指数对下，内层问题可写为带物理约束的线性最小二乘

$$\hat{\boldsymbol{\theta}}(\alpha, \beta) = \arg \min_{\boldsymbol{\theta}} \|\mathbf{y} - \mathbf{X}(\alpha, \beta) \boldsymbol{\theta}\|_2^2. \quad (5.8)$$

将内层解析解代回后，原问题被压缩为仅关于两个指数的轮廓残差平方和

$$S(\alpha, \beta) = \left\| \mathbf{y} - \mathbf{X}(\alpha, \beta) \hat{\boldsymbol{\theta}}(\alpha, \beta) \right\|_2^2. \quad (5.9)$$

本文先在指数区间内设置等距节点进行粗网格搜索，再以当前最优点为中心实施局部模式搜索，并逐次将搜索步长减半，直至步长小于 10^{-7} 。相较于同时对五个参数进行无结构的非线性优化，该可分离非线性最小二乘方法将高维耦合问题转化为“外层低维指数搜索 + 内层线性求解”，既降低了初值敏感性，也便于在每个指数候选点严格检查参数正性和不可约损失边界。

自适应结构早停 指数自由度越高，越容易把数据噪声读作真实的标度结构差异，因此本文按由简到繁、以外部验证收益为准的顺序逐层释放指数自由度。第一层令 $\alpha = \beta = s$ ，对共享指数 s 进行一维搜索。第二层以第一层最优值 s^* 为锚点，分别考察“固定 $\beta = s^*$ 、释放 α ”和“固定 $\alpha = s^*$ 、释放 β ”两个并列候选。只有当单方向释放产生稳定的外部收益时，第三层才进入 (α, β) 均自由的二维搜索。每个候选指数点仍由式 (5.8) 估计 E 、 A 和 B ，因此该过程并未引入新的标度律项，而是在同一标准模型内部逐步增加指数自由度。

不同来源的可信度、判别难度与统计稳定性并不相同，因此本文不预先固定其权重。记 r_j 为可信度先验， d_j 为基准模型在该来源上的验证难度， σ_j 为按轨迹或模型族分簇 Bootstrap 得到的分数标准差，则定义稳定性因子和原始权重

$$s_j = \frac{1}{1 + \sigma_j/d_j}, \quad u_j = r_j d_j^\xi s_j, \quad (5.10)$$

并在给定上下限后将 u_j 归一化为 ω_j 。较困难但稳定、且证据可靠的来源因而获得较高权重。高度相关、半合成或波动较大的来源则不会主导结构选择。权重在比较候选结构之前一次确定并冻结，以避免针对某个候选模型事后调整评价标准。

候选结构的最终选择分数定义为

$$J_m = \sum_j \omega_j \text{MedAPE}_{j_m} + \lambda \max(0, k_m), \quad (5.11)$$

其中， MedAPE 衡量归一化后的相对预测偏差， k_m 为有效自由参数数目，第二项用于要求新增指数自由度给出足以抵消复杂度增长的外部收益。候选结构首先需要满足主拟合样本上的最低拟合门槛。随后，只有当 $J_m < J_{\text{best}} - \delta$ 时，才将其视为实质改善并更新历史最优结构。

经典标度律的拟合、验证与外推 自适应结构早停最终保留参数项与数据项共享指数的简约结构，得到

$$\hat{L}(N, D) = 1.654679 + 0.425107N^{-0.293183} + 1.205248D^{-0.293183}, \quad (5.12)$$

其决定系数为 0.99938498，RMSE 为 0.00848302。释放参数规模指数仅使选模分数改善 0.000159，低于阈值 $\delta = 0.002$ ，因此不增加指数自由度。图 5.3(a) 表明，增加训练数据量或模型参数量均可降低损失，但边际收益持续递减。将资源投入统一换算为 $C = 6ND$ 后，各规模训练轨迹呈现相近的下降趋势。图 5.3(b) 中的经验下沿包络近似满足 $L = 2.26C^{-0.0595}$ ，刻画了既定计算预算下可达到的效率前沿。

为检验跨来源迁移能力，本文提取独立训练轨迹的最终收敛点，并采用留一轨迹或留一模型族的仿射尺度校准。表 5.2 与图 5.4(a) 显示，归一化后的四类数据均保持较高秩相关性。公开文献观测的误差相对较高，但考虑数据质量、网络结构与训练策略造成的差异，仍在标准标度律的描述范围内。

表 5.2 经典标度律的多来源样本外验证结果

验证来源	来源	样本数	归一化 RMSE	中位相对误差	归一化 R^2	Spearman 系数
独立模型族收敛终点	B2	7	0.014636	0.70%	0.9950	1.0000
连续插值训练轨迹	B3	4000	0.011445	0.28%	0.9996	0.9998
跨模型族实验	B4	57	0.088138	1.57%	0.9240	0.9758
公开文献实验观测	B5	44	0.127853	5.24%	0.7647	0.9280




图 5.3 经典标度律的资源标度与计算效率：(a) 参数规模、数据规模与验证损失的标度关系。(b) 不同参数规模下计算量与验证损失的关系，虚线为经验下沿包络。

图 5.4(b) 进一步给出百亿参数以上的情景外推。经典标度律在固定数据规模下预测损失随参数量缓慢下降，而大模型样本的离散程度明显更高，表明超大模型区间还受到数据质量与训练配置的显著影响。因此，该图用于界定外推趋势和风险，不作为新的外部验证证据，并为后续引入质量变量与领域配比提供依据。




图 5.4 经典标度律的跨来源验证与大模型外推：(a) 损失尺度归一化后的多来源预测一致性，虚线为理想预测，阴影区域表示相对误差不超过 10%；(b) 百亿参数以上模型区间的标度律外推，曲线按中位训练数据量计算。

5.2.2 质量加权组成响应的广义律构造

经典标度律揭示了参数规模与训练数据量的损失衰减规律，但其同质 Token 假设无法区分训练语料的质量和来源组成。为分析这一缺口，首先考察实验的可辨识结构，在模型规模与训练 Token 数均固定的条件下，存在数百种不同的语料配比，因而经典标度律对这些实验给出同一预测基线，却无法解释其损失差异。另有 256 组配比在两个模型规模下逐一对应，可比较规模改变后配比响应的形状与幅度。这说明需要在规模基线之外单独建立组成响应，而非仅用总 Token 数代表全部训练数据。与此同时，观测实验仅提供三个不同的 (N, D) 规模锚点，其中较大模型的 N 与 D 同时变化。若连同组成效应重新估计全部规模指数，将产生明显的参数混淆。因此沿用前文估计的 α 、 β ，将新增参数集中用于刻画组

成效应及其跨规模变化。

其次，训练配比属于单纯形，提高某一来源的份额必然压缩其他来源，故各 p_i 不是相互独立的投入量。仅以平均质量 $\sum_i p_i Q_i$ 概括语料，会把质量相近但知识内容不同的来源混为一谈。只用原始份额又难以直接表达来源之间的相对替代。基于这一约束，采用质量加权份额 $p_i Q_i$ 记录各来源的有效投入，并以中心化对数比刻画相对组成。但现有质量评分对每个来源固定， $p_i Q_i$ 与 p_i 在统计上不能区分独立的质量改善效应，因此这一项只表示给定质量分级下的组成暴露，不能作质量因果效应解释。

最后，逐行配对的跨规模配比为检验“响应形状相对稳定、作用幅度随规模改变”的可分离假设提供了依据。用规模幂函数调节组成响应的幅度，既与经典标度律的形式协调，也避免为每个规模重新拟合一套配比函数。以参考规模归一化该幅度，并将组成响应在参考样本上中心化，可减少其与损失截距之间的混淆。由于配比维度随来源数增长，估计时还须施加正则化以控制方差。设训练语料包含任意 m 个来源， $\mathbf{p} = (p_1, \dots, p_m)$ 满足 $p_i \geq 0$ 、 $\sum_i p_i = 1$ ， $\mathbf{Q} = (Q_1, \dots, Q_m)$ 为相应来源质量；本文实例取 $m = 17$ 和 $\mathbf{Q} = \mathbf{Q}^{(17)}$ 。对于任意给定的评估目标，由此提出统一的函数结构

$$L(N, D, \mathbf{p}, \mathbf{Q}) = E + AN^{-\alpha} + BD^{-\beta} + \left(\frac{N}{N_0}\right)^{-\eta} \left(\frac{D}{D_0}\right)^{-\zeta} \varphi(\mathbf{Q}, \mathbf{p}), \quad (5.13)$$

其中 (N_0, D_0) 为首个观测规模锚点。 E 、 A 和 B 决定损失基线， α 、 β 为规模指数， η 、 ζ 刻画组成响应随规模变化的程度。两个规模比值在参考规模均为 1，故 φ 直接表示该规模下的损失修正，其符号方向与问题一的总体表现指标 $\phi(\mathbf{p})$ 不同。为避免平均质量 $\sum_i p_i Q_i$ 抹去同等级、不同知识来源之间的差别，将组成响应展开为

$$\varphi(\mathbf{Q}, \mathbf{p}) = \sum_{i=1}^m w_i(p_i Q_i - \bar{m}_i) + \sum_{i=1}^m w_{\text{clr},i}(\text{clr}_\varepsilon(\mathbf{p})_i - \bar{m}_{\text{clr},i}). \quad (5.14)$$

这里 w_i 与 $w_{\text{clr},i}$ 分别为质量加权份额和相对配比的有效权重。 $\bar{m}_i$ 、 $\bar{m}_{\text{clr},i}$ 是对应特征在参考规模拟合样本上的均值，使 φ 在该样本上均值为零。其中，中心化对数比定义为

$$\text{clr}_\varepsilon(\mathbf{p})_i = \log(p_i + \varepsilon) - \frac{1}{m} \sum_{j=1}^m \log(p_j + \varepsilon). \quad (5.15)$$

式 (5.14) 中的 $p_i Q_i$ 记录质量加权的来源投入，中心化对数比反映单纯形上的相对结构， $\varepsilon > 0$ 用于处理零占比。拟合时对这两组特征进行标准化与正则化，并将所得系数换算为式 (5.14) 中的有效权重。不同评估目标均采用式 (5.13) 的函数结构，但 E 、 A 、 B 、 η 、 ζ 及组成权重分别估计。

5.2.3 锚定分阶段广义标度律参数辨识与跨规模验证

式 (5.13) 由经典规模基线与受规模因子调制的组成响应相加而成。若联合估计全部参数，仅有三个规模锚点不足以同时辨识经典律指数和组成响应指数。此外，响应形状与幅度可相互吸收，造成参数化不唯一。为此，本文按图 5.2 所示采用“锚定标准律—分阶段参数辨识—因子对比”的递进结构，在保留经典律约束的同时辨识新增的组成项。

锚定标准律 沿用前文由充分规模变化的实验辨识出的共享指数 $\alpha = \beta = 0.293183$ ，只借用指数而不直接移植损失基线参数。由此将广义模型的规模基线限制在 $\{1, N^{-\alpha}, D^{-\beta}\}$ 张成的空间中，避免用稀疏的配比实验重新估计指数。该锚定仅约束资源收益衰减的形状。损失下界及两个规模项的系数仍由当前评估目标的数据确定，从而不强求不同目标共享损失水平。以下 N, D 分别以十亿参数和十亿 Token 计。三个观测锚点依次为 $(10^{-3}, 1)$ 、 $(0.06, 1)$ 和 $(1, 25)$ ，首个锚点记为 (N_0, D_0) 。

分阶段参数辨识 在参考锚点, N, D 保持不变, 配比之间的损失差异因而提供组成响应的识别信息。对式 (5.14) 中的两组特征逐维标准化, 以岭回归估计该响应, 正则强度由调参折选定。将拟合响应在参考训练配比上中心化、换算至损失单位, 并规定其幅度 $\kappa_1 = 1$: 前者使组成项与常数基线在参考样本上分离, 后者固定 $\kappa\varphi$ 的尺度规范。令 s 表示锚点、 r 表示该锚点训练折中的配比, $\varphi_{sr} = \varphi(\mathbf{Q}, \mathbf{p}_{sr})$ 。其余幅度是损失对同一响应形状的投影斜率。扣除组成项后得到各锚点的规模基线:

$$\begin{aligned}\kappa_s &= \frac{\sum_r (\varphi_{sr} - \bar{\varphi}_s)(L_{sr} - \bar{L}_s)}{\sum_r (\varphi_{sr} - \bar{\varphi}_s)^2}, \quad s = 2, 3, \\ b_s &= \bar{L}_s - \kappa_s \bar{\varphi}_s, \quad s = 1, 2, 3.\end{aligned}\tag{5.16}$$

这样, 原先耦合的形状与幅度被化为参考规模的正则化回归及跨规模的一元投影。再以非负最小二乘将三个 b_s 投影回锚定的经典律基底:

$$(\hat{E}, \hat{A}, \hat{B}) = \arg \min_{E, A, B \geq 0} \sum_{s=1}^3 (b_s - E - AN_s^{-\alpha} - BD_s^{-\beta})^2.\tag{5.17}$$

非负约束保持经典基线项的物理方向。由于组成修正可为负, 仍须另行检查预测损失是否低于 E 。各评估目标采用相同的函数结构, 但分别估计其基线与组成权重。

因子对比 对正的响应幅度取对数, 得到 $\log \kappa_s = -\eta \log(N_s/N_0) - \zeta \log(D_s/D_0)$ 。由于前两个锚点的 D 相同, 其幅度比消去了数据量因子, 可先辨识 η , 再从第三个锚点的总幅度变化中扣除已知的参数规模效应, 条件辨识 ζ :

$$\eta = -\frac{\log \kappa_2}{\log(N_2/N_1)}, \quad \zeta = \frac{-\log \kappa_3 - \eta \log(N_3/N_1)}{\log(D_3/D_1)}.\tag{5.18}$$

上述对比利用实验设计形成的单因子变化, 而不依赖同时搜索两个指数。同一配比在前两个锚点的损失还应满足 $L_2(\mathbf{p}) = a + \lambda L_1(\mathbf{p})$, 其中 $\lambda = \kappa_2/\kappa_1$ 、 $a = b_2 - \lambda b_1$ 。这一配对关系消去了 φ , 因而可在不依赖其具体函数形式的条件下检验可分离结构。配对回归的训练折 R^2 中位数为 0.9868, 留出配比的跨规模预测相对 RMSE 中位数为 1.16%。

广义标度律验证 对逐行配对的规模采用相同配比划分, 第三个规模独立划分, 留出折均不参与拟合或选模。在 13 个评估目标、三个已观测规模的留出配比上, 三个规模的相对 RMSE 分别为 5.84%、5.49% 和 4.44%, 汇总为 5.54%。中位绝对百分比误差为 2.40%, 按评估目标与规模中心化的配比效应 R^2 为 0.9006。留出预测的最小 $\hat{L} - E$ 为 0.2129, 未跌破基线下界。图 5.5(a) 表明多数评估目标保持较低误差和较高解释度, 但数学目标的误差明显偏大, 提示跨目标性能仍有差异。图 5.5(b) 中, 三个规模的留出预测总体沿理想一致线分布。关闭配比项后, 预测在固定规模与评估目标内不再随配比变化, 形成水平带, 说明仅靠 N, D 无法解释同规模的损失波动, 这些结果支持已观测规模内的配比泛化。

5.3 语料规模—质量、配比替代

前述验证表明, 资源规模项能够描述总体损失的衰减趋势, 而语料质量与领域组成进一步决定相同 Token 预算下的损失差异。因而, 讨论质量对规模的替代, 首先需要在明确的工作点和可行配比方向上度量局部收益; 不同实验尺度下的收益只有经过一致校准, 才能进一步换算为等效 Token 数。




图 5.5 广义标度律的留出配比验证：(a) 各评估目标的相对 RMSE、总体 R^2 与配比效应 R^2 ；(b) 三个观测规模的实测与预测损失对比，灰色标记为同一组系数下关闭配比项的预测，实线为理想一致线，阴影表示 $\pm 5\%$ 误差带。

5.3.1 各因素边际效用与弹性分析

在损失为正、工作点位于可行域内部且局部可微时，对标量因素 $x \in \{N, D, Q\}$ 定义边际降损与损失弹性为

$$g_x = -\frac{\partial L}{\partial x}, \quad \epsilon_x = \frac{\partial \ln L}{\partial \ln x} = \frac{x}{L} \frac{\partial L}{\partial x}. \quad (5.19)$$

其中， N, D 的响应由广义标度律给出；整体质量等级 Q 不同于固定的来源质量 $Q_i^{(17)}$ ，其独立边际效应由质量实验拟合的响应模型估计，而不从广义律中的 $p_i Q_i$ 项直接推断。为使收益具有可解释的扰动尺度，规模因素报告 $L(x) - L(1.01x)$ ，质量因素报告 $L(Q) - L(Q + 0.01)$ 。配比受单纯形约束，增加来源 i 的份额 t 时，令 $p_i(t) = p_i + t$ 、 $p_j(t) = p_j(1 - t/(1 - p_i))$ ($j \neq i$)，并以 $L(\mathbf{p}) - L(\mathbf{p}(0.01))$ 衡量可行方向的降损。

图 5.6(a) 给出固定参考配比下的规模弹性及配比方向收益。在已观测的 $N = 10^9$ 、 $D = 2.5 \times 10^{10}$ 工作点，13 个评估目标的弹性中位数分别为 $\epsilon_N = -0.0345$ 、 $\epsilon_D = -0.0868$ 。这表明在该点数据量的相对增益具有更高的损失敏感度，但尚不能据此比较参数与 Token 的算力效率。图中的百亿参数点仅是模型外推，不作为观测证据。图 5.6(b) 显示质量收益随 Q 提高而递减：在 $Q = 0.6$ 时，质量分增加 0.01 的预测降损约为 2.15×10^{-3} 。主组 450 组与对照组 360 组存在包含关系，后者仅检验子集一致性。质量实验与广义律的损失基准尚未统一，故不能将两组导数直接相除，解释为质量提升所等效的 Token 增量。

配比的边际效用不具有统一符号。图 5.7(a) 表明，同一来源的增配方向可能降低某些评估目标的损失，却提高另一些目标的损失；在参考配比下，117 个位于观测支撑域内的可行方向中，仅 53.8% 获得正收益。图 5.7(b) 进一步显示，收益还随来源份额改变，不能把单点导数延伸为全区间的固定排序。因此，配比调整应被视为面向目标和当前配方的局部资源重分配。

5.3.2 广义标度律指导下的语料规模—质量、配比替代

为将上一节的局部降损量转换为等损失的 Token 需求，以已辨识的广义标度律为主体，对数据受限项引入整体质量等级的外部标定：

$$L(N, D, Q, \mathbf{p}) = E + AN^{-\alpha} + \left(\frac{Q}{Q_0}\right)^{-\gamma_Q} [BD^{-\beta} + M(N, D)\varphi(\mathbf{Q}^{(17)}, \mathbf{p})]. \quad (5.20)$$




图 5.6 资源与质量因素的局部响应：(a) 参数量和数据量的损失弹性，以及配比份额增加 1 个百分点的方向收益分布；区间表示跨评估目标的四分位范围，百亿参数点仅为外推。(b) 独立质量实验中质量分增加 0.01 的降损及损失弹性；对照组为主组子集。




图 5.7 领域配比的方向异质性与份额依赖：(a) 不同来源增配 1 个百分点时，各评估目标的预测降损，红色表示降损、蓝色表示增损，空白表示不满足可行方向条件；(b) 在观测支撑域内扫描来源份额所得的方向收益与弹性，色带反映跨评估目标的分布范围。两图均为模型敏感度分析，不作因果解释。




图 5.8 两种示例评估领域的质量—Token 等损失曲线。各曲线对应同一组观测配比，纵轴为保持参考目标损失所需的 Token 数； $Q_0 = 0.6$ 与 $Q_1 = 0.7$ 为质量比较点。离开 $N = 10^9$, $D_* = 250$ 亿 Token 观测工作点后的需求量属于模型情景推算。




图 5.9 同一组观测配比在两种示例评估领域中的等损失 Token 需求。各行配比保持一致，实心与空心标记分别对应 $Q_0 = 0.6$ 和 $Q_1 = 0.7$ ；横向差异表征模型预测的配比依赖性，并非配比干预的因果效应。

其中， $Q_0 = 0.6$ 是整体质量的校准点， $\mathbf{Q}^{(17)}$ 为问题一映射得到并在配比实验中固定的来源质量向量； $M(N, D) = (N/N_0)^{-\eta}(D/D_0)^{-\zeta}$ 为前述规模调制因子。质量指数 $\gamma_Q = 0.1085$ 由单独变化质量的校准实验标定，其余参数均不重估。故 $Q = Q_0$ 时，式 (5.20) 严格退化为原广义律。主口径假定质量同时作用于数据规模项与配比修正项；仅作用于 $BD^{-\beta}$ 的口径作为结构敏感性对照。主口径下，固定配比的精确局部等损失斜率为

$$\left. \frac{d \ln D}{d \ln Q} \right|_{L, \mathbf{p}} = -\gamma_Q \frac{BD^{-\beta} + M\varphi}{\beta BD^{-\beta} + \zeta M\varphi}, \quad (5.21)$$

其中 $M \propto D^{-\zeta}$, $\varphi = \varphi(\mathbf{Q}^{(17)}, \mathbf{p})$ 。因此 $-\gamma_Q/\beta$ 仅在忽略配比项或两项具有相同数据量指数时成立，有限幅度的替代量须逐目标数值求解。

固定 $N = 10^9$ 、替代工作点 Token 数 $D_* = 250$ 亿及参考配比 $\mathbf{p}_0$ ，将 $L(N, D_*, Q_0, \mathbf{p}_0)$ 作为各评估目标的基准损失，求满足该目标损失时 Q 与 $\mathbf{p}$ 对应的最小所需 D 。这里 D_* 不同于广义律的规模归一化锚点 D_0 。配比调整仅考虑观测支撑域内的方向：单一来源份额增加 1 个百分点，其余来源按比例缩减。图 5.8 展示两种示例评估领域的等损失曲线；在相同配比下提高质量使所需 Token 下降，而同一质量水平下不同配比对应不同的需求基线。图 5.9 用同一组真实配比进一步表明，这种配比效应的幅度具有明显的评估目标依赖性。

逐目标先对可行配比方向取节省量中位数，再对 13 个评估目标等权汇总：质量由 0.6 提至 0.7 时，固定配比的 Token 节省中位数为 13.97 亿，叠加可行的 1 个百分点配比调整后为 14.06 亿；仅缩放规模项的敏感性口径分别为 13.30 亿和 13.59 亿。因而，小幅配比调整的总增益有限，但图中的完整观测配比差异可显著改变所需 Token 水平，两种比较尺度不可混同。模型在 Q_0 的锚定误差小于 5×10^{-16} ，可行求根的最大损失残差为 2.33×10^{-13} 。

5.3.3 规模—质量、配比替代边界

上述等损失换算由 $L(N, D, Q, \mathbf{p}) = L^*$ 隐式定义，并非跨工作点通用的 Token 汇率。对式 (5.20)，只有在 $BD^{-\beta} + M\varphi > 0$ 且 $\beta BD^{-\beta} + \zeta M\varphi > 0$ 时，提高质量和增加 Token 才同时具有降损效应，式 (5.21) 的负斜率方可解释为局部替代。由于组成修正 φ 可正可负，这些条件须按评估目标、配比和工作点分别核查。识别边界同样重要：配比实验中的来源质量 $Q_i^{(17)}$ 固定，不能由 $p_i Q_i^{(17)}$ 单独辨识质量提升效应。整体质量指数来自独立实验，其与组成项的乘性耦合是外部标定的结构假设，尚缺少同时独立改变质量与配比的实验验证。

独立改变整体质量等级的实验为局部质量响应提供了直接依据：在 45 组固定 (N, D) 的比较中，验证损失对 Q 的线性趋势斜率均为负。包含 450 条记录的拟合及其 360 条记录的子集对照分别得到 $R^2 = 0.9568$ 和 0.9535 ；二者是包含关系，不能视为独立重复验证。在 $Q = 0.6$ 的工作点，质量提高 0.01 的预测降损约为 2.15×10^{-3} ，质量弹性约为 -0.0482 ，与负向的经验响应一致，但其边际收益随 Q 提高而递减。相比之下，向更大模型和语料规模延伸的扩展结果在 150 组固定 (N, D) 的比较中给出全部为正的质量—损失斜率，并有 362 条记录被截断于损失下界 0.5。这一方向冲突和截断现象表明，该扩展结果不能验证质量响应的外推，也不宜用于重标定质量指数；它并不构成“大模型中质量提升会增损”的实验证据。

因此，本文仅在观测支撑域内调整配比，并在独立质量实验标定的范围附近解释质量边际效用与弹性；质量与组成的联合替代仍须以两种耦合口径及逐目标差异进行敏感性检验。当等损失求解所需的 D 偏离已观测规模，或将关系推广至更大模型时，所得节省量应视为模型情景推算，而非已实现的训练收益或因果效应。

六、问题三：算力约束下的资源联合优化及结构性转移识别

6.1 问题分析与联合优化框架


前两问分别给出了领域质量评价和资源—损失响应，但资源的边际收益并不等于有限预算下的配置优先级。扩大模型、增加训练数据与提升质量均会占用算力，领域配比又会改变相同规模下的损失。因此，本问先在统一成本约束下求解联合配置，再比较质量成本和上下文长度的影响，最后沿预算变化识别配置策略是否发生结构性转移。

本文沿用第二问的 13 个评测域响应，将 A4 的 512 组真实配方作为配比约束依据，以 B7 质量响应描述整体治理收益，并采用 C7 的五档上下文长度构造外生情景。A6–A11 用于复算前问响应在检验配方上的一致性，A12–A15 用于说明跨尺度外推边界，不与真实训练观测混合。图 6.1 给出前问输入、联合求解和结果检验的衔接。

记参数个数和训练 Token 数为 N, D ，17 域配比为 $\mathbf{p} = (p_1, \dots, p_{17})$ 。第一问的 $\mathbf{q} = \mathbf{Q}^{(17)}$ 是固定领域属性，因跨域映射而只有 6 个不同取值；本问另以标量 Q 表示整体治理质量，不将 17 个领域的质量提升分别设为自由变量。为衔接第二问的规模单位，定义

$$n = \frac{N}{10^9}, \quad d = \frac{D}{10^9}, \quad q_{\text{mix}} = \sum_{i=1}^{17} p_i q_i, \quad Q_{\text{base}} = \frac{1}{17} \sum_{i=1}^{17} q_i = 0.6219326581. \quad (6.1)$$

其中， q_{mix} 随配比变化， Q 则通过质量收益和治理成本参与优化，二者不作等同。主分析取 $Q \in [Q_{\text{base}}, 1]$ ；训练平均配方加权基线 0.6193580512 用于敏感性比较，B7 的校准点 $Q_0 = 0.6$ 仅作为质量响应标尺。表中 N, D 统一以 B 表示（ $1\text{B} = 10^9$ ），算力计算仍采用绝



$Q^{(17)}$ 为前两问交接的固定域质量向量； Q 为联合优化中的治理质量变量。

图 6.1 质量、配方及规模响应的衔接与联合求解流程

对个数。

6.2 算力约束下的多维资源联合配置

6.2.1 基于质量桥接的联合资源配置建模

领域配比属于组成数据，不能把各分量视为互不约束的投入。沿用第二问的特征构造，对配比作带平滑项的中心化对数比变换，并与质量加权重额拼接为 34 维特征：

$$\text{clr}_\delta(p)_i = \ln(p_i + \delta) - \frac{1}{17} \sum_{j=1}^{17} \ln(p_j + \delta), \quad \delta = 0.001. \quad (6.2)$$

$$x = (p \odot \mathbf{q}, \text{clr}_\delta(p)), \quad z = \frac{x - \mu}{\sigma}, \quad \Phi_k = s_k(\beta_{0k} + \boldsymbol{\theta}_k^T z - c_k). \quad (6.3)$$

其中， $k = 1, \dots, 13$ 对应评测域， μ, σ 为特征标准化参数，其余系数均取第二问估计结果。规模衰减项与基础损失响应为

$$S_k = (n/0.001)^{-\eta_k} (d/1)^{-\zeta_k}, \quad L_{2,k} = E_k + A_k n^{-\alpha} + B_k d^{-\beta} + S_k \Phi_k, \quad (6.4)$$

这里 $\alpha = \beta = 0.2931826439$ 。固定领域质量已通过 $p \odot \mathbf{q}$ 进入基础响应，整体治理带来的变化则由 B7 质量律补充：

$$F_7(n, d, Q) = 0.9654077057 + 0.5307187920 n^{-0.2825} + 1.6157571765 (dQ)^{-0.108}. \quad (6.5)$$


为使治理前后的响应在基线质量处一致，主模型采用比值桥接，并以加性桥接作为敏感性对照：

$$L_k^{(r)} = L_{2,k} \left[\frac{F_7(n, d, Q)}{F_7(n, d, Q_{\text{base}})} \right]^\kappa, \quad (6.6)$$


$$L_k^{(a)} = L_{2,k} + \kappa [F_7(n, d, Q) - F_7(n, d, Q_{\text{base}})].$$

两种形式在 $Q = Q_{\text{base}}$ 时均还原第二问响应。主模型取 $\kappa = 1$ ，另以 0.5、1.5 检验收益强度， $\kappa = 0$ 构成零收益对照。固定 N, D, Q 时，质量项不改变配方排序；联合配置的收益来自配比、规模与治理投入在同一预算下的相互调整。

图 6.2a 区分三个直接观测尺度与本问的条件预测配置；图 6.2b 展示三类质量成本的差异。前者说明规模外推范围，后者说明质量收益必须与其额外开销共同考虑。



(a) 直接支持尺度与联合配置



(b) 三种质量成本的增量曲线

图 6.2 直接观测尺度与联合配置及三类质量治理成本

单位 Token 的治理成本采用表 6.1 所列三种形式。治理只计算相对于基础质量的增量，不把原有数据质量重复计费。

表 6.1 质量成本函数及题给参数

形式	$g(Q)$	单位与说明
指数	$10^7 \exp(6Q)$	FLOPs/Token, 随质量凸增
幂函数	$5 \times 10^9 Q^4$	FLOPs/Token, 四次幂
对数	$2 \times 10^9 \ln(1 + 10Q)$	FLOPs/Token, 上界处有限

令 L_{ctx} 为外生上下文长度，将训练与注意力的合并系数及增量质量成本分别记为

$$a = 6 + \eta_{\text{attn}} L_{\text{ctx}}, \quad h(Q) = [g(Q) - g(Q_{\text{base}})]_+, \quad \eta_{\text{attn}} = 2 \times 10^{-4}. \quad (6.7)$$

训练、质量处理与注意力计算使用同一训练数据量 D ，故总成本为

$$C_{\text{used}} = C_{\text{train}} + C_{\text{attn}} + C_Q = 6ND + \eta_{\text{attn}}NDL_{\text{ctx}} + Dh(Q) = D[aN + h(Q)]. \quad (6.8)$$

设 $A \in \mathbb{R}^{m \times 17}$ 为所选真实配方组成的锚点矩阵， w 为非负权重， $\mathbf{p} = A^T w$ 。以 13 域平均损失衡量整体表现，并将训练成本、质量边界和配方支持统一纳入约束。

问题三的联合配置模型写为

$$\begin{aligned} \min_{N, D, Q, w} \quad & J(N, D, Q, w) = \frac{1}{13} \sum_{k=1}^{13} L_k(N, D, Q, A^T w), \\ \text{s.t.} \quad & \begin{cases} D[(6 + \eta_{\text{attn}} L_{\text{ctx}})N + h(Q)] \leq C, & (C1) \\ Q_{\text{base}} \leq Q \leq 1, & (C2) \\ 10^6 \leq N \leq 10^{11}, \quad 10^9 \leq D \leq 10^{13}, & (C3) \\ p = A^T w, \quad w \geq 0, \quad \mathbf{1}^T w = 1, & (C4) \\ L_k(N, D, Q, p) \geq 10^{-6}, \quad k = 1, \dots, 13. & (C5) \end{cases} \end{aligned} \quad (6.9)$$

约束 (C1) 限定总 FLOPs，(C2) 限定治理质量，(C3) 给出规模计算范围，(C4) 使配比

位于真实配方的凸包内，(C5) 排除非正损失预测。由此，优化对象是四类资源的联合配置，而非四个独立目标； L_{ctx} 仅改变给定情景下的成本，不参与内点寻优。

6.2.2 基于真实配方凸包的约束求解

参数量与数据量横跨多个数量级，直接以原始数值求解容易造成搜索尺度失衡。本文采用对数参数化，将规模坐标归一化至 $[0, 1]$ ，并根据预算计算可行质量上界：


$$\begin{aligned} Q_{\text{hi}} &= \max\{Q \in [Q_{\text{base}}, 1] : D_{\min}[aN_{\min} + h(Q)] \leq C\}, \\ N &= \exp\{\ln N_{\min} + u \ln(N_{\text{cap}}/N_{\min})\}, \\ D &= \exp\{\ln D_{\min} + v \ln(D_{\text{cap}}/D_{\min})\}, \quad u, v \in [0, 1]. \end{aligned} \quad (6.10)$$

其中， N_{cap} 、 D_{cap} 为规模范围与预算共同限定的搜索上界。主求解器采用 SLSQP，设置三个确定性起点，并在满足预算、质量边界、凸组合及 13 域损失为正的候选中选择目标值最低者；独立复算采用 COBYQA。

初始搜索使用 25 个锚点以降低权重维度，但其凸包只是完整 A4 凸包的子集，不能据此排除其他真实配方方向上的改善。为检查锚点缩减的影响，固定 N, D, Q ，对全部 512 个配方沿下式作方向扫描：

$$p(t) = (1 - t)p + ta_r, \quad r = 1, \dots, 512, \quad t \in \{10^{-4}, 10^{-3}\} \quad (6.11)$$

这里 a_r 为第 r 个真实配方。发现下降方向后，将相应配方加入锚点集合并重新求解。由于 p 和 a_r 均属于完整 A4 凸包，增广过程始终保留真实配方支持约束。图 6.3 给出候选增广与复核流程；该检查用于寻找遗漏方向，不构成连续域全局最优证明。



方向扫描用于检查候选遗漏；最终配置仍须满足可行性与数值稳定性要求。

图 6.3 真实配方约束下的候选增广与求解复核流程

为使配置结果具有可比性，主实验在相同预算、上下文和成本条件下设置四组对照：仅优化 N, D 的规模基线，进一步释放配比的配比组，释放治理质量的质量组，以及同时释放两者的联合组。11 档预算、5 档上下文和 3 类成本共形成 165 个情景、660 项求解，其他敏感性与复算安排见表 6.2。

表 6.2 四组消融与条件实验矩阵

类别	自由变量或变化因素	数量及用途
规模基线	N, D ; 固定平均配方与基础质量	联合配置的基准
配比组	N, D, p ; 固定基础质量	分离配比调整收益
质量组	N, D, Q ; 固定平均配方	分离治理收益及成本
联合组	N, D, p, Q	评价联合资源配置
主矩阵	11 预算、5 上下文、3 成本、4 组	660 项
成本对照	统一 Q_{base} 至 1 的端点增量价格	检验价格尺度影响
桥接对照	2 种桥接、3 种强度、2 种基线质量	检验接口影响
搜索敏感性	49/97 锚点、6 起点、边界扰动	检验求解稳定性
零收益与预算加密	$\kappa = 0$; 41 档预算	检验治理收益与阈值
算法对照	5 预算、2 上下文、3 成本、2 求解器	60 项

6.2.3 多预算配置结果与逐域权衡分析

表 6.3 给出上下文 4096、预算为 10^{19} 、 10^{22} 、 10^{24} FLOPs 时的代表性配置。各行均从相同响应与约束下的可行候选中选取，候选来源分别列明，避免将原 25 锚点结果与增广后的结果混为一谈。

表 6.3 上下文 4096 时有限候选集中的典型资源配置

C (FLOPs)	成本	N (B)	D (B)	Q	J	候选来源
10^{19}	指数	0.0678	21.64	0.6219	2.38753	扩展锚点
10^{19}	幂	0.0678	21.64	0.6219	2.38753	扩展锚点
10^{19}	对数	0.0678	21.64	0.6219	2.38753	扩展锚点
10^{22}	指数	2.5115	491.40	0.9829	1.66994	扩展锚点
10^{22}	幂	2.6199	452.13	1.0000	1.67192	扩展锚点
10^{22}	对数	2.2175	626.41	1.0000	1.66062	97 锚点
10^{24}	指数	21.9273	6529.84	1.0000	1.46600	97 锚点
10^{24}	幂	22.0068	6480.02	1.0000	1.46612	97 锚点
10^{24}	对数	21.5744	6758.48	1.0000	1.46547	97 锚点

低预算时，三类成本均选择基础质量，新增算力主要用于参数量与数据量；预算提高后，治理质量逐步进入内点或达到上界。相同预算下，成本形式改变了治理投入与数据量之间的取舍，例如 10^{22} FLOPs 时指数成本对应 $Q = 0.9829$ ，而另两类成本达到质量上界。这里的上界解是当前质量响应与成本共同作用的结果，并不表示真实语料已经达到完美质量。

完整配方见表 6.4。以幂成本为例，预算提高时 wikipedia en 与 gutenber pg 19 的份额增加，stackexchange 的份额下降；pile cc 则先增后减。这表明配方调整并非对某一来源持续加码，而是随规模和治理投入共同变化。

表 6.4 幂成本条件下典型有限候选的完整领域配方 (%)

领域	10^{19}	10^{22}	10^{24}
arxiv	3.45	2.62	1.79
freelaw	7.67	7.44	5.25
nih exporter	0.02	0.01	4.88
pubmed central	2.93	1.46	3.63
wikipedia en	6.84	7.74	19.69
dm mathematics	4.73	5.06	0.84
github	11.40	12.92	12.12
philpapers	<0.005	<0.005	<0.005
stackexchange	14.07	13.10	3.83
enron emails	0	<0.005	0.08
gutenberg pg 19	6.55	9.03	15.90
pile cc	17.87	28.14	11.49
ubuntu irc	5.10	5.13	14.81
europarl	<0.005	<0.005	0.09
hackernews	6.16	4.63	5.22
pubmed abstracts	9.81	0.05	<0.005
uspto backgrounds	3.41	2.67	0.36

对全部 A4 配方作方向检查后，165 个原联合配置均发现初始 25 锚点凸包之外的改善方向。上下文 4096 的 33 组增广求解最终使用 39–42 个锚点，较原联合解进一步改善 0.8383%–2.5512%，配比的 L_1 距离变化为 0.5280–0.6468。图 6.4 说明初始搜索范围对配置有实质影响；这部分收益单独报告，不并入原四组消融结果。




图 6.4 上下文 4096 时 33 组锚点增广配置相对原 25 锚点联合解的变化

整体损失下降也不意味着每个评测域同时改善。原 165 组联合情景中，162 组至少有

一个评测域损失上升，最多涉及 2 个领域；最大退步为 0.0867182 nats，出现在 $C = 3 \times 10^{20}$ 、上下文 2048、幂成本条件下的 dm mathematics。图 6.5 保留 13 域的变化，说明均值目标下存在领域间权衡，不能仅凭平均改善判断全部任务受益。




图 6.5 典型配置的逐域代价；热力图保留 13 个评测域和 9 组预算–成本组合，颜色表示相对原配方的 Loss 变化

6.2.4 联合配置的消融与数值稳健性检验

首先在原 25 锚点条件下比较四组配置，以相同预算、上下文和成本的规模基线为参照，定义平均改善率及非加性项

$$G = 100 \frac{J_{\text{base}} - J_{\text{joint}}}{J_{\text{base}}}, \quad H = J_{\text{quality}} + J_{\text{mixture}} - J_{\text{base}} - J_{\text{joint}}. \quad (6.12)$$

图 6.6 给出指数成本、上下文 4096 的四组轨迹。165 个情景中，联合配置相对规模基线的平均损失改善为 4.1603%–5.8086%； H 在 71 组为正、47 组为负、47 组接近零。因此，配比和治理的联合收益取决于预算与响应曲率，不能把两者单独优化的收益直接相加。上述改善均为响应模型预测。

其次，质量收益的幅度与桥接形式可能影响候选排序。对同一候选集分别采用两种桥接和三种正收益强度，构成六个情景。设 X 为共同可行候选集，以各情景中的最佳候选为参照，定义相对后悔值

$$J_s^{\text{best}} = \min_{x \in X} J_s(x), \quad R_s(x) = \frac{J_s(x) - J_s^{\text{best}}}{|J_s^{\text{best}}|}. \quad (6.13)$$

再以最小化最坏情景后悔值选择稳健候选：

$$x_{\text{rob}} \in \arg \min_{x \in X} \max_s R_s(x), \quad v_{\text{rob}} = \min_{x \in X} \max_s R_s(x). \quad (6.14)$$






图 6.6 指数成本、上下文 4096 时 11 档预算的四组消融；各组均联动优化 N/D

165 组中的最大相对后悔值为 1.5465%，在另设的零收益压力情景下为 2.5946%。图 6.7a 表明，候选对已考察的质量收益变化保持有限幅度的稳定性；这一结论限定于共同候选集和给定情景集合。

最后，以相同 25 锚点、相同三个起点和相同配置进行 SLSQP 与 COBYQA 的 30 对复算。60 个结果均满足基本可行条件，59 个通过扰动检查，其中 SLSQP 为 30/30、COBYQA 为 29/30，最大均值损失差为 0.000168474。图 6.7b 同时比较损失差与函数调用次数，用于检查结果对求解器的依赖，而非证明全局最优。



(a) 有限候选的情景后悔值



(b) 两种求解器的一致性

图 6.7 有限情景下的稳健配置与求解器一致性检验

6.3 质量成本与上下文长度的配置影响

6.3.1 基于边际弹性的资源替代关系

联合配置的变化需要从预算约束下的边际收益解释。当总预算约束取等号、其余相关边界未激活时，可消去 D 。提高质量一方面直接降低损失，另一方面增加单位 Token 成本并压缩可训练的数据量，因此

$$D = \frac{C}{aN + h(Q)}, \quad \frac{dD}{dQ} = -\frac{Dg'(Q)}{aN + h(Q)}, \quad T_Q = J_Q - \frac{J_D D g'(Q)}{aN + h(Q)}. \quad (6.15)$$

T_Q 是沿预算边界提高质量时的净损失变化。若 $T_Q < 0$ ，局部增加治理质量仍有利；内

点驻值要求 $T_Q = 0$ 。在下界处, $T_Q \geq 0$ 对应继续治理缺乏局部收益; 上界处则应结合相应的单侧条件判断, 不能仅凭质量触及上界认定模型失效。

对未触及规模边界的配置, N, D 的驻点条件为

$$J_N + \lambda a D = 0, \quad J_D + \lambda(aN + h) = 0. \quad (6.16)$$

进而得到损失弹性与治理成本份额之间的关系:

$$\varepsilon_N = -\frac{NJ_N}{J}, \quad \varepsilon_D = -\frac{DJ_D}{J}, \quad \frac{\varepsilon_N}{\varepsilon_D} = \frac{aN}{aN + h} = 1 - s_Q, \quad (6.17)$$

$$s_Q = \frac{C_Q}{C_{\text{used}}} = \frac{h(Q)}{aN + h(Q)}, \quad \left. \frac{\partial s_Q}{\partial N} \right|_{Q, L_{\text{ctx}}} = -\frac{ah(Q)}{[aN + h(Q)]^2}. \quad (6.18)$$

式 (6.17) 说明, 治理成本占比越高, 可分配给模型与数据规模的相对空间越小; 式 (6.18) 则表明, 固定质量和上下文且 $h(Q) > 0$ 时, 模型规模增加会降低治理成本份额。因此, 质量治理的绝对投入与预算占比不能互相替代。

图 6.8a 给出三项成本分解。以增广后的幂成本配置为例, 预算从 10^{22} 增至 10^{24} FLOPs 时, 治理占比由 19.2241% 降至 2.6935%, 绝对成本却从 1.9224×10^{21} 增至 2.6935×10^{22} FLOPs。图 6.8b 进一步复核原 165 组联合配置的局部资源均衡关系, 最大归一化残差为 2.04434×10^{-6} 。




图 6.8 训练成本分解与局部资源均衡检验

6.3.2 基于端点归一化的质量成本比较

三类成本不仅曲率不同, 价格量级也不同。直接比较原参数下的解, 无法区分配置变化究竟来自函数形状还是治理价格。为此, 以指数成本从基础质量提升至 1 的增量价格为参照, 对其余形式作端点归一化:

$$\lambda_f = \frac{g_{\text{exp}}(1) - g_{\text{exp}}(Q_{\text{base}})}{g_f(1) - g_f(Q_{\text{base}})}, \quad h_f^{\text{norm}}(Q) = \lambda_f [g_f(Q) - g_f(Q_{\text{base}})]_+. \quad (6.19)$$

其中 f 表示成本类型。归一化后, 各成本在 $Q = 1$ 处具有相同增量价格, 但区间内的

边际成本仍保留各自形状，从而可以比较不同治理路径对配置的影响。

图 6.9b 比较原参数与归一化参数下的质量轨迹；55 个预算-上下文组合中，有 19 组的最低损失所对应成本形式发生变化。这说明质量投入同时受价格量级和曲率影响，不能据原参数下的一次排序断言某种函数普遍更优。图 6.9a 同时给出各成本下的预算-上下文轨迹，供下一节比较注意力开销的影响。




图 6.9 不同预算、上下文与成本口径下的质量配置轨迹

6.3.3 注意力临界长度与上下文敏感性检验

上下文长度不改变本问的决策维度，而是通过注意力开销改变预算约束。由注意力成本与训练成本之比可直接得到临界长度：

$$\frac{C_{\text{attn}}}{C_{\text{train}}} = \frac{\eta_{\text{attn}} L_{\text{ctx}}}{6}, \quad L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta_{\text{attn}}} = 30000. \quad (6.20)$$

这一比值与 N , D 和预算均无关。C7 的五档长度 2048、4096、8192、32768、131072 均纳入比较，其中 32768 和 131072 已超过临界值，注意力开销大于基础训练开销。

表 6.5 固定预算为 10^{22} FLOPs 并采用幂成本，比较原 25 锚点联合解在五档上下文下的变化。随着上下文增大，注意力/训练成本比由 0.06827 增至 4.36907，配置中的 N 由 2.8157 B 降至 1.1338 B， D 由 448.44 B 降至 245.24 B，平均损失相应上升。结合图 6.9a 可见，上下文需求既压缩规模预算，也会影响治理质量达到边界的预算区间。

表 6.5 原 25 锚点联合解的上下文配置比较

L_{ctx}	注意力/训练比	N (B)	D (B)	Q	J
2048	0.06827	2.8157	448.44	1.0000	1.69176
4096	0.13653	2.7163	439.08	1.0000	1.69523
8192	0.27307	2.5438	422.26	1.0000	1.70169
32768	1.09227	1.9152	353.43	1.0000	1.73153
131072	4.36907	1.1338	245.24	1.0000	1.79558

6.4 跨预算资源配置的结构性转移识别

6.4.1 基于质量边界与配方支持集的转移识别

预算增加时，资源数值变化是普遍现象，但平滑的数量增长不等于策略发生质变。本文从质量约束是否激活以及配方主要支持是否改变两个方面表征结构，并要求变化具有持续性。质量状态按 Q 与上下界的距离划分为下界、内点和上界；配方支持集与相邻配置的支持距离定义为

$$S_\tau(p) = \{i : p_i > \tau\}, \quad d_J(S_0, S_1) = 1 - \frac{|S_0 \cap S_1|}{|S_0 \cup S_1|}, \quad \tau = 0.01. \quad (6.21)$$

仅有支持集跨阈值还不足以判定转移。本文同时要求 $d_J \geq 0.2$ 与 $\|p_1 - p_0\|_1 \geq 0.02$ ，并检查该变化在后续预算点及加密预算中是否保持。候选事件先由 11 档预算定位，再以 41 档预算复核，从而将单点波动与持续变化分开。

质量边界事件还需与式 (6.15) 的边际方向一致，并在桥接形式、收益强度、随机种子、边界及锚点扰动下接受检验。主判据要求不少于 70% 的情景支持同一事件，同时提高阈值检查识别结果的稳定性。图 6.9a 仅作为联合配置质量轨迹的参照，固定配方事件与联合配置事件分别判断。

6.4.2 结构转移的多情景检验与阈值敏感性分析

表 6.6 汇总识别结果。固定配方、指数成本且上下文为 131072 时，出现一次治理质量由下界进入内点的启动事件；预算加密将区间从 $[3 \times 10^{19}, 10^{20}]$ 缩小至约 $[7.50 \times 10^{19}, 10^{20}]$ FLOPs，粗细扫描对应同一事件。

表 6.6 结构转移识别与阈值敏感性

项目	实际结果	判断
固定配方质量启动	指数成本、 $L_{\text{ctx}} = 131072$ ：下界 $\rightarrow$ 内点	质量治理由下界进入内点
预算区间 (FLOPs)	粗 $[3 \times 10^{19}, 10^{20}]$ ；细 $[7.50 \times 10^{19}, 10^{20}]$	两个区间属于同一事件
情景支持比例	$16/21 = 76.19\%$	通过 70% 门槛，未通过 80% 门槛
质量方向容差	10^{-4} 通过； 10^{-5} 不通过	阈值会影响事件识别
联合配置	70% 门槛下无稳定事件	联合策略未形成稳定结构转移
光滑配方负对照	占比均为正，仍跨 1% 阈值	配方支持变化具有连续性

该事件获得 16/21，即 76.19% 的情景支持，通过 70% 门槛，但未达到 80%；方向容差由 10^{-4} 收紧至 10^{-5} 后也不再通过。因此，它反映的是特定配置下的局部质量启动，不能推广为所有配置共有的相变。

在联合配置中，未发现通过 70% 情景门槛的稳定结构转移。光滑配方负对照还表明，即使所有份额始终为正，连续变化也可能跨过 1% 的支持阈值。因此，结构判断必须同时检查变化幅度、持续性和情景一致性，不能仅凭热图颜色突变或某一领域进入支持集作出结论。

6.5 本问结论

在统一计入训练、质量治理与注意力成本后，本文将规模、数据量、领域配比和治理质量纳入同一约束优化模型。原 25 锚点条件下，联合配置较同预算规模基线的平均预测损失改善 4.1603%–5.8086%，但 165 组中 162 组至少有一个评测域退步，说明整体收益伴随领域间权衡。全 A4 方向检查进一步发现初始候选集合的限制，并通过锚点增广获得更低的可行预测损失。

质量治理的绝对投入与成本占比可呈现不同趋势，成本函数的价格尺度和曲率也会改变配置。注意力与训练开销相当的临界上下文长度为 30000，C7 中的 32768 和 131072 已进入注意力成本占优的区间。因而，预算比较应同时固定成本口径和上下文条件，不能只比较参数量或治理质量。

结构检验在固定配方的局部情景中识别出质量启动，但联合配置未形成跨情景稳定的结构转移。有限候选的最大相对后悔值为 1.5465%，双求解器扰动检查通过 59/60，支持所报告配置的数值可复核性。后续能力分析可据此使用各预算下的配置及损失输出；实际训练应用仍需在同一治理流水线上联合校准质量评分、治理 FLOPs 与 13 域损失。

七、 问题四：技术演进分解及能力前沿预测

7.1 问题分析与统一状态框架

问题四需要解决的核心识别问题，是将前三问给出的 Loss 机制与现实模型的 Benchmark 表现统一到可比较的能力尺度。前三问依次刻画数据质量与领域配比、广义标度关系及算力约束下的最优资源配置，由此形成从预算到最优损失的机制映射 $L^*(C)$ ，现实样本则提供综合能力前沿 F_t 和训练算力前沿 C_t 。对两类前沿分别实施时间回归，既不能从回归系数中识别规模效应，也无法构造算力增速放缓的结构反事实。为此，本文引入 Loss-Benchmark 桥接函数 H 作为观测映射，并建立统一状态方程

$$F_t - F_{t_0} = \underbrace{H[L^*(C_t)] - H[L^*(C_{t_0})]}_{\text{规模机制项}} + \underbrace{T_t}_{\text{非规模技术综合项}} \quad (7.1)$$

其中， T_t 表示前三问规模机制不能解释的锚定残差，综合反映架构、优化方法、数据工程、后训练及未观测因素，不再将其归属于某项单一技术。图 7.1 给出从前三问机制输出到能力度量、桥接、贡献分解与预测的完整链路。历史分解与未来预测共用式 (7.1)，桥接误差和支持边界亦沿同一链路传播。后续分析依次识别 F_t 、估计 H 、构造 $B(C) = H[L^*(C)]$ ，并据此分解历史增长与推演未来前沿。

7.2 开放权重模型综合能力度量

本节首先确定现实能力的观测状态及其可靠性，再将该状态传递给后续桥接与贡献分解。具体而言，先建立可比较的综合能力坐标，再以滚动高分位提取时间前沿，并从任务维度、指标口径和模型族依赖三个层面检验其稳健性。




图 7.1 前三问机制输出与能力前沿分析的统一框架

7.2.1 基于多任务一致性验证的综合能力表征

能力口径首先满足“对象可比、时间可追溯、任务完整”。主样本限定为开放权重的 chat 或领域微调模型，以 Open LLM Leaderboard 的 Submission Date 作为能力出现时间，并要求 IFEval、BBH、MATH Lvl 5、GPQA、MUSR、MMLU-PRO 六项得分完整。pretrained 模型只作为类型对照，许可证字段另按 Apache、MIT、BSD、CC-BY、OpenRAIL 及可研究模型族许可证构造严格子样本，但该文本规则不解释为法律合规认证。各数据源的角色和时间合同见表 7.1。

表 7.1 问题四的数据口径、时间合同与证据角色

数据	主筛选与变量	时间轴	样本量	证据角色
C1/C2	开放权重、六项完整、chat/finetuned	Submission Date	231	能力主前沿
C8	最新可解析快照、六项任务得分	评测时间	1854	逐任务诊断
C4	Language、LM/QA、可信 reported compute	Publication date	326	算力主前沿
C6	High 与 Medium 分层保留	不进入时间轴	7+68	Loss-能力桥接
Q3	主情景、context 4096、三档预算	算力预算	3 个锚点	规模机制

说明，C8 共审计 1860 个唯一模型，其中 1854 个六维完整，C4 的 6ND 估计仅进入敏感性分析。

六项指标分别刻画指令遵循、综合推理、数学、研究生层次问答、多步软推理与专业知识。为避免由样本方差替研究目标赋权，主分析采用等权均值 $Y_i = \frac{1}{6} \sum_{k=1}^6 S_{ik}$ ，使结果仍保持 0–100 分的直观解释。等权并不意味着六项完全同质，其作用是构造稳定、透明的共同能力坐标，PCA 和任务内标准化均值只用于检验该坐标是否被单项量纲支配。

六项原始得分的 Cronbach $\alpha = 0.826$ ，达到较好的内部一致性，标准化 PCA 的第一主成分解释率为 65.1%，等权得分与第一主成分、任务内标准化均值的相关系数分别为 0.960 和 0.977。三种能力口径的前沿净变化方向均为正，说明等权指标既保留可解释性，也未偏离数据中的主要共同变化方向。

7.2.2 基于滚动分位的能力前沿建模

单个榜首模型易受偶然提交、测试噪声和同族微调影响，月均值又会被大量普通提交拖动。本文在每个月末向前取三个月，以综合能力的 90% 分位定义开放权重能力前沿

$$F_t = Q_{0.90}\{Y_i | t - 3\text{月} < t_i \leq t\}. \quad (7.2)$$

该定义衡量当期可稳定达到的高能力区域，而非单一最高值。滚动窗口同时具有两个作用，其一是降低单次榜首提交对前沿的影响，其二是将模型提交日期转换为可比较的月度状态。窗口内的模型数量不足时不形成有效点，从而避免少量观测造成过度波动。主样本在 2024 年 6 月至 2025 年 3 月形成 10 个有效月度点，前沿从 30.754 升至 39.062，观测净增长为 8.307 分。图 7.2a 同时保留全部模型散点和 2/3/4 个月、Q90/Q95 六种方案的包络，主曲线始终处于敏感性范围内。由此，本节得到可用于后续桥接的时间索引能力状态 F_t ，并为逐任务和模型族检验保留了原始观测基础。




图 7.2 开放权重模型综合能力前沿与逐任务演进广度。(a) 综合能力滚动前沿及多窗口敏感性包络。(b) 六项任务首末窗口得分变化

7.2.3 能力前沿的多维稳健性检验

图 7.2b 显示，首末窗口的六项任务中有五项提高，MATH Lvl 5、IFEval、MMLU-PRO、BBH、MUSR 分别增加 18.807、8.825、6.355、3.853 和 2.116 分，GPQA 下降 1.174 分。月度任务改善广度的中位数为 4/6。因此，8.307 分增长具有较广的任务基础，但并不表明各维能力同步改善。C8 中 MATH 的 154 个精确零值保留为困难任务的有效得分，未发现重复模型、重复结果文件或集中性快照故障。

进一步控制重复提交后，按基础架构正则识别模型族，无法识别时退回 Hugging Face 组织名，每个模型族每月仅保留最高能力模型，54 个“族-月”单元的前沿仍增长 8.238 分。按“月份 × 模型族”进行 2000 次块 Bootstrap，净增长为正的的比例为 93.8%，中位数 6.804 分，2.5%–97.5% 分位为 $[-2.201, 15.732]$ 。该结果排除了热门模型族重复提交对主增长的完全解释，但仍保留 6.2% 重采样不增长这一不确定性。类型对照中，pretrained 前沿提高 5.731 分，小于 chat/finetuned 的 8.307 分，提示后训练可能参与能力推进，由于两类样本构成不同，本文不把差值解释为后训练的因果贡献。

表 7.2 依次检验指标的可合成性、方向一致性、重复提交影响及模型类型异质性。由此得到统一状态方程中的观测状态 F_t ，后续以 8.307 分作为历史增长事实，并将模型族依赖纳入 Bootstrap。下一节进一步估计连接 Loss 与该能力状态的观测映射 H 。

表 7.2 综合能力指标与能力前沿的多层稳健性检验

检验层次	统计量或对照	结果	证据含义
内部一致性	Cronbach α	0.826	六项任务具有较好可合成性
共同因子	第一主成分解释率	65.1%	存在占主导的共同能力方向
口径一致性	等权与 PCA/标准化均值相关	0.960/0.977	结论不受单一量纲支配
前沿口径	等权、PCA、标准化均值	净变化均为正	上升方向不依赖合成方法
模型族平衡	每族每月仅留最优模型	+8.238 分	重复提交不能解释主增长
相关性重采样	族-月块 Bootstrap 2000 次	93.8% 为正	方向稳健，但保留 6.2% 反例
模型类型	pretrained 与 chat/finetuned	5.731/8.307 分	异质性提示，不作因果归因

说明，主模型始终采用等权能力口径，PCA、标准化均值及类型拆分仅用于稳健性检验。

7.3 Loss-Benchmark 能力映射

能力前沿给出了现实模型的观测尺度，但尚未回答前三问的最优损失如何进入该尺度。本节利用分层桥接样本估计 H ，重点处理来源水平差异、单调机制约束及小样本验证误差，并将桥接结果作为规模能力函数的唯一观测接口。

7.3.1 Loss-Benchmark 桥接样本的可比性分层

前三问输出的是验证 Loss，式 (7.1) 左侧则是 Benchmark 得分，两者不能直接相减。C6 桥接样本要求验证 Loss 与榜单综合得分同时可用，共保留 75 条观测。桥接数据不进入时间前沿，其作用仅在于估计两个量尺之间的观测关系，因而发布日期差异不会被误写为时间趋势。

按实验协议的可比程度，样本分为 High 和 Medium 两层。7 条 High 观测均来自 Pythia，训练阶段与 Loss 口径较为一致，可用于确定映射的水平位置。68 条 Medium 观测覆盖更多模型族，为响应曲线提供更宽的 Loss 范围，但其验证集、训练阶段或 Loss 定义存在差异。若直接混合两层样本，来源间的绝对水平差将进入能力响应，若仅使用 High 层，7 条观测又不足以稳定辨识非线性形状。

基于上述证据结构，High 层承担水平锚定，Medium 层提供形状信息，来源截距与残差方差分别估计。该分工不要求不同来源具有统一的绝对 Loss 尺度，后续贡献分解只使用同一层内的桥接差值。由此既利用 Medium 层的覆盖范围，又避免其系统偏移改变规模贡献的方向。

7.3.2 基于来源偏差不变约束的单调能力桥接

记 I_i^M 为 Medium 指示变量，在 Loss 分位点 κ_j 上构造铰链基函数，建立

$$Y_i = \alpha + \delta_M I_i^M + \sum_{j=1}^J \beta_j (\kappa_j - L_i)_+ + \varepsilon_i, \quad \beta_j \geq 0, \quad \text{Var}(\varepsilon_i) = \sigma_{g(i)}^2. \quad (7.3)$$

非负约束保证 $H'(L) \leq 0$ ，即 Loss 降低不会预测出能力下降。High/Medium 分别估计残差尺度，考虑 High 仅 7 条，本文以 5 个先验自由度向总体方差作经验收缩，避免小样本方差过小而在加权拟合中占据不合理权重。相邻铰链系数的一阶差分惩罚控制局部斜率突变，惩罚强度由分层留出交叉验证确定为 10。

估计的 Medium 来源截距为 $\hat{\delta}_M = 11.824$ 分。绝对截距用于吸收跨来源 Loss 水平差异，而历史分解只使用同一桥接层内的差值 $H(L_1) - H(L_0)$ ，故固定来源偏差严格抵消。该“来源截距可变、能力差分不变”的设定适应了当前多源小样本条件，且无需假定不同来源具有统一的绝对 Loss 基准。图 7.3a 仅在 C6 观测范围 [1.65, 2.84] 内绘制桥接曲线，灰色边缘不参与拟合外推。




图 7.3 来源分层的 Loss-Benchmark 单调桥接与留出预测校准。(a) High 与 Medium 分层样本及单调桥接曲线。(b) 分层留出预测与四类桥接误差对照

7.3.3 桥接模型的留出检验与误差分析

四类桥接统一采用“Medium 留一模型族、High 留一观测”的交叉验证，结果见表 7.3。pooled 线性模型的 RMSE 最低，主模型的 MAE 最低，主模型并非在所有误差指标上占优。本文仍选择来源校准单调样条，是因为贡献分解要求同时满足机制方向、来源偏差显式分离和差分不变性，不能只依据单一 RMSE 选模。

表 7.3 四类 Loss-Benchmark 桥接的统一留出验证

桥接模型	RMSE	MAE	结构性质
pooled 线性	11.815	9.817	无来源校准、无形状约束
High-only 线性	17.620	13.455	同协议但样本仅 7 条
无来源校准保序回归	13.190	10.318	单调但混合来源水平
来源校准单调样条（主模型）	12.766	9.650	单调、分层方差、差分不变

说明，四类模型均在同一 75 条留出预测上比较，加粗只表示对应误差指标的最小值。

全样本 Loss 与能力的 Spearman 相关为 -0.549 ，方向符合机制预期，但图 7.3b 显示绝对映射仍有明显离散。逐一删去 7 个 Pythia 观测后，末端斜率保持在 -24.61 至 -24.99 分/Loss，后续规模份额上界仅在 8.431% – 8.561% 间变化，表明固定样本结论不由单个 High 观测主导。桥接误差仍是问题四的重要不确定性，须在后续条件模拟中完整传播。本节由此得到观测映射 H ，下一节将其与问题三的 $L^*(C)$ 复合，形成规模能力函数 $B(C)$ 。

7.4 规模扩张与非规模技术进步贡献分解

在获得能力状态 F_t 、桥接函数 H 及问题三的最优损失曲线 $L^*(C)$ 后，本节考察历史能力增长中可由算力机制解释的部分。分析顺序为先构造与能力前沿同尺度的算力前沿，再形成 $B(C) = H[L^*(C)]$ ，最后在共同支持边界约束下给出贡献的部分识别集合。

7.4.1 训练算力前沿的滚动分位建模

为与能力前沿保持相同时间平滑尺度，训练算力前沿定义为开放权重 Language 域、language modeling 或 question answering 任务中，Confident/Likely 且真实报告训练 FLOPs 模型的三个月滚动 Q90。共有 617 个模型满足基础元数据筛选，342 个报告 compute，其中

326 个进入可信主样本，72 个仅能由 6ND 估计，203 个缺失算力。主结果只使用 reported compute，6ND 仅构造敏感性曲线。

图 7.4a 显示，2023 年 6 月至 2024 年 6 月的 Theil–Sen 斜率为每月 $0.0812 \log_{10}$ FLOPs，2024 年 7 月至 2025 年 3 月转为 -0.0429 。这表明 2024 年中跃升后进入平台/回落阶段，负的短窗口斜率不等于长期算力必然下降，故预测主情景将未来算力增速保守截为 0。reported compute 与加入 6ND 后的前沿走势接近，结论不依赖估算值。




图 7.4 训练算力演进与 Q3–C6 共同支持边界。(a) 报告训练算力的滚动前沿与敏感性曲线。(b) Q3 最优损失曲线、C6 桥接范围及域外层级

7.4.2 基于最优损失机制锚定的规模能力反事实

问题三主情景固定为 context 4096、指数质量成本、ratio 桥接与 $\kappa = 1$ ，在 10^{19} , 10^{22} , 10^{24} FLOPs 三档预算下得到最优平均 Loss 2.4500、1.6932、1.4803。本文仅在 $\log C$ – $\log L$ 空间对三锚点分段连接，形成继承前三问机制的 $L^*(C)$ ，而不使用历史能力数据重新拟合“规模趋势”。由此定义规模能力函数

$$B(C) = H[L^*(C)], \quad \Delta F_t = \Delta B(C_t) + T_t. \quad (7.4)$$

其中 $B(C)$ 回答“在前三问配置机制与桥接关系保持不变时，仅改变算力预算应获得多少能力”。这一反事实直接连接问题三，而 T_t 只承接剩余变化，从而避免把时间回归系数直接命名为技术进步。

图 7.4b 将 $L^*(C)$ 与 C6 Loss 范围叠加。Level A 为较强机制支持区，Level B 依赖响应形状延伸， $C > 10^{24}$ FLOPs 的 Level C 超出 Q3 预算。观测窗口起点和终点的算力分别为 1.729×10^{24} 与 3.399×10^{24} FLOPs，均位于 Level C，对应 L^* 为 1.457 和 1.428，又低于 C6 最小 Loss 1.65。因此，历史分解同时越过 Q3 和 C6 边界，规模贡献在现有数据下不可点识别。

7.4.3 共同支持边界下的贡献部分识别与稳健性检验

边界之外若直接延长末端斜率，相当于将未经观测的局部响应视为确定关系，完全饱和和假设则对应规模贡献的保守下界。为涵盖两种具有明确含义的边界情形，令尾部延续强度 $\theta \in [0, 1]$ ， $\theta = 0$ 表示到达 C6 边界后饱和， $\theta = 1$ 表示完整延续末段斜率。对低于观测下界 $L_{\min}$ 的 Loss 定义

$$H_\theta(L) = H(L_{\min}) + \theta\{H(L) - H(L_{\min})\}, \quad L < L_{\min}, \quad \theta \in [0, 1]. \quad (7.5)$$

该构造不声称 θ 具有可估计概率，而是用两个可解释边界形成部分识别集合。将观测增长 8.307 分代入式 (7.1)，得到

$$0 \leq \Delta F_{\text{scale}} \leq 0.708, \quad 7.599 \leq \Delta F_{\text{tech}} \leq 8.307,$$

即固定样本下规模份额为 0%–8.52%，非规模技术综合残差为 91.48%–100%。这是一组由结构边界产生的识别集合，不是置信区间， $\theta = 0$ 对应的“技术项 100%”只是下端边界，不能作为唯一分解结论。




图 7.5 能力增长的动态贡献分解与终点部分识别集合。(a) 观测增长、规模解释区间与非规模残差的逐月演化。(b) 期末规模贡献与非规模贡献的识别集合

图 7.5a 进一步给出逐月识别路径。深色曲线为观测能力相对起点的净变化，橙色带表示规模机制可解释区间 $[0, \Delta B_t^{(1)}]$ ，青色带表示由此反推的非规模综合项 $[\Delta F_t - \Delta B_t^{(1)}, \Delta F_t]$ 。2024 年 7 月的短暂负值来自滚动窗口样本更替，此后观测能力持续上升。规模上界随算力前沿波动，最高约 1.576 分，期末收敛至 0.708 分，非规模综合项则随观测增长逐步累积，并在绝大多数月份承担主要变化。图 7.5b 报告期末识别集合，从动态路径与终点结构两个层面呈现同一分解结果。

为检验识别集合上端点对样本构成的敏感性，进一步分层重采样能力窗口、算力窗口和 C6 两层样本，并切换 Q3 三种成本形式，共实施 1000 次 Bootstrap。表 7.4 区分固定样本识别集合与上端点的重采样稳定性，后者不构成贡献率的置信区间。970 次重采样产生有限份额，30 次因能力净增长非正而比值不定义，24 个有限上界超过 100%，均予以保留。有限上界中位数为 12.73%，97.5% 分位为 85.34%，上界低于 10%、25%、50% 的比例分别为 42.5%、70.4%、88.4%。这表明“规模上界低于一半”在多数重采样中成立，而“规模上界低于 10%”的稳定性相对有限。

表 7.4 历史贡献识别集合及其上端点稳定性

证据层次	数值结果	统计含义
观测能力净增长	8.307 分	不依赖分解假设的历史事实
固定样本规模贡献	0–0.708 分，0–8.52%	共同支持边界下的部分识别
固定样本非规模贡献	7.599–8.307 分，91.48%–100%	与规模贡献互补的残差集合
Bootstrap 上端点中位数	12.73%	识别上界的重采样中心
Bootstrap 上端点高分位	97.5% 分位为 85.34%	极端样本构成下的尾部敏感性
阈值稳定性	42.5% / 70.4% / 88.4%	上端点低于 10%/25%/50% 的比例
有效性审计	970 有限，30 未定义，24 超过 100%	保留不利及极端结果

说明，Bootstrap 考察识别集合上端点的稳定性，不应解释为规模贡献率的置信区间。

作为独立方向核验，C1–C4 有 128 条可靠实体匹配，其中 49 条同时具备 `compute` 与能力得分， $\log_{10}\text{compute}$ 与能力的 Spearman 相关为 0.578， $p = 1.35 \times 10^{-5}$ 。该结果支持规模作用方向为正，但不能消除发布时点、架构和数据质量的混杂，故不用于估计贡献率。由此获得了支持边界约束下的历史部分识别路径，下一节沿用同一状态方程，将算力路径与非规模状态共同推进至未来。

7.5 算力放缓下的能力前沿预测

历史分解确定了规模项与非规模状态项的接口，预测阶段不再引入独立的时间序列结构，而是沿用同一状态方程推进两条路径。本节先给出算力平台与技术漂移的情景设定，再报告条件模拟、不确定性来源及滚动起点回测。

7.5.1 算力平台与技术漂移的双状态建模

历史残差由 $T_t = F_t - F_{t_0} - [B(C_t) - B(C_{t_0})]$ 锚定。对其采用带漂移随机游走 $T_{t+1} = T_t + b + \eta_t$ ，其中 b 用 Theil–Sen 稳健斜率估计，得到每月 1.191 分，创新标准差为 2.663 分。该漂移描述短期非规模综合项的延续速度，不解释为某项技术的因果效应。算力主情景令未来 $\log_{10} C$ 增速为 0，无放缓反事实则延续早期每月 0.0812 的增速。

将两种状态代回统一方程， h 个月后的前沿为

$$F_{t+h} = F_t + \{B(C_{t+h}) - B(C_t)\} + bh + \sum_{j=1}^h \eta_{t+j}. \quad (7.6)$$

式 (7.6) 不是独立的时间序列模型，第一项承接现实能力，第二项仍由问题三机制和桥接决定，后两项延续式 (7.1) 中的同一非规模状态。因而历史解释、反事实和预测不会因更换模型而失去可比性。

7.5.2 基于统一状态方程的能力前沿情景预测

表 7.5 给出算力路径与技术漂移的 2×2 有限情景。主情景“算力平台 + 当前漂移”的 12 个月点预测为 53.358。保持技术漂移不变、将算力改为无放缓，只提高 1.127 分，保持算力平台、将技术漂移减半，则降低 7.148 分。由此，当前支持边界下的中期预测主要受非规模技术路径假设影响，而不是算力路径的细微差别。

表 7.5 12 个月能力前沿的算力–技术情景矩阵

算力路径	非规模技术路径	预测前沿	相对主情景
平台（主情景）	当前 Theil–Sen 漂移	53.358	0
平台	半漂移	46.210	–7.148
延续早期增速	当前 Theil–Sen 漂移	54.484	+1.127
延续早期增速	半漂移	47.336	–6.021

说明，情景矩阵用于结构反事实，不赋予四种路径主观发生概率。

条件模拟共 2000 次，逐次传播七类不确定性，终点能力窗口、模型族依赖、终点算力窗口、Q3 成本形式、High/Medium 桥接样本、支持边界后斜率，以及技术漂移和随机游走创新。图 7.6 以 50%、80%、95% 三层色带连接起点与 12/24 月模拟端点。12 个月模拟中位数为 51.203，95% 条件区间为 [24.220, 78.336]，该区间刻画给定情景与重采样规则下的不确定性传播，不属于频率学置信区间。

24 个月点预测为 67.654，中位数 66.296，95% 区间为 [16.336, 100]，上端触及量表边界。该结果表明现有证据在这一期限已不足以约束分布上尾，并不意味着能力必然达到量表上限。因此，12 个月作为主预测期限，13–24 个月仅作为压力测试，并在图中以灰色背景降低其证据等级。




图 7.6 算力平台情景下开放权重模型能力前沿的条件预测

7.5.3 基于单因素方差缩减的预测不确定性归因

条件区间的宽度不仅取决于随机游走创新，还受到能力样本、模型族结构和跨问题机制接口的共同影响。为识别主要来源，本文采用单因素方差缩减实验，在保持其余来源随机的条件下，将第 j 类不确定性固定为主设定值，并在同一模拟抽样批次下重新估计 12 个月预测。定义

$$R_j = 1 - \frac{\text{Var}(F_{12} | U_j = \bar{U}_j)}{\text{Var}(F_{12})}. \quad (7.7)$$

R_j 衡量固定单一来源后总方差的相对缩减。由于各来源存在非线性交互且预测值受 0–100 边界截断，该指标不具可加性，也不解释为 Sobol 指数。

完整模拟的 12 个月预测方差为 187.300，对应标准差 13.686。图 7.7 显示，固定技术漂移与创新后方差缩减 93.79%，显著高于模型族依赖的 3.71% 和能力窗口抽样的 1.72%，支持域外斜率、算力前沿、Q3 成本形式及桥接样本的单因素影响均接近 0。Q3 成本形式和桥接样本出现 -0.00% 与 -0.01% 的微小负值，源于非线性交互、量表截断及有限模拟误差，不表示其产生“负不确定性”。因此，预测区间的主要宽度来自非规模技术状态的未来延续，而非对算力路径的局部扰动，该发现也与情景矩阵中技术漂移变化造成更大预测位移相互印证。

7.5.4 预测模型的滚动起点回测与基线检验

采用 rolling-origin 方式，在每个历史起点只使用此前信息预测未来 1、2、3 个月，共得到每种方法 12 个预测。对照包括最后值保持和直接对 F_t 作 Theil–Sen 外推。图 7.8a 显示统一模型 95% 条件区间覆盖率为 91.7%，各期限覆盖率为 80%、100%、100%，平均宽度随期限由 10.237 增至 16.438，符合随机游走不确定性随时间累积的方向。

图 7.8b 与表 7.6 表明，最后值保持在三个期限均取得最小 MAE，统一状态模型的短期点预测精度未优于简单基线。直接 Theil–Sen 与统一模型在本回测窗口内完全重合，原因在于各训练折的算力机制项在域外饱和边界下为 0，在无放缓算力反事实中，两者不再等价。由于三种方法共享同一残差尺度，其区间覆盖率与平均宽度相同，不能据此判断统一状态模型具有更优的概率校准。

点预测精度与结构反事实效用属于不同评价维度。对于一至三个月的短期点预测，最后值保持具有更低误差，对于算力增速继续放缓如何影响能力前沿这一结构性问题，统一状态模型能够分离算力路径与非规模技术路径，因而具有简单预测基线不具备的反事实解释功能。




图 7.7 12 个月能力预测不确定性的单因素方差缩减




图 7.8 能力前沿预测的滚动起点回测与简单基线比较。(a) 统一状态模型的逐案例区间预测。(b) 三类方法在不同预测期限下的绝对误差

表 7.6 统一状态模型与简单基线的滚动起点回测

方法或区间指标	1 个月 ($n = 5$)	2 个月 ($n = 4$)	3 个月 ($n = 3$)	总体 ($n = 12$)
统一状态模型 MAE	2.934	2.767	3.493	3.018
最后值保持 MAE	1.952	2.678	2.923	2.437
直接 Theil-Sen MAE	2.934	2.767	3.493	3.018
共同 95% 覆盖率	80.0%	100.0%	100.0%	91.7%
共同平均区间宽度	10.237	14.212	16.438	13.112

说明，三种方法共用历史残差尺度，故区间指标相同，加粗值表示同期限最小 MAE。

7.6 本问结论

问题四得到四项主要结论。第一，开放权重 chat/finetuned 模型的能力前沿提高 8.307 分，指标信度、多口径和模型族平衡检验均支持总体上升方向，但 GPQA 并未同步改善。第二，来源校准单调桥接显式处理了跨来源水平偏差，绝对映射误差仍作为不确定性进入后续分析。第三，现实算力与映射 Loss 均超出共同支持域，规模贡献仅能部分识别，固定样本识别集合为 0%–8.52%，不支持唯一的点分解比例。第四，算力平台情景下的 12 个月点预测为 53.358，区间宽度主要由非规模技术状态的延续决定，且短期点预测精度未优于保持基线。

上述结论由同一状态方程贯通。综合能力前沿 F_t 确立现实观测尺度，桥接函数 H 将问题三的最优损失 $L^*(C)$ 转化为规模能力项 $B(C)$ ，共同支持边界进一步限定历史贡献的可识别范围。在此基础上，历史分解得到的非规模状态与未来算力路径共同进入前沿推演。由此，能力度量、机制映射、历史归因和情景预测形成变量逐层传递、识别边界一致的分析链条。

八、 结论、局限与推广

8.1 主要结论

问题一将异质质量信号统一为可比较的样本与领域质量分，并在配比单纯形上刻画逐目标损失响应。质量分与人工复核结果的 Spearman 相关为 0.666，配比预测模型在真实留出配方上的平均 R^2 为 0.765，表明质量评价与来源组成均包含可利用的信息。但配比排序的一致性随模型规模增大而减弱，不能将小模型的最优配方直接推广到大模型。

问题二以归一化经典律锚定规模效应，再辨识质量加权的组成响应。广义律在三个已观测规模上的留出相对 RMSE 为 5.54%，中心化配比效应的 R^2 为 0.9006，说明组成信息能够解释同等规模下经典律未刻画的损失差异。在参考工作点，质量由 0.6 提高至 0.7 对应的等损失 Token 节省中位数为 13.97 亿，叠加可行的一个百分点配比调整后为 14.06 亿。这是给定质量标定与耦合形式的模型推算，不是普适的 Token 兑换率。

问题三在统一 FLOPs 预算下联合配置参数量、训练量、治理质量和领域配比。相对同预算的规模基线，165 个情景的平均损失改善为 4.16%–5.81%，但其中 162 个情景至少有一个评估目标退步。由此，平均最优不等于逐领域最优，实际配置还须明确任务权重与最低性能要求。

问题四进一步将最优损失连接到综合能力尺度。观测期开放权重模型的能力前沿提高 8.307 分，而固定桥接样本下规模贡献份额只能部分识别为 0%–8.52%。算力平台情景的 12 个月点预测为 53.358 分，短期回测的点预测精度并未优于最后值保持。该框架的作用在于比较算力路径与非规模技术路径的条件影响，而非给出唯一的历史归因比例或保证更准确的短期预测。

8.2 局限与适用边界

质量分是由可观测信号构造的代理变量，17 个训练来源仅对应 6 个不同的分级质量值，且现有配比实验没有独立改变同来源的质量。每个配方缺少重复训练，规模实验也只有三个不同的 (N, D) 锚点。因此，同规模损失差异不能全部归因于配比，质量与配比的乘性交互动尚未获得联合实验的直接辨识。较大模型上的质量扩展结果还出现与局部实验相反的损失趋势及下界截断，不能用来验证质量收益的远距离外推。本文的等损失替代应限于已观测配比支撑域和质量标定范围附近，超出范围时仅作为情景计算。

联合配置采用 FLOPs 成本代理和有限配方凸包，未覆盖通信、存储、部署以及实际数据治理的全部代价。其稳健性也只相对于本文列出的成本、桥接与收益情景成立。能力分析受开放权重模型样本、评测口径和 Loss–Benchmark 桥接范围限制，现实前沿与机制映

射存在共同支持域不匹配。由此得到的规模贡献是固定样本与结构边界下的识别集合，非规模项是多种未观测变化的综合残差，不能解释为某项技术的因果贡献。未来能力区间同样以给定状态演化和不确定性传播规则为条件。

8.3 推广方向

要进一步辨识质量、配比与规模的联合作用，应在多个独立的 N, D 水平上交叉设置质量等级与配方，并对相同设置重复训练。这类实验既可分离训练随机性与配比效应，也可检验质量-组成耦合形式及等损失边界是否随规模改变。在资源配置层面，可将真实治理开销、硬件效率与逐领域性能下限纳入预算约束，使优化结果从平均损失最小化转向满足应用需求的多目标配置。能力映射则需要更多具有一致训练记录和可比评测的模型，并随新观测更新桥接支撑域与滚动回测。这样，本文的分层方法可以从当前数据下的条件决策工具，逐步推广为可持续校准的算力与语料配置框架。

参考文献

- [1] 卢经纬, 郭超, 戴星原, 等, 问答 ChatGPT 之后: 超大预训练模型的机遇和挑战, 自动化学报, 49(4):705-717, 2023.
- [2] 彭泽顺, 韩智博, 张岩峰, 等, 大语言模型预训练系统关键技术综述, 软件学报, 37(1): 200-229, 2026.
- [3] 刘泽垣, 王鹏江, 宋晓斌, 等, 大语言模型的幻觉问题研究综述, 软件学报, 36(3):1152-1185, 2025.
- [4] Xie S M, Pham H, Dong X, et al., DoReMi: Optimizing Data Mixtures Speeds Up Language Model Pretraining, Advances in Neural Information Processing Systems: volume 36, 69798-69818, 2023.
- [5] Muennighoff N, Rush A, Barak B, et al., Scaling Data-Constrained Language Models, Advances in Neural Information Processing Systems: volume 36, 50358-50376, 2023.
- [6] Schaeffer R, Miranda B, Koyejo S, Are Emergent Abilities of Large Language Models a Mirage?, Advances in Neural Information Processing Systems: volume 36, 55565-55581, 2023.
- [7] Zheng L, Chiang W L, Sheng Y, et al., Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena, Advances in Neural Information Processing Systems: volume 36, 46595-46623, 2023.
- [8] Li J, Fang A, Smyrnis G, et al., DataComp-LM: In Search of the Next Generation of Training Sets for Language Models, Advances in Neural Information Processing Systems: volume 37, 14200-14282, 2024.
- [9] Penedo G, Kydliček H, Allal L B, et al., The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale, Advances in Neural Information Processing Systems: volume 37, 30811-30849, 2024.
- [10] Porian T, Wortsman M, Jitsev J, et al., Resolving Discrepancies in Compute-Optimal Scaling of Language Models, Advances in Neural Information Processing Systems: volume 37, 100535-100570, 2024.
- [11] Ruan Y, Maddison C J, Hashimoto T, Observational Scaling Laws and the Predictability of Language Model Performance, Advances in Neural Information Processing Systems: volume 37, 15841-15892, 2024.
- [12] Chiang W L, Zheng L, Sheng Y, et al., Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference, Proceedings of the 41st International Conference on Machine Learning: volume 235, 8359-8388, 2024.
- [13] Liu Q, Zheng X, Muennighoff N, et al., RegMix: Data Mixture as Regression for Language Model Pre-training, International Conference on Learning Representations, 38305-38339, 2025.
- [14] Ye J, Liu P, Sun T, et al., Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Modeling Performance, International Conference on Learning Representations, 82263-82287, 2025.
- [15] White C, Dooley S, Roberts M, et al., LiveBench: A Challenging, Contamination-Limited LLM Benchmark, International Conference on Learning Representations, 91595-91631, 2025.

附录 A 核心程序代码

1.1 问题一核心代码

1.2 问题二核心代码

```
# 问题二核心算法代码
# 完整运行入口: q2/classic_law.py, q2/classic_law_early_stopping.py,
#               q2/generalized_law.py, q2/classic_law_analysis.py。
# 本文件保留“拟合—选模—辨识”数学核心, 省略 CSV 读取、绘图和报告输出。
# N、D 均按十亿参数、十亿 Token 计; 不同来源的原始 Loss 不可直接混合。

import numpy as np
from scipy.optimize import nnls
from scipy.stats import spearmanr
from sklearn.linear_model import Ridge
from sklearn.preprocessing import StandardScaler

# 一、可分离非线性最小二乘
#  $L = E + A \cdot N^{(-\alpha)} + B \cdot D^{(-\beta)}$ 。
# 给定两个指数后, E、A、B 构成线性最小二乘; 网格只搜索  $\alpha$ 、 $\beta$ 。
def classic_predict(theta, n, d):
    e, a, alpha, b, beta = theta
    return e + a * n**(-alpha) + b * d**(-beta)

def profile_classic(n, d, y, alpha, beta):
    design = np.column_stack((np.ones_like(y), n**(-alpha), d**(-beta)))
    e, a, b = np.linalg.lstsq(design, y, rcond=None)[0]
    if e < 0 or e >= np.min(y) or a <= 0 or b <= 0:
        return None # 不可约损失和规模项须满足物理方向约束
    theta = np.array([e, a, alpha, b, beta], dtype=float)
    sse = float(np.sum((y - classic_predict(theta, n, d))**2))
    return theta, sse

def fit_classic(n, d, y, lower=0.01, upper=1.50, grid_size=31, tol=1e-7):
    # 粗搜: 每个指数网格点重新求线性最小二乘。
    candidates = [
        profile_classic(n, d, y, float(alpha), float(beta))
        for alpha in np.linspace(lower, upper, grid_size)
        for beta in np.linspace(lower, upper, grid_size)
    ]
    feasible = [item for item in candidates if item is not None]
    if not feasible:
        raise ValueError(" 指数范围内无可行解")
    best = min(feasible, key=lambda item: item[1])

    # 精搜: 八邻域停滞时将步长减半; 模型形式始终不变。
    step = (upper - lower) / (grid_size - 1)
    while step > tol:
        center = best[0]
        improved = False
        for da in (-step, 0.0, step):
            for db in (-step, 0.0, step):
                if da == db == 0:
                    continue
                alpha, beta = center[2] + da, center[4] + db
                if not (lower <= alpha <= upper and lower <= beta <= upper):
                    continue
                item = profile_classic(n, d, y, alpha, beta)
                if item is not None and item[1] < best[1] - 1e-18:
                    best, improved = item, True
        if not improved:
            step /= 2
    return best[0]

# 二、自适应权重与结构早停
# 结构路径:  $\alpha = \beta = s$ ;  $\beta = s \cdot$  释放  $\alpha$ ;  $\alpha = s \cdot$  释放  $\beta$ ;
# 最后  $\alpha$ 、 $\beta$  均自由。不同层只改变指数约束, 不改标准律。
def fit_one_exponent(n, d, y, mode, shared=None,
                    lower=0.01, upper=1.50, grid_size=31, tol=1e-7):
```

```

def evaluate(value):
    if mode == "shared":
        return profile_classic(n, d, y, value, value)
    if mode == "release_alpha":
        return profile_classic(n, d, y, value, shared)
    if mode == "release_beta":
        return profile_classic(n, d, y, shared, value)
    raise ValueError(mode)

feasible = [item for x in np.linspace(lower, upper, grid_size)
             if (item := evaluate(float(x))) is not None]
if not feasible:
    raise ValueError(" 该约束阶段无可行解")
best = min(feasible, key=lambda item: item[1])
step = (upper - lower) / (grid_size - 1)
while step > tol:
    center = best[0][4 if mode == "release_beta" else 2]
    improved = False
    for value in (center - step, center + step):
        if lower <= value <= upper:
            item = evaluate(value)
            if item is not None and item[1] < best[1] - 1e-18:
                best, improved = item, True
    if not improved:
        step /= 2
return best[0]

def cross_fitted_score(actual, predicted, cluster, mape_cap=0.20):
    # 每次用其余簇拟合 L_source=a+b*L_reference, 逆映射当前留出簇。
    # 高度相关的训练检查点共享簇号, 不能当作独立验证样本。
    cluster = np.asarray(cluster)
    normalized = np.empty_like(actual, dtype=float)
    groups = np.unique(cluster)
    for group in groups:
        heldout = cluster == group
        training = ~heldout if len(groups) > 1 else np.ones(len(actual), bool)
        x, y = predicted[training], actual[training]
        a, b = np.linalg.lstsq(
            np.column_stack((np.ones_like(x), x)), y, rcond=None
        )[0]
        if b <= 1e-8 or not np.isfinite(b):
            b = max(np.std(y) / max(np.std(x), 1e-12), 1e-8)
            a = np.mean(y) - b * np.mean(x)
        normalized[heldout] = (actual[heldout] - a) / b
    error = predicted - normalized
    ape = np.median(np.abs(error) / np.maximum(np.abs(normalized), 1e-12))
    nrmse = np.sqrt(np.mean(error**2)) / max(np.std(normalized), 1e-12)
    rho = spearmanr(normalized, predicted).statistic
    rho = float(rho) if np.isfinite(rho) else -1.0
    return float(min(ape, mape_cap) + 0.25*nrmse + 0.10*(1-rho))

def bounded_weights(raw, minimum=0.05, maximum=0.50):
    # 对超出上下界的来源先锁定, 再按剩余原始权重分配剩余质量。
    if len(raw)*minimum > 1 or len(raw)*maximum < 1:
        raise ValueError(" 权重上下界与总和为 1 的条件不相容")
    assigned, active, remaining = {}, set(raw), 1.0
    while active:
        total = sum(max(raw[name], 1e-15) for name in active)
        proposal = {name: remaining*max(raw[name], 1e-15)/total
                    for name in active}
        low = [name for name in active if proposal[name] < minimum]
        high = [name for name in active if proposal[name] > maximum]
        if not low and not high:
            assigned.update(proposal)
            break
        for name in low:
            assigned[name], remaining = minimum, remaining-minimum
            active.remove(name)
        for name in high:
            if name in active:
                assigned[name], remaining = maximum, remaining-maximum
                active.remove(name)
    return {name: assigned[name]/sum(assigned.values()) for name in raw}

```

```

def adaptive_weights(reference_score, bootstrap_std, priors,
                    difficulty_power=0.50):
    # 参考分数由完整经典律事先计算; bootstrap_std 来自分簇重采样。
    # 先验可靠性 × 验证难度 × 重采样稳定性, 确定后在结构路径中冻结。
    # 默认先验: B2=0.55、B3=0.20、B4=B5=1.00。
    raw = {}
    for name, score in reference_score.items():
        stability = 1 / (1 + bootstrap_std[name] / max(score, 0.02))
        raw[name] = (priors[name] * max(score, 0.01)**difficulty_power
                    * stability)
    return bounded_weights(raw)

def choose_structure(b1, validations, weights, full_theta,
                    min_r2=0.995, penalty_rate=0.001,
                    min_delta=0.002, patience=1):
    # b1=(n,d,y): validations[name]=(n,d,loss,cluster)。
    # 所有指数网格点只用 B1 最小二乘拟合, 外部集只负责结构选择。
    n, d, y = b1
    shared = fit_one_exponent(n, d, y, "shared")
    s = shared[2]
    def evaluate(name, theta, n_parameters):
        fitted = classic_predict(theta, n, d)
        r2 = 1 - np.sum((y-fitted)**2) / np.sum((y-np.mean(y))**2)
        if r2 < min_r2:
            return None
        score = 0.0
        for source, (nv, dv, loss, cluster) in validations.items():
            predicted = classic_predict(theta, nv, dv)
            score += weights[source] * cross_fitted_score(
                loss, predicted, cluster)
        return (score + penalty_rate*max(n_parameters-3, 0), name, theta)

    best, bad_layers = None, 0
    history = []
    for stage in range(3):
        if stage == 0:
            layer = [("shared", shared, 4)]
        elif stage == 1:
            layer = [
                ("release_alpha", fit_one_exponent(n, d, y, "release_alpha", s), 5),
                ("release_beta", fit_one_exponent(n, d, y, "release_beta", s), 5),
            ]
        else:
            layer = [("full", full_theta, 5)]
            # 同层候选全部评价完毕后才决定是否释放下一层自由度。
            candidates = [evaluate(*item) for item in layer]
            candidates = [item for item in candidates if item is not None]
            history.extend(candidates)
            layer_best = min(candidates, default=None, key=lambda item: item[0])
            if layer_best is not None and (
                best is None or layer_best[0] < best[0] - min_delta
            ):
                best, bad_layers = layer_best, 0
            else:
                bad_layers += 1
            if bad_layers >= patience:
                break
    return best, history # 返回历史最优, 而非最后搜索到的结构

# 三、标准律锚定的广义律分阶段辨识
#  $L_k = E_k + A_k N^{(-\alpha)} + B_k D^{(-\beta)}$ 
#  $+ (N/N_0)^{(-\eta_k)} * (D/D_0)^{(-\zeta_k)} * \Phi_k(p, Q)$ 。
# alpha、beta 固定为经典律结果;  $Q_i$  是来源固定属性, 不能从配比实验
# 单独识别“提高同一来源质量”的因果效应。
def composition_features(p, q, epsilon=1e-3):
    log_p = np.log(p + epsilon)
    clr = log_p - np.mean(log_p, axis=1, keepdims=True)
    return np.column_stack((p*q[None, :], clr))

def identify_generalized(reference, tuning, later, q, alpha, beta,

```

```

ridges=(0.01, 0.1, 1.0, 10.0, 100.0)):
# reference、tuning=(p,y,n,d), later 为另两个观测规模的同型元组;
# y 的列对应不同评估目标。最后的留出折不为此函数输入。
p0, y0, n0, d0 = reference
pt, yt, _, _ = tuning

# 阶段一: 仅在参考规模学习配比响应的形状, 调参折只选岭强度。
scaler = StandardScaler().fit(composition_features(p0, q))
x0 = scaler.transform(composition_features(p0, q))
xt = scaler.transform(composition_features(pt, q))
options = []
for strength in ridges:
    ridge = Ridge(alpha=strength).fit(x0, y0)
    score = np.sqrt(np.mean((ridge.predict(xt)/yt-1)**2))
    options.append((score, strength, ridge))
_, strength, ridge = min(options, key=lambda item: item[0])

def raw_response(p):
    return ridge.predict(scaler.transform(composition_features(p, q)))

center = np.mean(raw_response(p0), axis=0)
centered = raw_response(p0)-center
slope = np.sum(centered*(y0-np.mean(y0, axis=0)), axis=0) / np.sum(
    centered**2, axis=0)
if np.any(slope <= 0):
    raise ValueError(" 参考规模配比响应幅度必须为正")

def phi(p):
    return (raw_response(p)-center)*slope

# 阶段二: 每个规模只估计“截距 + 形状函数的幅度”, 不重拟合形状。
anchors = (reference, *later)
n = np.array([item[2] for item in anchors], dtype=float)
d = np.array([item[3] for item in anchors], dtype=float)
baseline, amplitude = [], []
for index, (p, y, _, _) in enumerate(anchors):
    f = phi(p)
    if index == 0:
        scale = np.ones(y.shape[1])
    else:
        fc = f-np.mean(f, axis=0)
        denominator = np.sum(fc**2, axis=0)
        if np.any(denominator <= 1e-12):
            raise ValueError(" 该规模的配比缺乏可辨识变化")
        scale = np.sum(fc*(y-np.mean(y, axis=0)), axis=0)/denominator
    if np.any(scale <= 0):
        raise ValueError(" 配比响应幅度必须为正")
    baseline.append(np.mean(y, axis=0)-scale*np.mean(f, axis=0))
    amplitude.append(scale)
baseline, amplitude = np.stack(baseline), np.stack(amplitude)

# 阶段三: 固定经典指数; 用三个锚点的基线非负最小二乘解 E、A、B。
design = np.column_stack((np.ones(3), n**(-alpha), d**(-beta)))
eab = np.stack([nnls(design, baseline[:, k])[0]
    for k in range(y0.shape[1])])
# 前两点 D 相同, 先由幅度比解 eta; 第三点再条件求 zeta。
eta = -np.log(amplitude[1])/np.log(n[1]/n0)
zeta = (-np.log(amplitude[2])-eta*np.log(n[2]/n0))/np.log(d[2]/d0)

def predict(p, n_value, d_value):
    base = (eab[:, 0]+eab[:, 1]*n_value**(-alpha)
        +eab[:, 2]*d_value**(-beta))
    scale = ((n_value/n0)**(-eta)*(d_value/d0)**(-zeta))
    return base[None, :]+phi(p)*scale[None, :]

return {"ridge": strength, "EAB": eab, "eta": eta, "zeta": zeta,
    "predict": predict}

# 识别边界: 仅有三个 (N,D) 观测锚点; 最大规模 N、D 同时变化。
# eta、zeta 是给定可分离幂律后的条件辨识, 不保证域外外推成立。

```

1.3 问题三核心代码

1.4 问题四核心代码