



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

中南大学

参赛队号

20250900001

队员姓名

1.

彭铸

2.

郑徐瀚宇

3.

阳挺

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： 全国研究生数学建模竞赛论文标题

摘 要：

目录

一、 问题重述	4
1.1 问题背景	4
1.2 问题重述	4
1.3 总体技术路线	4
二、 基本假设与符号说明	4
2.1 基本假设	4
2.2 符号说明	4
三、 数据说明与预处理	4
3.1 数据来源及可信度分层	4
3.2 数据口径统一	4
3.3 训练、检验及外推数据划分	4
四、 问题一：数据质量评价、冲突消解及领域配比	4
4.1 数据质量评价	5
4.1.1 质量信号统一表征与方向审计	5
4.1.2 域均衡层次质量评价	5
4.1.3 质量评价结果与一致性检验	7
4.2 质量冲突消解	8
4.2.1 质量冲突的域感知识别	8
4.2.2 冲突证据的可靠性重加权	9
4.2.3 冲突消解效果及稳健性	9
4.3 领域配比-Loss 关系	10
4.3.1 配比数据标准化及质量先验检验	10
4.3.2 配比-Loss 响应的预测与解释模型	10
4.3.3 领域份额替换及互补结构	11
4.3.4 配比规律的跨尺度迁移边界	11
五、 问题二：广义标度律及质量-规模替代	12
5.1 问题二的分析	12
5.2 问题二的模型建立	13
5.2.1 经典标度律的参数辨识模型建立与验证	13
5.2.2 经典标度律的外推与广义标度律的设计	16
5.2.3 广义标度律的估计模型建立	17
5.3 问题二的结果	17
5.3.1 广义标度律各因素边际效用与弹性分析	17
5.3.2 广义标度律下领域数据间关系分析	17
5.3.3 广义标度律指导下的大模型训练方案选择与验证	17
六、 问题三：算力约束下的联合资源配置	17
七、 问题四：技术演进分解及能力前沿预测	17

八、 结论、局限与推广	17
参考文献	18
附录 A 完整数据审计表	20
附录 B 关键参数与敏感性结果	20
附录 C 程序代码	20

一、 问题重述

- 1.1 问题背景
- 1.2 问题重述
- 1.3 总体技术路线

二、 基本假设与符号说明

- 2.1 基本假设
 - 1.
- 2.2 符号说明

表 2.1 主要符号说明

符号	含义
x_{ij}	样本 i 在第 j 项质量信号上的原始取值
s_{ij}	指标方向统一后的质量表示, $s_{ij} \in [0, 1]$
F_j^{bal}	第 j 项信号的域均衡经验分布
$\mathcal{P}, \mathcal{N}, \mathcal{M}$	正向、负向与中心适宜指标集合
G_k, a_{jk}	第 k 个信息簇及其簇内指标权重
K	信息簇个数, 取 $K = 9$
η_j	第 j 项信号的领域间方差占比
$Q_i^{(0)}$	样本 i 的初始质量分数
r_{ij}, I_{ij}	标准化异常度与冲突指示变量
C_i	样本 i 的冲突度
R_{ij}, U_i	证据可靠度与信息簇平均可靠度
Q_i^*	冲突校正后的质量分数
p_i	第 i 个训练域在配方中的份额
$z_{mk}, \phi(\mathbf{p})$	标准化验证损失与总体配比表现
$S_{i \leftarrow j}$	份额由领域 j 转向领域 i 的边际替换效应
C_{ij}^{mix}	领域 i 与 j 的互补指数
ρ_s	Spearman 等级相关系数

三、 数据说明与预处理

- 3.1 数据来源及可信度分层
- 3.2 数据口径统一
- 3.3 训练、检验及外推数据划分

四、 问题一：数据质量评价、冲突消解及领域配比

附件 A 包含两类相互衔接的数据, A1–A3 给出语料的多维质量信号, A4–A15 给出不同领域配方及其验证损失。本问依次解决三个层次的问题。首先在七域样本不均衡条件下构造初始质量 $Q^{(0)}$; 随后依据各领域内部的正常指标关系识别异常评价证据, 并校正其权

重得到 Q^* ；最后在单纯形约束下建立 17 域训练配比对 13 域验证 Loss 的联合响应。 Q^* 经 A16 映射为 $Q^{(17)}$ ，并与总体配比效应 $\phi(\mathbf{p})$ 一同作为问题二的数据侧输入。

4.1 数据质量评价

A1 含 51,230 条样本、7 个领域和 22 项质量信号；A2、A3 分别是 arxiv 和 github 的扩展抽样集合，各含 17,523 条和 203,752 条样本，并完整包含 A1 对应领域的 1,419 条与 10,000 条样本。A2、A3 采用与 A1 相同的字段口径和采集来源，因此可用于检验 A1 的抽样代表性。综合评价面临三项结构性困难，即七域样本量差异显著、多项评价信号存在重复信息，以及部分文本结构指标具有合理区间而非简单单调关系。针对这三点，依次进行质量信号统一表征、域均衡标度、信息簇合成和人工一致性检验。

4.1.1 质量信号统一表征与方向审计

22 项信号包含 8 个列表字段和 14 个标量字段。列表字段按原始含义先行标量化，二分类 logits 经 softmax 转为目标类别概率，六级有序 logits 取期望等级并按 5 归一化，QuRating 的四个异质量纲分量先分别作百分位变换再取均值。原始数据完整性良好，仅 modernbert_reasoning 与 modernbert_professionalism 分别出现 13 条和 5 条无效 logits，以所属领域的中位数填补，占总样本比例不足 0.04%。

标量化只解决量纲不一致，并不解决方向不一致。为统一综合分数的含义，本文对 22 项信号逐一登记方向，分为正向、负向和中心适宜三类，最终仅 WordLength、Sentences、WordCount、Entropy 与 Uppercase 设为中心适宜，其余按单调方向处理；方向设定的依据与消融见 4.1.3 节。表 4.2 汇总 22 项信号的短名、含义、字段形态、标量化方式以及统一表示 s_{ij} 的分布特征，信息簇归属与方向判定见图 4.1。

表 4.2 22 项质量信号的统一表征与分布特征

信号短名	含义	字段形态	标量化方式	$\bar{s}$	σ_s	η_j
NoAlpha	非字母词比例	标量	直接使用	0.516	0.310	0.49
Uppercase	大写字母比例	标量	直接使用	0.835	0.280	0.47
TermPunct	句末标点比例	标量	直接使用	0.498	0.298	0.60
Ad-Prob	无广告概率	列表 2	softmax 取 $P(\text{no-ad})$	0.491	0.291	0.20
MB-Reason	推理性	列表 6	期望等级 / 5	0.404	0.251	0.60
UniqueWords	词汇多样性	标量	直接使用	0.624	0.224	0.62
DSIR-Math	数学域倾向	标量	直接使用	0.626	0.223	0.64
DSIR-Books	书籍域倾向	标量	直接使用	0.625	0.225	0.63
DSIR-Wiki	维基域倾向	标量	直接使用	0.626	0.223	0.64
FineWebEdu	教育价值	列表 1	取列表唯一评分	0.447	0.279	0.24
MB-Prof	专业性	列表 6	期望等级 / 5	0.452	0.268	0.69
Fluency	语言流畅度	列表 2	softmax 取 $P(\text{fluent})$	0.477	0.293	0.30
QuRating	综合文本质量	列表 4	四分量分位均值	0.447	0.203	0.39
MB-Clean	洁净度	列表 6	期望等级 / 5	0.435	0.283	0.44
MB-Read	可读性	列表 6	期望等级 / 5	0.434	0.292	0.38
WordLength	平均词长	标量	直接使用	0.795	0.311	0.31
Numerical	数字字符比例	标量	直接使用	0.461	0.290	0.16
Sentences	句子数	标量	直接使用	0.857	0.270	0.38
WordCount	词数	标量	直接使用	0.858	0.271	0.42
Entropy	一元词熵	标量	直接使用	0.855	0.272	0.40
Top2Gram	二元重复集中度	标量	直接使用	0.420	0.282	0.27
Top3Gram	三元重复集中度	标量	直接使用	0.444	0.306	0.18

注：字段形态中“列表 m ”表示该字段为长度 m 的列表； $\bar{s}$ 与 σ_s 为统一表示 s_{ij} 在 A1 全样本上的均值与标准差； η_j 为指标 j 的领域间方差占比；中心适宜指标在中间 60% 分位区间取满分，其 $\bar{s}$ 相应偏高。表内按信息簇 C1–C9 分组排列。

4.1.2 域均衡层次质量评价

A1 中 book 仅 171 条、arxiv 为 1,419 条，而 c4、github、stackexchange、wikipedia 均接近 10^4 条。若以全样本经验分布作为统一标尺，大样本领域将获得更高权重；若分别在

域内归一化，则会抹去域间真实差异。因此，对指标 j 在领域 d 内建立经验分布 F_{jd} ，并令七个领域等权参与公共参考尺度，即

$$F_j^{\text{bal}}(x) = \frac{1}{7} \sum_{d=1}^7 F_{jd}(x). \quad (4.1)$$

在此基础上，将不同方向的指标统一为 $s_{ij} \in [0, 1]$ ，具体形式为

$$s_{ij} = \begin{cases} F_j^{\text{bal}}(x_{ij}), & j \in \mathcal{P}, \\ 1 - F_j^{\text{bal}}(x_{ij}), & j \in \mathcal{N}, \\ \min \left\{ \frac{F_j^{\text{bal}}(x_{ij})}{0.20}, \frac{1 - F_j^{\text{bal}}(x_{ij})}{0.20}, 1 \right\}, & j \in \mathcal{M}, \end{cases} \quad (4.2)$$

其中 $\mathcal{P}, \mathcal{N}, \mathcal{M}$ 分别表示正向、负向和中心适宜指标集合。中心适宜函数在中间 60% 分位区间取满分，仅对结构极端样本进行惩罚。

统一表征后，以域均衡权重计算 22 项信号的 **Spearman** 相关矩阵，并以 $1 - |\rho|$ 为距离进行层次聚类。综合轮廓系数和 120 次分层 **bootstrap** 的配对稳定度，数据驱动选择 $K = 9$ 个信息簇。对第 k 个信息簇 G_k ，以簇内绝对相关矩阵的最大特征向量形成非负权重 a_{jk} ；不同簇之间采用等权，即

$$H_{ik} = \sum_{j \in G_k} a_{jk} s_{ij}, \quad Q_i^{(0)} = \frac{1}{K} \sum_{k=1}^K H_{ik}, \quad K = 9. \quad (4.3)$$

这种层次合成先在同类信号中提取共识，再汇总不同质量语义，从而削弱重复评价对综合分数的影响。图 4.1 表明，域均衡相关矩阵呈明显的簇状结构，顶部色带给出信息簇归属，右侧给出领域间方差占比 η_j 与指标方向。多个 **DSIR** 与模型评分信号的 η_j 超过 0.60，说明其变化更多来自领域身份而非通用质量，因此这些指标只参与综合评价，不单独解释为领域质量的因果来源。




图 4.1 22 项质量信号的冗余结构与领域异质性

4.1.3 质量评价结果与一致性检验

领域级质量以域内 $Q_i^{(0)}$ 的均值表示，并在固定评价规则下采用分层 bootstrap 构造 95% 置信区间。表 4.3 给出七域点估计、分布中心和同源扩展检验，图 4.2 则展示领域排序及方向假设的主要证据。

表 4.3 七域初始质量评价及同源扩展检验

领域	n	A1 均值	95% CI	ΔQ	W_1
arxiv	1,419	0.7076	[0.7055, 0.7098]	-0.001740	0.002437
commoncrawl	9,640	0.6056	[0.6043, 0.6067]	-	-
stackexchange	10,000	0.6024	[0.6011, 0.6038]	-	-
wikipedia	10,000	0.5950	[0.5934, 0.5968]	-	-
c4	10,000	0.5548	[0.5529, 0.5566]	-	-
book	171	0.4994	[0.4875, 0.5115]	-	-
github	10,000	0.4786	[0.4771, 0.4802]	-0.000054	0.000384
总体		$Q_{\text{micro}} = 0.5707$		$Q_{\text{macro}} = 0.5776$	

注：A1 均值为初始质量 $Q^{(0)}$ 的域内均值，95% CI 由分层 bootstrap 给出； ΔQ 为 A2/A3 全量均值减 A1 对应领域均值， W_1 为 Wasserstein 距离。A2/A3 与 A1 同源，因此该结果用于检验抽样代表性。

arxiv 的平均 $Q^{(0)}$ 最高，github 最低。github 的人工审阅相关仅为 0.071，明显低于其他领域，说明代码和技术文本与现有评价信号之间存在较强的领域失配；因此该排名仅表示统一评价口径下的相对位置，不作语料本身优劣的绝对判断。A1 的微平均与宏平均接近，说明样本量不平衡未改变总体水平判断；book 样本量最小，其置信区间也最宽。冻结 A1 的标量化规则、公共 ECDF、信息簇及簇内权重后应用于 A2/A3，arxiv 和 github 的均值差分别仅为 -1.74×10^{-3} 和 -5.4×10^{-5} ，对应的 Wasserstein 距离也很小，表明 A1 对两类同源扩展集合具有较好的代表性。

方向设定与聚合方式的消融结果见表 4.4。最终“五中心”方案在保持七域排序稳定的同时，将 210 条分层人工复核与 $Q^{(0)}$ 的 Spearman 相关提高到 0.666；全部结构指标均按正向处理时，七域排序相关降至 0.429。等权与 CRITIC 与本文方法的样本排序相关分别为 0.901 和 0.920，说明主要质量结构具有较高共识；全局 PCA 的一致性明显较低，说明直接以单一主成分压缩 22 项信号会损失部分质量语义。

表 4.4 质量评价方案的消融与一致性检验

检验类型	方案	七域排序	样本排序	人工审阅
方向设定	旧八中心方案	1.000	0.880	0.616
	最终五中心方案	1.000	1.000	0.666
	中心指标缩减为四个	0.893	0.993	0.656
	全部按正向处理	0.429	0.772	0.634
聚合基线	等权	0.929	0.901	0.619
	CRITIC	0.929	0.920	0.625
	全局 PCA	0.750	0.622	0.449

注：三列均为 Spearman 相关 ρ_s ；人工复核样本按领域与质量层次分层抽取，排序相关均以最终五中心方案为基准。




图 4.2 七域质量评价结果与评价规则可信度

由此得到的 $Q^{(0)}$ 保留了样本间的质量次序和域间差异，可作为下一节冲突校正的基准分数；其数值用于统一评价口径下的相对比较。

4.2 质量冲突消解

$Q^{(0)}$ 的合成默认各项质量证据均可直接使用，但特殊文本可能使个别评价器偏离该领域的常见关系。因此，本文把“正常的多维差异”与“异常的不一致”分开处理。只有当某项观测显著偏离同域相关信号所预测的正常水平时，才记为质量冲突；随后降低该项证据在综合评价中的权重。

4.2.1 质量冲突的域感知识别

以上一节的域均衡相关结构为基础，仅保留 $|\rho| \geq 0.10$ 且在 300 次分层 bootstrap 中稳定率不低于 0.95 的指标关系，共得到 135 条稳定边。对每项指标，用其稳定邻居和领域信

息建立 Elastic Net 预测器，并按七域进行 5 折 cross-fitting，使每个样本的条件期望均由未包含该样本的训练折给出。记交叉预测残差为 $e_{ij} = s_{ij} - \hat{s}_{ij}^{(-i)}$ ，并在所属领域内按 MAD 标准化。若异常度进入对应“指标-领域”经验残差分布的上 2.5% 尾部，则置 $I_{ij} = 1$ 。样本级冲突度同时计入异常覆盖范围和异常强度，即

$$\begin{aligned} r_{ij} &= \frac{|e_{ij}|}{1.4826 \text{MAD}_{d_i}(e_{\cdot j}) + \varepsilon}, \\ p_{ij}^{\text{conf}} &= 1 - F_{j,d_i}^R(r_{ij}), \quad I_{ij} = \mathbf{1}\{p_{ij}^{\text{conf}} < 0.025\}, \\ C_i &= \sqrt{\left(\frac{1}{22} \sum_j I_{ij}\right) \left(\frac{\sum_j I_{ij} r_{ij}}{\sum_j I_{ij} + \varepsilon}\right)}. \end{aligned} \quad (4.4)$$

该定义以各指标在各领域中的正常波动为参照，因此不会把代码、公式密集文本等领域特征仅因数值差异而判为冲突。

4.2.2 冲突证据的可靠性重加权

冲突不直接从样本总分中扣除，而是作用于对应证据的可靠度。设 τ_{j,d_i} 为指标 j 在领域 d_i 的冲突阈值，定义

$$R_{ij} = \begin{cases} 1, & I_{ij} = 0, \\ \exp\{-0.5(r_{ij} - \tau_{j,d_i})_+\}, & I_{ij} = 1, \end{cases} \quad Q_i^* = \sum_{k=1}^K v_{ik}^* H_{ik}, \quad v_{ik}^* = \frac{\sum_{j \in G_k} a_{jk} R_{ij}}{\sum_{\ell=1}^K \sum_{h \in G_\ell} a_{h\ell} R_{ih}}. \quad (4.5)$$

各信息簇可靠度的均值记为 U_i 。当不存在冲突时， $v_{ik}^* = 1/K$ ，故 $Q_i^* = Q_i^{(0)}$ ；出现局部异常时，仅相应信息簇的权重发生变化。

4.2.3 冲突消解效果及稳健性

冲突校正后， Q^* 与 $Q^{(0)}$ 的全样本 Spearman 为 0.9992，说明总体质量次序基本保持不变；但修正量明显向高冲突样本集中。Top 10%、Top 5% 和 Top 1% 冲突样本的 $|Q^* - Q^{(0)}|$ 中位数分别为 0.00435、0.00655 和 0.0118，且 Top 10% 样本贡献了 64.8% 的总绝对修正量。图 4.3 中的分箱中位线进一步显示，冲突程度升高后修正幅度呈持续上升趋势。




图 4.3 冲突修正的局部性与异常来源

高严重度冲突主要集中在 Entropy、Sentences、Uppercase、WordCount 和 WordLength 等结构信号，表明异常主要来自文本结构偏离所属领域的常态。最新结果中 GitHub 的平

均冲突度最高 (0.180), Book 最低 (0.138); 这里的领域差异反映评价证据的一致性, 而不适用于比较领域质量高低。将 A1 学得的关系结构、残差尺度和阈值冻结后应用于 A2/A3, 严重冲突仍集中在同类结构信号。作为对照, 本文冲突度与“指标方差”和“最大两两差”的 Spearman 仅为 0.132 和 0.172; 当显著性阈值在 0.01–0.10、可靠性衰减系数在 0.3–1.0 内变化时, Q^* 排序与主方案的 Spearman 始终不低于 0.994。因此, 冲突校正主要影响高冲突尾部, 并未改变质量评价的主体结构。第二小问最终输出 (Q_i^*, U_i, C_i) , 分别记录修正后的质量、证据可信度和冲突程度。

4.3 领域配比–Loss 关系

A4/A5 提供 512 组 1M 训练配方及其 13 域验证 Loss; A6/A7 为 1M 同尺度真实检验, A8/A9 和 A10/A11 分别提供 60M、1B 真实检验, A12–A15 为 10B、70B 外推表。17 个训练比例满足 $p_i \geq 0$ 、 $\sum_i p_i = 1$, 而 13 个验证域的 Loss 基准不同, 因此建模时需同时处理单纯形约束、多输出响应和跨尺度迁移。

4.3.1 配比数据标准化及质量先验检验

不同验证域的 Loss 先在 A5 内按验证域进行中位数–MAD 标准化, 再定义总体配比表现, 即

$$z_{mk} = \frac{L_{mk} - \text{median}(L_{\cdot k})}{1.4826 \text{ MAD}(L_{\cdot k})}, \quad \phi(\mathbf{p}) = -\frac{1}{13} \sum_{k=1}^{13} \hat{z}_k(\mathbf{p}). \quad (4.6)$$

$\phi(\mathbf{p})$ 越大, 表示该配方在 13 个验证域上的总体表现越优。

第二小问得到的七域 Q^* 经 A16 映射到 17 个训练域。由于 $\sum_i p_i Q_i$ 是 $\mathbf{p}$ 的确定函数, 直接作为额外线性项会与配比变量共线。因此以指数倾斜 $\tilde{p}_i(\gamma) \propto p_i \exp[\gamma(Q_i - \bar{Q})]$ 检验质量先验。交叉验证的最优值为 $\gamma = 0$, 且 $\gamma > 0$ 时误差略有增加, 说明 A4/A5 无法把“领域身份”与“领域质量”的独立作用分开识别。本小问据此不引入质量先验, 质量的独立边际效应在问题二 B6–B8 的独立质量变化中进一步估计。

4.3.2 配比–Loss 响应的预测与解释模型

为显式刻画领域及领域组合的作用, 对第 k 个验证域建立二阶 Scheffé 混合响应

$$\hat{z}_k(\mathbf{p}) = \sum_{i=1}^{17} \beta_{ik} p_i + \sum_{1 \leq i < j \leq 17} \gamma_{ijk} p_i p_j, \quad k = 1, \dots, 13. \quad (4.7)$$

17 个主效应和 136 个交互项在 13 个任务上联合拟合, 以组稀疏约束筛选跨任务稳定结构, 并用 Ridge 项稳定相关系数; 一阶 Scheffé 和 ILR–Ridge 作为对照。1M 真实检验结果见表 4.5。

表 4.5 1M 真实检验集上的配比响应模型比较

模型	平均 RMSE	平均 R^2	MAE	用途
一阶 Scheffé	0.522	0.619	0.435	线性混合基准
多任务稀疏 Scheffé	0.444	0.710	0.361	机制解释
ILR–Ridge	0.420	0.765	0.337	数值预测

注: RMSE、 R^2 、MAE 均为 13 个验证任务的平均值; 总体宏观配比指标 G 在 1M 检验集上的 R^2 为 0.391。

ILR–Ridge 的点估计最优; 重复 5 折交叉验证下, 其相对多任务 Scheffé 的 R^2 差值均值为 0.038, 95% CI 为 $[-0.012, 0.081]$, 区间包含 0。因此后续数值预测采用 ILR–Ridge, 领域替换和交互机制采用多任务稀疏 Scheffé 解释, 两类模型分别承担预测和机制分析任务。

4.3.3 领域份额替换及互补结构

在单纯形约束下，“增加领域 i ”必然伴随其他领域份额减少，因此主效应系数不能直接解释为独立边际收益。在参考配比 $\mathbf{p}$ 附近，定义从领域 j 向领域 i 转移份额的边际效应和两领域的总体互补指数，即

$$S_{i \leftarrow j}(\mathbf{p}) = \frac{1}{13} \sum_{k=1}^{13} \left(\frac{\partial \hat{z}_k}{\partial p_i} - \frac{\partial \hat{z}_k}{\partial p_j} \right), \quad C_{ij}^{\text{mix}} = -\frac{1}{13} \sum_{k=1}^{13} \gamma_{ijk}. \quad (4.8)$$

$S_{i \leftarrow j} < 0$ 表示在当前配比附近将份额从 j 转移到 i 有助于降低总体 Loss； $C_{ij}^{\text{mix}} > 0$ 表示两域共同出现时的 Loss 低于线性混合预期。前者描述份额替换，后者描述非加性交互。

为控制稀疏配方造成的大系数伪影，正文只解释同时满足三项条件的关系，即两域训练覆盖充分、bootstrap 符号稳定率不低于 0.95、效应量位于训练支持范围。约 52% 的替换关系和 46% 的互补关系通过该门槛。通过门槛的关系中，DM-Math $\rightarrow$ HackerNews 的替换效应为 -2.68 ，显示稳定的 Loss 改善信号；arXiv-GitHub 则表现出稳定互补。相反，enron_emails 的平均份额仅 0.0022、最大份额 0.026、非零占比 0.31，其大幅替换效应超出充分支持范围，因此不进入机制结论。图 4.4 将替换矩阵和通过资格门槛的互补/冗余关系合并展示，灰色斜线区域表示证据不足。




图 4.4 领域配比的替换机制与互补结构

4.3.4 配比规律的跨尺度迁移边界

同尺度预测精度不能直接代表跨规模可迁移性，因此分别考察配比空间外推和模型规模迁移。在配比空间内，以 Hellinger 距离衡量测试配方到最近训练配方的距离。1M 检验集最近邻距离的中位数为 0.299，90% 分位数为 0.375，且预测误差随距离增大而整体上升，说明模型的机制解释应限制在训练配方支持区域附近。

模型规模迁移通过不同尺度下的配方排序一致性衡量。表 4.6 和图 4.5 显示，60M 和 1B 的 Spearman 相关分别为 0.810 和 0.608，均保持为正，但随规模扩大明显减弱；10B、

70B 的 Loss 为较小规模幂律外推结果，其排序相关和预测-观测斜率均转为负值。因此，现有数据支持真实 1M-1B 范围内的有限迁移，不支持将小模型上的配比规律视为尺度不变关系。

表 4.6 领域配比效应的跨尺度一致性

模型规模	数据性质	样本数	排序相关 ρ_s	两两一致率	回归斜率
60M	真实检验	256	0.810	0.805	0.912
1B	真实检验	64	0.608	0.711	0.348
10B	外推 Loss	63	-0.584	0.293	-0.339
70B	外推 Loss	63	-0.617	0.279	-0.370

注：排序相关为各尺度配方排序与 1M 预测排序的 Spearman 相关，两两一致率为配方两两比较方向一致的比例，回归斜率为预测-观测回归的斜率；10B/70B 的 Loss 来自小规模实验的幂律外推，仅用于识别尺度失效边界，不作为真实大模型训练验证。




图 4.5 配比模型的预测有效域与跨尺度迁移边界

问题一最终得到三类后续输入，即冲突修正质量 Q^* 、映射到 17 个训练域的质量描述 $Q^{(17)}$ 以及总体配比效应 $\phi(\mathbf{p})$ 。替换效应 $S_{i \leftarrow j}$ 和互补指数 C_{ij}^{mix} 用于解释领域结构， U 与 C 用于记录质量评价中的不确定性。问题二将在此基础上融合附件 B，建立含参数规模、数据量、质量和领域结构的广义标度关系。

五、 问题二：广义标度律及质量-规模替代

5.1 问题二的分析

经典标度律通常将训练 Token 视为同质资源，重点描述参数规模和数据规模对模型损失的影响。然而，随着高质量语料逐渐稀缺，不同数据在信息密度、噪声水平、知识覆盖和任务相关性方面呈现出显著差异，单纯增加参数量或训练 Token 数已不足以准确解释模型能力的增长规律。如果忽略这种数据异质性，模型不仅会高估低质量数据的边际价值，还会掩盖领域结构失衡造成的性能瓶颈，从而难以回答数据质量提升、领域配比调整与模型规模扩张之间能否相互替代这一关键问题。因此，将数据质量和领域配比纳入标度律，是

从“规模驱动”转向“规模与数据价值协同驱动”的必要拓展，也是实现有限算力下精细化资源配置的理论基础。

数据结构决定了这一拓展不能简单地用一个质量系数修正训练 Token 数。设训练数据来自 m 个领域，配比 $\mathbf{p}$ 满足 $p_i \geq 0$ 与 $\sum_{i=1}^m p_i = 1$ ，任一来源份额的增加必然挤占其他来源；质量评分 Q_i 则由数据分级给定，在现有配比实验中对每个来源保持固定。若把完整配比压缩为平均质量 $\sum_i p_i Q_i$ 或单一有效数据量，质量等级相同但知识内容不同的来源将无法区分，跨评估目标的差异化响应也会被掩盖。同时，固定的 Q_i 与来源身份交织，不能仅凭这些实验识别独立提高质量的效应。可观测的模型-数据规模组合较少，不同体系的原始损失又存在尺度偏移，因此盲目增加交互项或直接混合损失均会削弱参数的可辨识性。

基于上述约束，本文采用“经典规模基线—组成响应—独立质量校准”的分层建模框架。首先，对多来源损失进行尺度归一化，利用自适应结构早停识别稳健的经典标度指数；随后针对任意评估目标，在规模基线上叠加配比响应项，以质量加权份额 $p_i Q_i$ 表示分级质量与投入的联合暴露，以中心化对数比特特征刻画单纯形上的相对组成，并允许响应幅度随 N 、 D 变化。该设计保留了经典标度律对规模收益递减的解释，同时允许相同质量等级的不同来源产生不同的损失变化。受规模锚点数量限制，扩展模型沿用前述经典指数，而不从配比实验中重新辨识所有规模参数。

5.2 问题二的模型建立

5.2.1 经典标度律的参数辨识模型建立与验证

为刻画模型规模、训练数据量与验证损失之间的基本数量关系，本文采用经典标度律

$$L(N, D) = E + AN^{-\alpha} + BD^{-\beta}, \quad (5.9)$$

其中， N 表示模型参数量， D 表示训练 Token 数， L 表示验证集交叉熵损失； E 是规模趋于充分时仍无法消除的不可约损失， A 与 B 分别控制参数规模项和数据规模项的幅度， α 与 β 则刻画两类资源的边际收益衰减速度。为保证模型具有明确的物理含义，估计过程中施加

$$0 \leq E < \min_i L_i, \quad A > 0, \quad B > 0, \quad \alpha > 0, \quad \beta > 0 \quad (5.10)$$

等约束。由式 (5.9) 可知，随着 N 或 D 增大，预测损失单调下降，但改善幅度逐渐减小，因而能够自然描述大模型训练中的收益递减现象。

损失尺度归一化 不同模型体系可能采用不同的分词器、验证语料和损失统计口径，即使其学习曲线具有相似形状，原始 Loss 的位置和尺度也可能存在系统差异。若直接比较原始损失，模型族之间的整体平移或缩放会被误判为标度结构失效。为此，本文将主拟合来源的 Loss 定义为参考尺度，并假设第 j 个外部来源的观测损失满足仿射观测关系

$$L_{ji}^{\text{obs}} = a_j + b_j L_{ji}^{\text{ref}} + \varepsilon_{ji}, \quad b_j > 0, \quad (5.11)$$

其中， a_j 描述损失基线差异， b_j 描述损失单位或动态范围差异， ε_{ji} 为无法由统一尺度解释的结构残差。相应地，将外部观测映射到参考尺度：

$$\tilde{L}_{ji} = \frac{L_{ji}^{\text{obs}} - a_j}{b_j}. \quad (5.12)$$

主拟合来源取 $a_0 = 0$ 、 $b_0 = 1$ ，因此其训练过程保持在原始可解释的 Loss 尺度上；其他来源经式 (5.12) 归一化后再参与验证与结构选择。

为防止利用同一批验证标签完成校准后又在原样本上评价，本文采用按训练轨迹或模型族分簇的交叉归一化。对于待评价簇 c ，仅使用其余簇估计

$$(\hat{a}_j^{(-c)}, \hat{b}_j^{(-c)}) = \arg \min_{a \in \mathbb{R}, b > 0} \sum_{i: g(i) \neq c} \left[L_{ji}^{\text{obs}} - (a + b \hat{L}_{ji}^{\text{ref}}) \right]^2, \quad (5.13)$$

再使用 $\hat{a}_j^{(-c)}$ 和 $\hat{b}_j^{(-c)}$ 归一化留出簇。该处理只消除来源间的仿射尺度差异，不改变留出轨迹的排序、曲率和局部偏差，因而归一化后的剩余误差仍能反映标度规律的跨体系可迁移性。为保持评价透明性，本文同时保留未经校准的原始尺度误差，并将其解释为“结构误差与观测尺度偏移”的合成结果。

可分离非线性最小二乘法 式 (5.9) 对五个参数整体而言是非线性模型，但当指数 (α, β) 给定后， E 、 A 和 B 构成线性参数。令

$$\mathbf{y} = (L_1, \dots, L_n)^\top, \quad \boldsymbol{\theta} = (E, A, B)^\top, \quad (5.14)$$

并构建设计矩阵

$$\mathbf{X}(\alpha, \beta) = \begin{bmatrix} 1 & N_1^{-\alpha} & D_1^{-\beta} \\ 1 & N_2^{-\alpha} & D_2^{-\beta} \\ \vdots & \vdots & \vdots \\ 1 & N_n^{-\alpha} & D_n^{-\beta} \end{bmatrix}. \quad (5.15)$$

于是，在任意候选指数对下，内层问题可写为带物理约束的线性最小二乘

$$\hat{\boldsymbol{\theta}}(\alpha, \beta) = \arg \min_{\boldsymbol{\theta}} \|\mathbf{y} - \mathbf{X}(\alpha, \beta) \boldsymbol{\theta}\|_2^2. \quad (5.16)$$

将内层解析解代回后，原问题被压缩为仅关于两个指数的轮廓残差平方和

$$S(\alpha, \beta) = \left\| \mathbf{y} - \mathbf{X}(\alpha, \beta) \hat{\boldsymbol{\theta}}(\alpha, \beta) \right\|_2^2. \quad (5.17)$$

本文先在指数区间内设置等距节点进行粗网格搜索，再以当前最优点为中心实施局部模式搜索，并逐次将搜索步长减半，直至步长小于 10^{-7} 。相较于同时对五个参数进行无结构的非线性优化，该可分离非线性最小二乘方法将高维耦合问题转化为“外层低维指数搜索 + 内层线性求解”，既降低了初值敏感性，也便于在每个指数候选点严格检查参数正性和不可约损失边界。

自适应结构早停 指数自由度越高，越容易把数据噪声读作真实的标度结构差异，因此本文按由简到繁、以外部验证收益为准的顺序逐层释放指数自由度。第一层令 $\alpha = \beta = s$ ，对共享指数 s 进行一维搜索；第二层以第一层最优值 s^* 为锚点，分别考察“固定 $\beta = s^*$ 、释放 α ”和“固定 $\alpha = s^*$ 、释放 β ”两个并列候选；只有当单方向释放产生稳定的外部收益时，第三层才进入 (α, β) 均自由的二维搜索。每个候选指数点仍由式 (5.16) 估计 E 、 A 和 B ，因此该过程并未引入新的标度律项，而是在同一标准模型内部逐步增加指数自由度。

不同来源的可信度、判别难度与统计稳定性并不相同，因此本文不预先固定其权重。记 r_j 为可信度先验， d_j 为基准模型在该来源上的验证难度， σ_j 为按轨迹或模型族分簇 Bootstrap 得到的分数标准差，则定义稳定性因子和原始权重

$$s_j = \frac{1}{1 + \sigma_j/d_j}, \quad u_j = r_j d_j^m s_j, \quad (5.18)$$

并在给定上下限后将 u_j 归一化为 w_j 。较困难但稳定、且证据可靠的来源因而获得较高权重；高度相关、半合成或波动较大的来源则不会主导结构选择。权重在比较候选结构之前一次确定并冻结，以避免针对某个候选模型事后调整评价标准。

候选结构的最终选择分数定义为

$$J_m = \sum_j w_j \text{MedAPE}_{jm} + \lambda \max(0, k_m), \quad (5.19)$$

其中，**MedAPE** 衡量归一化后的相对预测偏差， k_m 为有效自由参数数目，第二项用于要求新增指数自由度给出足以抵消复杂度增长的外部收益。候选结构首先需要满足主拟合样本上的最低拟合门槛。随后，只有当 $J_m < J_{\text{best}} - \delta$ 时，才将其视为实质改善并更新历史最优结构。

经典标度律的拟合、验证与外推 自适应结构早停最终保留参数项与数据项共享指数的简约结构，得到

$$\hat{L}(N, D) = 1.654679 + 0.425107N^{-0.293183} + 1.205248D^{-0.293183}, \quad (5.20)$$

其决定系数为 0.99938498，RMSE 为 0.00848302。释放参数规模指数仅使选模分数改善 0.000159，低于阈值 $\delta = 0.002$ ，因此不增加指数自由度。图 5.6(a) 表明，增加训练数据量或模型参数量均可降低损失，但边际收益持续递减。将资源投入统一换算为 $C = 6ND$ 后，各规模训练轨迹呈现相近的下降趋势；图 5.6(b) 中的经验下沿包络近似满足 $L = 2.26C^{-0.0665}$ ，刻画了既定计算预算下可达到的效率前沿。




图 5.6 经典标度律的资源标度与计算效率：(a) 参数规模、数据规模与验证损失的标度关系；(b) 不同参数规模下计算量与验证损失的关系，虚线为经验下沿包络。

为检验跨来源迁移能力，本文提取独立训练轨迹的最终收敛点，并采用留一轨迹或留一模型族的仿射尺度校准。表 5.7 与图 5.7(a) 显示，归一化后的四类数据均保持较高秩相关性。公开文献观测的误差相对较高，但考虑数据质量、网络结构与训练策略造成的差异，仍在标准标度律的描述范围内。

图 5.7(b) 进一步给出百亿参数以上的情景外推。经典标度律在固定数据规模下预测损失随参数量缓慢下降，而大模型样本的离散程度明显更高，表明超大区间还受到数据质量与训练配置的显著影响。因此，该图用于界定外推趋势和风险，不作为新的外部验证证据，并为后续引入质量变量与领域配比提供依据。

表 5.7 经典标度律的多来源样本外验证结果

验证来源	样本数	原始 RMSE	归一化 RMSE	中位相对误差	Spearman 系数
独立模型族收敛终点	7	0.855373	0.014636	0.70%	1.0000
连续插值训练轨迹	4000	0.011422	0.011445	0.28%	0.9998
跨模型族实验	57	0.289767	0.088138	1.57%	0.9758
公开文献实验观测	44	0.191785	0.127853	5.24%	0.9280




图 5.7 经典标度律的跨来源验证与大模型外推：(a) 损失尺度归一化后的多来源预测一致性，虚线为理想预测，阴影区域表示相对误差不超过 10%；(b) 百亿参数以上模型区间的标度律外推，曲线按中位训练数据量计算。

5.2.2 经典标度律的外推与广义标度律的设计

经典标度律揭示了参数规模与训练数据量的损失衰减规律，但其同质 Token 假设无法区分训练语料的质量和来源组成。为分析这一缺口，首先考察实验的可辨识结构，在模型规模与训练 Token 数均固定的条件下，存在数百种不同的语料配比，因而经典标度律对这些实验给出同一预测基线，却无法解释其损失差异。另有 256 组配比在两个模型规模下逐一对应，可比较规模改变后配比响应的形状与幅度。这说明需要在规模基线之外单独建立组成响应，而非仅用总 Token 数代表全部训练数据。与此同时，观测实验仅提供三个不同的 (N, D) 规模锚点，其中较大模型的 N 与 D 同时变化；若连同组成效应重新估计全部规模指数，将产生明显的参数混淆。因此沿用前文估计的 α, β ，将新增参数集中用于刻画组成效应及其跨规模变化。

其次，训练配比属于单纯形，提高某一来源的份额必然压缩其他来源，故各 p_i 不是相互独立的投入量。仅以平均质量 $\sum_i p_i Q_i$ 概括语料，会把质量相近但知识内容不同的来源混为一谈。只用原始份额又难以直接表达来源之间的相对替代。基于这一约束，采用质量加权份额 $p_i Q_i$ 记录各来源的有效投入，并以中心化对数比刻画相对组成。但现有质量评分对每个来源固定， $p_i Q_i$ 与 p_i 在统计上不能区分独立的质量改善效应，因此这一项只表示给定质量分级下的组成暴露，不能作质量因果效应解释。

最后，逐行配对的跨规模配比为检验“响应形状相对稳定、作用幅度随规模改变”的可分离假设提供了依据。用规模幂函数调节组成响应的幅度，既与经典标度律的形式协调，也避免为每个规模重新拟合一套配比函数；以参考规模归一化该幅度，并将组成响应在参考样本上中心化，可减少其与损失截距之间的混淆。由于配比维度随来源数增长，估计时还须施加正则化以控制方差。设训练语料包含任意 m 个来源， $\mathbf{p} = (p_1, \dots, p_m)$ 满足 $p_i \geq 0$ 、 $\sum_i p_i = 1$ ， $\mathbf{Q} = (Q_1, \dots, Q_m)$ 为相应质量属性。对于任意给定的评估目标，由此

提出统一的函数结构

$$L(N, D, \mathbf{p}, \mathbf{Q}) = E + AN^{-\alpha} + BD^{-\beta} + \left(\frac{N}{N_0}\right)^{-\eta} \left(\frac{D}{D_0}\right)^{-\zeta} \phi(\mathbf{Q}, \mathbf{p}), \quad (5.21)$$

其中 (N_0, D_0) 为参考规模。 E 、 A 和 B 决定损失基线， α 、 β 为规模指数， η 、 ζ 刻画组成响应随规模变化的程度。两个规模比值在参考规模均为 1，故 ϕ 直接表示该规模下的损失修正。为避免平均质量 $\sum_i p_i Q_i$ 抹去同等级、不同知识来源之间的差别，将组成响应展开为

$$\phi(\mathbf{Q}, \mathbf{p}) = \sum_{i=1}^m w_i (p_i Q_i - \bar{m}_i) + \sum_{i=1}^m w_{\text{clr},i} (\text{clr}_\varepsilon(\mathbf{p})_i - \bar{m}_{\text{clr},i}). \quad (5.22)$$

这里 w_i 与 $w_{\text{clr},i}$ 分别为质量加权份额和相对配比的有效权重； $\bar{m}_i$ 、 $\bar{m}_{\text{clr},i}$ 是对应特征在参考规模拟合样本上的均值，使 ϕ 在该样本上均值为零。其中，中心化对数比定义为

$$\text{clr}_\varepsilon(\mathbf{p})_i = \log(p_i + \varepsilon) - \frac{1}{m} \sum_{j=1}^m \log(p_j + \varepsilon). \quad (5.23)$$

式 (5.22) 中的 $p_i Q_i$ 记录质量加权的来源投入，中心化对数比反映单纯形上的相对结构， $\varepsilon > 0$ 用于处理零占比。拟合时对这两组特征进行标准化与正则化，并将所得系数换算为式 (5.22) 中的有效权重。不同评估目标均采用式 (5.21) 的函数结构，但 E 、 A 、 B 、 η 、 ζ 及组成权重分别估计。

5.2.3 广义标度律的估计模型建立

5.3 问题二的结果

5.3.1 广义标度律各因素边际效用与弹性分析

5.3.2 广义标度律下领域数据间关系分析

5.3.3 广义标度律指导下的大模型训练方案选择与验证

六、 问题三：算力约束下的联合资源配置

七、 问题四：技术演进分解及能力前沿预测

八、 结论、局限与推广

参考文献

- [1] Mittelbach F, Goossens M, Braams J, et al., The $\LaTeX$ Companion, 2nd ed., Reading, MA, USA: Addison-Wesley, 107-109, 2004.
- [2] Wright J, $\LaTeX$ 3 programming: External perspective, TUGboat, 30(1):107-109, 2009.
- [3] Beeton B, Freytag A, Sargent III M, Unicode support for mathematics, <http://www.unicode.org/reports/tr25/>, 2018-07-21.
- [4] Vieth U, Experiences typesetting mathematical physics, Proceedings of EuroTeX, 13, 2009.

AI 工具使用说明

本文使用 AI 工具辅助数据字段理解、代码调试、图表绘制、文字润色，以及对 210 条分层抽样文本进行初步阅读。上述 AI 输出均由作者逐项复核并独立确认，论文中采用的原文一致性结论以作者复核结果为准。核心模型、公式推导、参数选择、结果解释与结论由作者完成。

附录 A 完整数据审计表

附录 B 关键参数与敏感性结果

附录 C 程序代码