



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

中南大学

参赛队号

20250900001

队员姓名

1.

彭铸

2.

郑徐瀚宇

3.

阳挺

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： 全国研究生数学建模竞赛论文标题

摘 要：

目录

一、 问题重述	3
1.1 问题背景	3
1.2 问题重述	3
1.3 总体技术路线	3
二、 基本假设与符号说明	3
2.1 基本假设	3
2.2 符号说明	3
三、 数据说明与预处理	3
3.1 数据来源及可信度分层	3
3.2 数据口径统一	3
3.3 训练、检验及外推数据划分	3
四、 问题一：数据质量评价、冲突消解及领域配比	3
4.1 数据质量评价	4
4.1.1 质量信号统一表征与方向审计	4
4.1.2 域均衡层次质量评价	4
4.1.3 质量评价结果与一致性检验	5
4.2 质量冲突消解	7
4.2.1 质量冲突的域感知识别	7
4.2.2 冲突证据的可靠性重加权	8
4.2.3 冲突消解效果及稳健性	8
4.3 领域配比-Loss 关系	8
4.3.1 配比数据标准化及质量先验检验	9
4.3.2 配比-Loss 响应的预测与解释模型	9
4.3.3 领域份额替换及互补结构	9
4.3.4 配比规律的跨尺度迁移边界	10
五、 问题二：广义标度律及质量-规模替代	11
六、 问题三：算力约束下的联合资源配置	11
七、 问题四：技术演进分解及能力前沿预测	11
八、 结论、局限与推广	11
附录 A 完整数据审计表	13
附录 B 关键参数与敏感性结果	13
附录 C 程序代码	13

一、 问题重述

- 1.1 问题背景
- 1.2 问题重述
- 1.3 总体技术路线

二、 基本假设与符号说明

- 2.1 基本假设
 - 1.
- 2.2 符号说明

表 2.1 主要符号说明

符号	含义
x_{ij}	样本 i 在第 j 项质量信号上的原始取值
s_{ij}	指标方向统一后的质量表示, $s_{ij} \in [0, 1]$
F_j^{bal}	第 j 项信号的域均衡经验分布
$\mathcal{P}, \mathcal{N}, \mathcal{M}$	正向、负向与中心适宜指标集合
G_k, a_{jk}	第 k 个信息簇及其簇内指标权重
K	信息簇个数, 取 $K = 9$
η_j	第 j 项信号的领域间方差占比
$Q_i^{(0)}$	样本 i 的初始质量分数
r_{ij}, I_{ij}	标准化异常度与冲突指示变量
C_i	样本 i 的冲突度
R_{ij}, U_i	证据可靠度与信息簇平均可靠度
Q_i^*	冲突校正后的质量分数
p_i	第 i 个训练域在配方中的份额
$z_{mk}, \phi(\mathbf{p})$	标准化验证损失与总体配比表现
$S_{i \leftarrow j}$	份额由领域 j 转向领域 i 的边际替换效应
C_{ij}^{mix}	领域 i 与 j 的互补指数
ρ_s	Spearman 等级相关系数

三、 数据说明与预处理

- 3.1 数据来源及可信度分层
- 3.2 数据口径统一
- 3.3 训练、检验及外推数据划分

四、 问题一：数据质量评价、冲突消解及领域配比

附件 A 包含两类相互衔接的数据, A1–A3 给出语料的多维质量信号, A4–A15 给出不同领域配方及其验证损失。本问依次解决三个层次的问题。首先在七域样本不均衡条件下构造初始质量 $Q^{(0)}$; 随后依据各领域内部的正常指标关系识别异常评价证据, 并校正其权

重得到 Q^* ；最后在单纯形约束下建立 17 域训练配比对 13 域验证 Loss 的联合响应。 Q^* 经 A16 映射为 $Q^{(17)}$ ，并与总体配比效应 $\phi(\mathbf{p})$ 一同作为问题二的数据侧输入。

4.1 数据质量评价

A1 含 51,230 条样本、7 个领域和 22 项质量信号；A2、A3 分别是 arxiv 和 github 的扩展抽样集合，各含 17,523 条和 203,752 条样本，并完整包含 A1 对应领域的 1,419 条与 10,000 条样本。A2、A3 采用与 A1 相同的字段口径和采集来源，因此可用于检验 A1 的抽样代表性。综合评价面临三项结构性困难，即七域样本量差异显著、多项评价信号存在重复信息，以及部分文本结构指标具有合理区间而非简单单调关系。针对这三点，依次进行质量信号统一表征、域均衡标度、信息簇合成和人工一致性检验。

4.1.1 质量信号统一表征与方向审计

22 项信号包含 8 个列表字段和 14 个标量字段。列表字段按原始含义先行标量化，二分类 logits 经 softmax 转为目标类别概率，六级有序 logits 取期望等级并按 5 归一化，QuRating 的四个异质量纲分量先分别作百分位变换再取均值。原始数据完整性良好，仅 modernbert_reasoning 与 modernbert_professionalism 分别出现 13 条和 5 条无效 logits，以所属领域的中位数填补，占总样本比例不足 0.04%。

标量化只解决量纲不一致，并不解决方向不一致。为统一综合分数的含义，本文对 22 项信号逐一登记方向，分为正向、负向和中心适宜三类，最终仅 WordLength、Sentences、WordCount、Entropy 与 Uppercase 设为中心适宜，其余按单调方向处理；方向设定的依据与消融见 4.1.3 节。表 4.2 汇总 22 项信号的短名、含义、字段形态、标量化方式以及统一表示 s_{ij} 的分布特征，信息簇归属与方向判定见图 4.1。

表 4.2 22 项质量信号的统一表征与分布特征

信号短名	含义	字段形态	标量化方式	$\bar{s}$	σ_s	η_j
NoAlpha	非字母词比例	标量	直接使用	0.516	0.310	0.49
Uppercase	大写字母比例	标量	直接使用	0.835	0.280	0.47
TermPunct	句末标点比例	标量	直接使用	0.498	0.298	0.60
Ad-Prob	无广告概率	列表 2	softmax 取 $P(\text{no-ad})$	0.491	0.291	0.20
MB-Reason	推理性	列表 6	期望等级 / 5	0.404	0.251	0.60
UniqueWords	词汇多样性	标量	直接使用	0.624	0.224	0.62
DSIR-Math	数学域倾向	标量	直接使用	0.626	0.223	0.64
DSIR-Books	书籍域倾向	标量	直接使用	0.625	0.225	0.63
DSIR-Wiki	维基域倾向	标量	直接使用	0.626	0.223	0.64
FineWebEdu	教育价值	列表 1	取列表唯一评分	0.447	0.279	0.24
MB-Prof	专业性	列表 6	期望等级 / 5	0.452	0.268	0.69
Fluency	语言流畅度	列表 2	softmax 取 $P(\text{fluent})$	0.477	0.293	0.30
QuRating	综合文本质量	列表 4	四分量分位均值	0.447	0.203	0.39
MB-Clean	洁净度	列表 6	期望等级 / 5	0.435	0.283	0.44
MB-Read	可读性	列表 6	期望等级 / 5	0.434	0.292	0.38
WordLength	平均词长	标量	直接使用	0.795	0.311	0.31
Numerical	数字字符比例	标量	直接使用	0.461	0.290	0.16
Sentences	句子数	标量	直接使用	0.857	0.270	0.38
WordCount	词数	标量	直接使用	0.858	0.271	0.42
Entropy	一元词熵	标量	直接使用	0.855	0.272	0.40
Top2Gram	二元重复集中度	标量	直接使用	0.420	0.282	0.27
Top3Gram	三元重复集中度	标量	直接使用	0.444	0.306	0.18

注：字段形态中“列表 m ”表示该字段为长度 m 的列表； $\bar{s}$ 与 σ_s 为统一表示 s_{ij} 在 A1 全样本上的均值与标准差； η_j 为指标 j 的领域间方差占比；中心适宜指标在中间 60% 分位区间取满分，其 $\bar{s}$ 相应偏高。表内按信息簇 C1–C9 分组排列。

4.1.2 域均衡层次质量评价

A1 中 book 仅 171 条、arxiv 为 1,419 条，而 c4、github、stackexchange、wikipedia 均接近 10^4 条。若以全样本经验分布作为统一标尺，大样本领域将获得更高权重；若分别在

域内归一化，则会抹去域间真实差异。因此，对指标 j 在领域 d 内建立经验分布 F_{jd} ，并令七个领域等权参与公共参考尺度，即

$$F_j^{\text{bal}}(x) = \frac{1}{7} \sum_{d=1}^7 F_{jd}(x). \quad (4.1)$$

在此基础上，将不同方向的指标统一为 $s_{ij} \in [0, 1]$ ，具体形式为

$$s_{ij} = \begin{cases} F_j^{\text{bal}}(x_{ij}), & j \in \mathcal{P}, \\ 1 - F_j^{\text{bal}}(x_{ij}), & j \in \mathcal{N}, \\ \min \left\{ \frac{F_j^{\text{bal}}(x_{ij})}{0.20}, \frac{1 - F_j^{\text{bal}}(x_{ij})}{0.20}, 1 \right\}, & j \in \mathcal{M}, \end{cases} \quad (4.2)$$

其中 $\mathcal{P}, \mathcal{N}, \mathcal{M}$ 分别表示正向、负向和中心适宜指标集合。中心适宜函数在中间 60% 分位区间取满分，仅对结构极端样本进行惩罚。

统一表征后，以域均衡权重计算 22 项信号的 Spearman 相关矩阵，并以 $1 - |\rho|$ 为距离进行层次聚类。综合轮廓系数和 120 次分层 bootstrap 的配对稳定度，数据驱动选择 $K = 9$ 个信息簇。对第 k 个信息簇 G_k ，以簇内绝对相关矩阵的最大特征向量形成非负权重 a_{jk} ；不同簇之间采用等权，即

$$H_{ik} = \sum_{j \in G_k} a_{jk} s_{ij}, \quad Q_i^{(0)} = \frac{1}{K} \sum_{k=1}^K H_{ik}, \quad K = 9. \quad (4.3)$$

这种层次合成先在同类信号中提取共识，再汇总不同质量语义，从而削弱重复评价对综合分数的影响。图 4.1 表明，域均衡相关矩阵呈明显的簇状结构，顶部色带给出信息簇归属，右侧给出领域间方差占比 η_j 与指标方向。多个 DSIR 与模型评分信号的 η_j 超过 0.60，说明其变化更多来自领域身份而非通用质量，因此这些指标只参与综合评价，不单独解释为领域质量的因果来源。

4.1.3 质量评价结果与一致性检验

领域级质量以域内 $Q_i^{(0)}$ 的均值表示，并在固定评价规则下采用分层 bootstrap 构造 95% 置信区间。表 4.3 给出七域点估计、分布中心和同源扩展检验，图 4.2 则展示领域排序及方向假设的主要证据。

arxiv 的平均 $Q^{(0)}$ 最高，github 最低。github 的人工审阅相关仅为 0.071，明显低于其他领域，说明代码和技术文本与现有评价信号之间存在较强的领域失配；因此该排名仅表示统一评价口径下的相对位置，不作语料本身优劣的绝对判断。A1 的微平均与宏平均接近，说明样本量不平衡未改变总体水平判断；book 样本量最小，其置信区间也最宽。冻结 A1 的标量化规则、公共 ECDF、信息簇及簇内权重后应用于 A2/A3，arxiv 和 github 的均值差分别仅为 -1.74×10^{-3} 和 -5.4×10^{-5} ，对应的 Wasserstein 距离也很小，表明 A1 对两类同源扩展集合具有较好的代表性。

方向设定与聚合方式的消融结果见表 4.4。最终“五中心”方案在保持七域排序稳定的同时，将 210 条分层人工复核与 $Q^{(0)}$ 的 Spearman 相关提高到 0.666；全部结构指标均按正向处理时，七域排序相关降至 0.429。等权与 CRITIC 与本文方法的样本排序相关分别为 0.901 和 0.920，说明主要质量结构具有较高共识；全局 PCA 的一致性明显较低，说明直接以单一主成分压缩 22 项信号会损失部分质量语义。

表 4.4 的人工审阅列同时给出 210 条复核样本上的 95% 分层 bootstrap 区间。最终五中心方案相对 CRITIC、等权和旧八中心方案的审阅相关差值分别为 0.041、0.047 和 0.050，




图 4.1 22 项质量信号的冗余结构与领域异质性

表 4.3 七域初始质量评价及同源扩展检验

领域	n	A1 均值	95% CI	ΔQ	W_1
arxiv	1,419	0.7076	[0.7055, 0.7098]	-0.001740	0.002437
commoncrawl	9,640	0.6056	[0.6043, 0.6067]	—	—
stackexchange	10,000	0.6024	[0.6011, 0.6038]	—	—
wikipedia	10,000	0.5950	[0.5934, 0.5968]	—	—
c4	10,000	0.5548	[0.5529, 0.5566]	—	—
book	171	0.4994	[0.4875, 0.5115]	—	—
github	10,000	0.4786	[0.4771, 0.4802]	-0.000054	0.000384
总体		$Q_{\text{micro}} = 0.5707$		$Q_{\text{macro}} = 0.5776$	

注：A1 均值为初始质量 $Q^{(0)}$ 的域内均值，95% CI 由分层 bootstrap 给出； ΔQ 为 A2/A3 全量均值减 A1 对应领域均值， W_1 为 Wasserstein 距离。A2/A3 与 A1 同源，因此该结果用于检验抽样代表性。

表 4.4 质量评价方案的消融与一致性检验

检验类型	方案	七域排序	样本排序	人工审阅
方向设定	旧八中心方案	1.000	0.880	0.616 [0.54, 0.68]
	最终五中心方案	1.000	1.000	0.666 [0.61, 0.72]
	中心指标减为四个	0.893	0.993	0.656 [0.60, 0.71]
	全部按正向处理	0.429	0.772	0.634 [0.56, 0.70]
聚合基线	等权	0.929	0.901	0.619 [0.55, 0.69]
	CRITIC	0.929	0.920	0.625 [0.55, 0.69]
	全局 PCA	0.750	0.622	0.449 [0.36, 0.53]

注：三列均为 Spearman 相关 ρ_s ；人工审阅列为 210 条分层样本上的 95% 分层 bootstrap 区间，样本按领域与质量层次分层抽取，排序相关均以最终五中心方案为基准。




图 4.2 七域质量评价结果与评价规则可信度

区间分别为 $[0.009, 0.073]$ 、 $[0.013, 0.080]$ 和 $[0.017, 0.083]$ ，均不包含 0，说明方向审计与层次合成带来的提升不是抽样噪声，但幅度有限。相对“中心指标减为四个”的差值为 0.010，区间 $[-0.003, 0.022]$ 包含 0，二者在人工一致性上不可区分，保留中心五指标的意义在于不丢失结构语义；相对“全部按正向处理”的差值区间同样包含 0，该方案的决定性缺陷体现在七域排序相关由 1.000 降至 0.429。

由此得到的 $Q^{(0)}$ 保留了样本间的质量次序和域间差异，可作为下一节冲突校正的基准分数；其数值用于统一评价口径下的相对比较。

4.2 质量冲突消解

$Q^{(0)}$ 的合成默认各项质量证据均可直接使用，但特殊文本可能使个别评价器偏离该领域的常见关系。因此，本文把“正常的多维差异”与“异常的不一致”分开处理。只有当某项观测显著偏离同域相关信号所预测的正常水平时，才记为质量冲突；随后降低该项证据在综合评价中的权重。

4.2.1 质量冲突的域感知识别

以上一节的域均衡相关结构为基础，仅保留 $|\rho| \geq 0.10$ 且在 300 次分层 bootstrap 中稳定率不低于 0.95 的指标关系，共得到 135 条稳定边。对每项指标，用其稳定邻居和领域信息建立 Elastic Net 预测器，并按七域进行 5 折 cross-fitting，使每个样本的条件期望均由未包含该样本的训练折给出。记交叉预测残差为 $e_{ij} = s_{ij} - \hat{s}_{ij}^{(-i)}$ ，并在所属领域内按 MAD 标准化。若异常度进入对应“指标-领域”经验残差分布的上 2.5% 尾部，则置 $I_{ij} = 1$ 。样本级冲突度同时计入异常覆盖范围和异常强度，即

$$\begin{aligned}
 r_{ij} &= \frac{|e_{ij}|}{1.4826 \text{MAD}_{d_i}(e_{\cdot j}) + \varepsilon}, \\
 p_{ij}^{\text{conf}} &= 1 - F_{j, d_i}^R(r_{ij}), \quad I_{ij} = \mathbf{1}\{p_{ij}^{\text{conf}} < 0.025\}, \\
 C_i &= \sqrt{\left(\frac{1}{22} \sum_j I_{ij}\right) \left(\frac{\sum_j I_{ij} r_{ij}}{\sum_j I_{ij} + \varepsilon}\right)}.
 \end{aligned} \tag{4.4}$$

该定义以各指标在各领域中的正常波动为参照，因此不会把代码、公式密集文本等领域特征仅因数值差异而判为冲突。

4.2.2 冲突证据的可靠性重加权

冲突不直接从样本总分中扣除，而是作用于对应证据的可靠度。设 τ_{j,d_i} 为指标 j 在领域 d_i 的冲突阈值，定义

$$R_{ij} = \begin{cases} 1, & I_{ij} = 0, \\ \exp\{-0.5(r_{ij} - \tau_{j,d_i})_+\}, & I_{ij} = 1, \end{cases} \quad Q_i^* = \sum_{k=1}^K v_{ik}^* H_{ik}, \quad v_{ik}^* = \frac{\sum_{j \in G_k} a_{jk} R_{ij}}{\sum_{\ell=1}^K \sum_{h \in G_\ell} a_{h\ell} R_{ih}}. \quad (4.5)$$

各信息簇可靠度的均值记为 U_i 。当不存在冲突时， $v_{ik}^* = 1/K$ ，故 $Q_i^* = Q_i^{(0)}$ ；出现局部异常时，仅相应信息簇的权重发生变化。

4.2.3 冲突消解效果及稳健性

冲突校正后， Q^* 与 $Q^{(0)}$ 的全样本 Spearman 为 0.9992，说明总体质量次序基本保持不变；但修正量明显向高冲突样本集中。Top 10%、Top 5% 和 Top 1% 冲突样本的 $|Q^* - Q^{(0)}|$ 中位数分别为 0.00435、0.00655 和 0.0118，且 Top 10% 样本贡献了 64.8% 的总绝对修正量。图 4.3 中的分箱中位线进一步显示，冲突程度升高后修正幅度呈持续上升趋势。




图 4.3 冲突修正的局部性与异常来源

高严重度冲突主要集中在 Entropy、Sentences、Uppercase、WordCount 和 WordLength 等结构信号，表明异常主要来自文本结构偏离所属领域的常态。最新结果中 GitHub 的平均冲突度最高 (0.180)，Book 最低 (0.138)；这里的领域差异反映评价证据的一致性，而不用于比较领域质量高低。将 A1 学得的关系结构、残差尺度和阈值冻结后应用于 A2/A3，严重冲突仍集中在同类结构信号。作为对照，本文冲突度与“指标方差”和“最大两两差”的 Spearman 仅为 0.132 和 0.172；当显著性阈值在 0.01–0.10、可靠性衰减系数在 0.3–1.0 内变化时， Q^* 排序与主方案的 Spearman 始终不低于 0.994。因此，冲突校正主要影响高冲突尾部，并未改变质量评价的主体结构。第二小问最终输出 (Q_i^*, U_i, C_i) ，分别记录修正后的质量、证据可信度和冲突程度。

4.3 领域配比–Loss 关系

A4/A5 提供 512 组 1M 训练配方及其 13 域验证 Loss；A6/A7 为 1M 同尺度真实检验，A8/A9 和 A10/A11 分别提供 60M、1B 真实检验，A12–A15 为 10B、70B 外推表。17 个训练比例满足 $p_i \geq 0$ 、 $\sum_i p_i = 1$ ，而 13 个验证域的 Loss 基准不同，因此建模时需同时处理单纯形约束、多输出响应和跨尺度迁移。

4.3.1 配比数据标准化及质量先验检验

不同验证域的 Loss 先在 A5 内按验证域进行中位数-MAD 标准化，再定义总体配比表现，即

$$z_{mk} = \frac{L_{mk} - \text{median}(L_{\cdot k})}{1.4826 \text{ MAD}(L_{\cdot k})}, \quad \phi(\mathbf{p}) = -\frac{1}{13} \sum_{k=1}^{13} \hat{z}_k(\mathbf{p}). \quad (4.6)$$

$\phi(\mathbf{p})$ 越大，表示该配方在 13 个验证域上的总体表现越优。

第二小问得到的七域 Q^* 经 A16 映射到 17 个训练域。由于 $\sum_i p_i Q_i$ 是 $\mathbf{p}$ 的确定函数，直接作为额外线性项会与配比变量共线。因此以指数倾斜 $\tilde{p}_i(\gamma) \propto p_i \exp[\gamma(Q_i - \bar{Q})]$ 检验质量先验。交叉验证的最优值为 $\gamma = 0$ ，且 $\gamma > 0$ 时误差略有增加，说明 A4/A5 无法把“领域身份”与“领域质量”的独立作用分开识别。本小问据此不引入质量先验，质量的独立边际效应在问题二 B6-B8 的独立质量变化中进一步估计。

4.3.2 配比-Loss 响应的预测与解释模型

为显式刻画领域及领域组合的作用，对第 k 个验证域建立二阶 Scheffé 混合响应

$$\hat{z}_k(\mathbf{p}) = \sum_{i=1}^{17} \beta_{ik} p_i + \sum_{1 \leq i < j \leq 17} \gamma_{ijk} p_i p_j, \quad k = 1, \dots, 13. \quad (4.7)$$

17 个主效应和 136 个交互项在 13 个任务上联合拟合，以组稀疏约束筛选跨任务稳定结构，并用 Ridge 项稳定相关系数；一阶 Scheffé 和 ILR-Ridge 作为对照。1M 真实检验结果见表 4.5。

表 4.5 1M 真实检验集上的配比响应模型比较

模型	平均 RMSE	平均 R^2	MAE	用途
一阶 Scheffé	0.522	0.619	0.435	线性混合基准
多任务稀疏 Scheffé	0.444	0.710	0.361	机制解释
ILR-Ridge	0.420	0.765	0.337	数值预测

注：RMSE、 R^2 、MAE 均为 13 个验证任务的平均值；总体宏观配比指标 G 在 1M 检验集上的 R^2 为 0.391。

ILR-Ridge 的点估计最优；重复 5 折交叉验证下，其相对多任务 Scheffé 的 R^2 差值均值为 0.038，95% CI 为 $[-0.012, 0.081]$ ，区间包含 0。因此后续数值预测采用 ILR-Ridge，领域替换和交互机制采用多任务稀疏 Scheffé 解释，两类模型分别承担预测和机制分析任务。

4.3.3 领域份额替换及互补结构

在单纯形约束下，“增加领域 i ”必然伴随其他领域份额减少，因此主效应系数不能直接解释为独立边际收益。在参考配比 $\mathbf{p}$ 附近，定义从领域 j 向领域 i 转移份额的边际效应和两领域的总体互补指数，即

$$S_{i \leftarrow j}(\mathbf{p}) = \frac{1}{13} \sum_{k=1}^{13} \left(\frac{\partial \hat{z}_k}{\partial p_i} - \frac{\partial \hat{z}_k}{\partial p_j} \right), \quad C_{ij}^{\text{mix}} = -\frac{1}{13} \sum_{k=1}^{13} \gamma_{ijk}. \quad (4.8)$$

$S_{i \leftarrow j} < 0$ 表示在当前配比附近将份额从 j 转移到 i 有助于降低总体 Loss； $C_{ij}^{\text{mix}} > 0$ 表示两域共同出现时的 Loss 低于线性混合预期。前者描述份额替换，后者描述非加性交互。

为控制稀疏配方造成的大系数伪影，正文只解释同时满足三项条件的关系，即两域训练覆盖充分、bootstrap 符号稳定率不低于 0.95、效应量位于训练支持范围。约 52% 的替

换关系和 46% 的互补关系通过该门槛。通过门槛的关系中，DM-Math $\rightarrow$ HackerNews 的替换效应为 -2.68 ，显示稳定的 Loss 改善信号；arXiv-GitHub 则表现出稳定互补。相反，enron_emails 的平均份额仅 0.0022、最大份额 0.026、非零占比 0.31，其大幅替换效应超出充分支持范围，因此不进入机制结论。图 4.4 将替换矩阵和通过资格门槛的互补/冗余关系合并展示，灰色斜线区域表示证据不足。




图 4.4 领域配比的替换机制与互补结构

4.3.4 配比规律的跨尺度迁移边界

同尺度预测精度不能直接代表跨规模可迁移性，因此分别考察配比空间外推和模型规模迁移。在配比空间内，以 Hellinger 距离衡量测试配方到最近训练配方的距离。1M 检验集最近邻距离的中位数为 0.299，90% 分位数为 0.375，且预测误差随距离增大而整体上升，说明模型的机制解释应限制在训练配方支持区域附近。

模型规模迁移通过不同尺度下的配方排序一致性衡量。表 4.6 和图 4.5 显示，60M 和 1B 的 Spearman 相关分别为 0.810 和 0.608，均保持为正，但随规模扩大明显减弱；10B、70B 的 Loss 为较小规模幂律外推结果，其排序相关和预测-观测斜率均转为负值。因此，现有数据支持真实 1M–1B 范围内的有限迁移，不支持将小模型上的配比规律视为尺度不变关系。

问题一最终得到三类后续输入，即冲突修正质量 Q^* 、映射到 17 个训练域的质量描述 $Q^{(17)}$ 以及总体配比效应 $\phi(\mathbf{p})$ 。替换效应 $S_{i \leftarrow j}$ 和互补指数 C_{ij}^{mix} 用于解释领域结构， U 与 C 用于记录质量评价中的不确定性。问题二将在此基础上融合附件 B，建立含参数规模、数据量、质量和领域结构的广义标度关系。

表 4.6 领域配比效应的跨尺度一致性

模型规模	数据性质	样本数	排序相关 ρ_s	两两一致率	回归斜率
60M	真实检验	256	0.810	0.805	0.912
1B	真实检验	64	0.608	0.711	0.348
10B	外推 Loss	63	-0.584	0.293	-0.339
70B	外推 Loss	63	-0.617	0.279	-0.370

注：排序相关为各尺度配方排序与 1M 预测排序的 Spearman 相关，两两一致率为配方两两比较方向一致的比例，回归斜率为预测-观测回归的斜率；10B/70B 的 Loss 来自小规模实验的幂律外推，仅用于识别尺度失效边界，不作为真实大模型训练验证。




图 4.5 配比模型的预测有效域与跨尺度迁移边界

五、 问题二：广义标度律及质量-规模替代

六、 问题三：算力约束下的联合资源配置

七、 问题四：技术演进分解及能力前沿预测

八、 结论、局限与推广

AI 工具使用说明

本文使用 AI 工具辅助数据字段理解、代码调试、图表绘制、文字润色，以及对 210 条分层抽样文本进行初步阅读。上述 AI 输出均由作者逐项复核并独立确认，论文中采用的原文一致性结论以作者复核结果为准。核心模型、公式推导、参数选择、结果解释与结论由作者完成。

附录 A 完整数据审计表

附录 B 关键参数与敏感性结果

附录 C 程序代码