



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

中南大学

参赛队号

20250900001

队员姓名

1.

彭铸

2.

阳挺

3.

郑徐瀚宇

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： 全国研究生数学建模竞赛论文标题

摘 要：

本文围绕数据质量、领域配比、广义标度律、算力约束下的资源配置及现实模型能力演进建立统一分析框架。问题四通过来源偏差不变的 Loss-Benchmark 桥接，将前三问最优损失映射到现实能力尺度；在共同支持边界外采用部分识别而非点外推，并在统一状态方程下分析算力放缓时的未来能力前沿及其不确定性来源。

目录

一、 问题重述	4
1.1 问题背景	4
1.2 问题重述	4
1.3 总体技术路线	5
二、 基本假设与符号说明	5
2.1 基本假设	5
2.2 符号说明	5
三、 数据说明与预处理	6
3.1 数据来源及可信度分层	6
3.2 数据口径统一	6
3.3 训练、检验及外推数据划分	6
四、 问题一：数据质量评价、冲突消解及领域配比	6
4.1 数据质量评价	6
4.1.1 质量信号统一表征与方向审计	7
4.1.2 域均衡层次质量评价	7
4.1.3 质量评价结果与一致性检验	8
4.2 质量冲突消解	10
4.2.1 质量冲突的域感知识别	10
4.2.2 冲突证据的可靠性重加权	11
4.2.3 冲突消解效果及稳健性	11
4.3 领域配比-Loss 关系	11
4.3.1 配比数据标准化及质量先验检验	12
4.3.2 配比-Loss 响应的预测与解释模型	12
4.3.3 领域份额替换及互补结构	12
4.3.4 配比规律的跨尺度迁移边界	13
五、 问题二：广义标度律及语料规模-质量、配比替代	14
5.1 经典标度律的局限与语料规模-质量、配比分析	14
5.2 广义标度律设计与参数辨识	15
5.2.1 经典标度律的参数辨识模型建立与验证	15
5.2.2 广义标度律的设计	17
5.2.3 广义标度律的参数辨识模型建立与验证	19
5.3 广义标度律指导下的语料规模-质量、配比替代	21
5.3.1 广义标度律各因素边际效用与弹性分析	21
5.3.2 广义标度律指导下的语料规模-质量、配比替代	22
5.3.3 广义标度律的质量、配比替代边界	23
六、 问题三：算力约束下的联合资源配置	24
6.1 问题分析与联合资源模型	24
6.1.1 数据接口与变量定义	24

6.1.2	配方响应与质量桥接	25
6.1.3	成本函数与完整优化模型	26
6.2	求解方法与实验设计	26
6.2.1	资源替代关系	26
6.2.2	数值求解与可行域复核	27
6.2.3	实验矩阵	27
6.3	资源配置结果与结构性转移	28
6.3.1	联合收益与逐域代价	28
6.3.2	配方支持域与典型配置	29
6.3.3	上下文、成本与结构状态	31
6.4	稳健性检验与问题三结论	32
6.4.1	有限情景的稳健配置	32
6.4.2	求解器复算与适用范围	33
七、	问题四：技术演进分解及能力前沿预测	33
7.1	开放权重模型综合能力度量	34
7.1.1	开放权重模型的多维能力统一表征	34
7.1.2	基于滚动分位的能力前沿构建	35
7.1.3	能力前沿的逐任务与多口径检验	35
7.2	Loss-Benchmark 能力映射	36
7.2.1	桥接样本的可比性分层	36
7.2.2	来源偏差不变的单调能力桥接	36
7.2.3	分层留出验证与映射误差评估	37
7.3	规模扩张与非规模技术进步贡献分解	37
7.3.1	基于滚动分位的训练算力前沿构建	37
7.3.2	机制锚定的规模能力反事实	38
7.3.3	支撑边界感知的贡献部分识别与稳健性	38
7.4	算力放缓下的能力前沿预测	40
7.4.1	算力平台-技术漂移的双状态演化	40
7.4.2	历史-预测统一的能力前沿推演	40
7.4.3	预测不确定性的来源归因	40
7.4.4	条件模拟传播与滚动起点回测	41
八、	结论、局限与推广	42
	参考文献	43
	附录 A 完整数据审计表	43
	附录 B 关键参数与敏感性结果	43
	附录 C 程序代码	43

一、 问题重述

1.1 问题背景

大语言模型的性能改进通常伴随参数规模、训练数据量和计算量的增长。经典标度律用 $L(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 描述模型参数量 N 、训练 Token 数 D 与验证损失 L 的关系，为比较不同规模投入提供了基准。然而，该关系将 Token 主要视为数量资源：若两份语料具有相同的 Token 数，却在事实准确性、噪声水平、知识覆盖和领域结构上存在差异，仅用 D 难以解释其训练效果的差别。随着高质量语料获取难度增加，数据的有效性与组成不再只是预处理细节，而成为影响规模收益的重要因素。

算力约束使这一差异具有直接的资源配置意义。扩大模型、延长训练、筛选或改善语料质量都需要成本；领域配比的改变虽未必增加总 Token 数，却会重新分配训练预算，使不同评估目标获得的收益发生变化。长上下文训练还引入额外的序列相关开销，进一步压缩可用于其他投入的预算。因此，资源配置不能仅依据单一因素的降损趋势，还取决于边际收益、成本函数、预算水平及各因素之间的替代或互补关系。

此外，验证损失与下游任务能力相关，但二者并不等价：损失的改善未必在所有任务上转化为同幅度的得分提升。可用于建模的多源记录也具有不同的实验口径与证据强度，直接观测、校准生成和跨规模外推不能混为一谈。由此，需要从语料质量评价出发，建立广义资源-损失关系，并进一步研究有限算力下的最优配置及能力前沿，同时明确各结论的适用范围。

1.2 问题重述

本文围绕“有限算力如何转化为更高模型能力”这一核心问题，依次研究数据价值、训练损失、资源配置和能力前沿。四项任务既相互衔接，又对应不同的观测量和验证方式：

- 数据质量评价与领域配比建模。**多维质量信号的量纲、优劣方向和领域覆盖各不相同，首先需要将其转化为方向一致、可跨领域比较的质量评分，并明确由样本到语料及训练来源的聚合规则。当同一文本的质量指标相互矛盾时，还需定义冲突程度、分析证据可靠性并提出消解方法，检验结论在不同数据范围内是否稳定。在此基础上，针对训练来源份额非负且总和为 1 的约束，建立领域配比与验证损失的定量关系，辨别单一来源的替换效应和来源组合的互补或竞争作用。
- 广义标度律与替代条件。**不同训练轨迹及模型体系的原始损失未必处于统一尺度，需要先建立可比口径，辨识经典标度律并检验其跨轨迹、跨模型族的泛化能力。随后将整体数据质量 Q 和领域配比 $\mathbf{p}$ 纳入 N 、 D 与 L 的关系，提出可估计、可验证的广义标度律；其中质量效应与配比效应必须区分，不能从固定来源质量的配比变化中直接推断独立的质量收益。进一步计算各因素的边际降损与弹性，在给定工作点和目标损失下，推导语料质量、配比与规模投入可相互替代的条件及其外推边界。
- 算力预算下的资源联合优化。**在训练开销、质量提升开销和长上下文开销共同约束下，求解参数量、训练 Token 数、整体质量与领域配比的联合配置。上下文长度由架构与任务需求外生给定，而非与其他因素一同自由寻优；需分析其可行取值对剩余预算的挤占。比较不同质量成本形式及多个量级的算力预算，给出最优配置和性能变化，并用可检验的判据识别预算增加时资源分配是否出现结构性转移。
- 技术演进分解与能力前沿预测。**利用历史模型的发布日期、规模与多维评测记录，界定综合能力指标以及开源模型、预训练模型和对话微调模型的比较口径，分离规模扩张与非规模技术进步对能力增长的贡献。由于前三项任务以验证损失为主要结果变量，而能力前沿以评测得分衡量，还需建立两者之间的桥接关系并分析映射误差。在算力增长放缓的情景下预测未来开源模型的能力边界，同时给出时间跨度、任务差异和数据不确定性对预测的影响。

1.3 总体技术路线

二、基本假设与符号说明

2.1 基本假设

1.

2.2 符号说明

表 2.1 主要符号说明

符号	含义	使用章节
L_{mk}, L	配方 m 在评估目标 k 上的验证损失; L 为给定目标时的简写	第 4、5 节
$\mathbf{p}, p_i$	训练来源配比向量及来源 i 的份额, $\sum_i p_i = 1$	第 4、5 节
$\mathbf{Q}^{(17)}$	问题一由校正质量映射得到的 17 域来源质量向量	第 4、5 节
x_{ij}, s_{ij}	样本 i 的第 j 项原始质量信号及方向统一后的表示	第 4 节
F_j^{bal}	第 j 项质量信号的域均衡经验分布	第 4 节
$\mathcal{P}, \mathcal{N}, \mathcal{M}$	正向、负向与中心适宜指标集合	第 4 节
G_k, a_{jk}, K	信息簇、簇内指标权重及信息簇个数 ($K = 9$)	第 4 节
η_j	第 j 项信号的领域间方差占比	第 4 节
$Q_i^{(0)}, Q_i^*$	样本 i 的初始质量分数与冲突校正质量分数	第 4 节
r_{ij}, I_{ij}, C_i	标准化异常度、冲突指示变量及样本冲突度	第 4 节
R_{ij}, U_i	指标证据可靠度及样本的信息簇平均可靠度	第 4 节
z_{mk}	按评估目标标准化后的验证损失	第 4 节
$\phi(\mathbf{p})$	13 个评估目标的总体配比表现, 越大越优	第 4 节
$S_{i \leftarrow j}, C_{ij}^{\text{mix}}$	来源份额的边际替换效应及两来源互补指数	第 4 节
ρ_s	Spearman 等级相关系数; 不作组成响应幅度使用	第 4 节
N, D, C	模型参数量、训练 Token 数及总 FLOPs 预算; 训练项为 $C_{\text{train}} = 6ND$	第 5、6 节
E, A, B	不可约损失及参数项、数据项的幅度系数	第 5 节
α, β	参数量与数据量的经典标度指数	第 5 节
$a_j, b_j, \tilde{L}$	来源 j 的损失仿射校准系数及归一化损失	第 5 节
ξ, ω_j, J_m	验证难度指数、来源验证权重及候选结构评分	第 5 节
$Q_i, \mathbf{Q}$	通用来源质量及其向量; 本文 17 域实例取 $\mathbf{Q} = \mathbf{Q}^{(17)}$	第 5 节
$\varphi(\mathbf{Q}, \mathbf{p})$	逐目标的组成损失修正; 不同于 $\phi(\mathbf{p})$	第 5 节
$w_i, w_{\text{clr}, i}$	质量加权份额与相对配比特征的有效系数	第 5 节
$\text{clr}_\varepsilon(\mathbf{p})$	加伪计数 ε 的中心化对数比变换	第 5 节
N_0, D_0	广义律的首个规模归一化锚点	第 5 节
$\eta, \zeta, M(N, D)$	组成响应的规模指数及调制因子 $M = (N/N_0)^{-\eta}(D/D_0)^{-\zeta}$	第 5 节
κ_s, b_s	锚点 s 的组成响应幅度及规模基线损失	第 5 节
Q, Q_0, Q_1	整体质量等级及比较点 $Q_0 = 0.6, Q_1 = 0.7$; 非样本质量 $Q_i^{(0)}$	第 5 节
γ_Q	独立质量实验标定的整体质量指数	第 5 节
$D_\star, \mathbf{p}_0$	等损失替代的 Token 工作点及参考配比; $D_\star \neq D_0$	第 5 节
g_x, ϵ_x	因素 x 的边际降损与损失弹性	第 5 节

表 2.1 (续)

符号	含义	使用章节
$L_{\text{ctx}}, \eta_{\text{attn}}$	外生上下文长度及注意力成本系数; $C_{\text{attn}} = \eta_{\text{attn}} N D L_{\text{ctx}}$	第 6 节
$Q_{\text{base}}, Q, h(Q)$	第三问治理基线质量、治理决策质量及单位 Token 增量治理成本	第 6 节
$C_Q, C_{\text{used}}, a, s_Q$	质量治理成本、实际总成本、合并系数 $a = 6 + \eta L_{\text{ctx}}$ 及治理成本份额	第 6 节

三、 数据说明与预处理

3.1 数据来源及可信度分层

本文按证据功能而非文件顺序组织数据。语料质量评价以多维质量信号抽样及扩展记录 (A1–A3) 为基础; 领域配比与验证损失由成对的训练表 (A4、A5) 建立关联, 并以同尺度及跨尺度检验表 (A6–A11) 评估泛化。更大规模的配比与损失表 (A12–A15) 属于子集配方和外推估计, 仅用于考察趋势的稳健性; 跨领域质量映射采用参考对应关系 (A16), 其不确定性在解释时保留。

规模基线锚定于真实训练日志 (B1), 再以半合成的族外日志 (B2)、插值轨迹 (B3)、跨模型族观测 (B4) 及文献数据 (B5) 进行分层检验。独立质量变化由校准生成的质量实验 (B6、B7) 提供; 含大规模推算的扩展表 (B8) 不作为直接观测验证。超大模型的参数资料与预估损失 (B9、B10) 也分别承担情景设定和外推对照的角色, 不能混作同等级证据。能力演进分析可依托多维排行榜及其替代版本 (C1、C2)、时序记录 (C3)、模型元数据 (C4)、损失–评测桥接样本 (C5、C6) 和逐任务结果 (C8); 上下文长度的可行范围则参考架构元数据 (C7)。上述来源在建模中分别用于估计、验证或情景分析, 半合成、插值与估算结果均不等同于独立实测。

3.2 数据口径统一

3.3 训练、检验及外推数据划分

四、 问题一：数据质量评价、冲突消解及领域配比

附件 A 包含两类相互衔接的数据, A1–A3 给出语料的多维质量信号, A4–A15 给出不同领域配方及其验证损失。本问依次解决三个层次的问题。首先在七域样本不均衡条件下构造初始质量 $Q^{(0)}$; 随后依据各领域内部的正常指标关系识别异常评价证据, 并校正其权重得到 Q^* ; 最后在单纯形约束下建立 17 域训练配比对 13 域验证 Loss 的联合响应。 Q^* 经 A16 映射为来源质量向量 $\mathbf{Q}^{(17)}$, 并与总体配比效应 $\phi(\mathbf{p})$ 一同作为问题二的数据侧输入。

4.1 数据质量评价

A1 含 51,230 条样本、7 个领域和 22 项质量信号; A2、A3 分别是 arxiv 和 github 的扩展抽样集合, 各含 17,523 条和 203,752 条样本, 并完整包含 A1 对应领域的 1,419 条与 10,000 条样本。A2、A3 采用与 A1 相同的字段口径和采集来源, 因此可用于检验 A1 的抽样代表性。综合评价面临三项结构性困难, 即七域样本量差异显著、多项评价信号存在重复信息, 以及部分文本结构指标具有合理区间而非简单单调关系。针对这三点, 依次进行质量信号统一表征、域均衡标度、信息簇合成和人工一致性检验。

4.1.1 质量信号统一表征与方向审计

22 项信号包含 8 个列表字段和 14 个标量字段。列表字段按原始含义先行标量化，二分类 logits 经 softmax 转为目标类别概率，六级有序 logits 取期望等级并按 5 归一化，QuRating 的四个异质量纲分量先分别作百分位变换再取均值。原始数据完整性良好，仅 modernbert_reasoning 与 modernbert_professionalism 分别出现 13 条和 5 条无效 logits，以所属领域的中位数填补，占总样本比例不足 0.04%。

标量化只解决量纲不一致，并不解决方向不一致。为统一综合分数的含义，本文对 22 项信号逐一登记方向，分为正向、负向和中心适宜三类，最终仅 WordLength、Sentences、WordCount、Entropy 与 Uppercase 设为中心适宜，其余按单调方向处理；方向设定的依据与消融见 4.1.3 节。表 4.3 汇总 22 项信号的短名、含义、字段形态、标量化方式以及统一表示 s_{ij} 的分布特征，信息簇归属与方向判定见图 4.1。

表 4.3 22 项质量信号的统一表征与分布特征

信号短名	含义	字段形态	标量化方式	$\bar{s}$	σ_s	η_j
NoAlpha	非字母词比例	标量	直接使用	0.516	0.310	0.49
Uppercase	大写字母比例	标量	直接使用	0.835	0.280	0.47
TermPunct	句末标点比例	标量	直接使用	0.498	0.298	0.60
Ad-Prob	无广告概率	列表 2	softmax 取 $P(\text{no-ad})$	0.491	0.291	0.20
MB-Reason	推理性	列表 6	期望等级 /5	0.404	0.251	0.60
UniqueWords	词汇多样性	标量	直接使用	0.624	0.224	0.62
DSIR-Math	数学域倾向	标量	直接使用	0.626	0.223	0.64
DSIR-Books	书籍域倾向	标量	直接使用	0.625	0.225	0.63
DSIR-Wiki	维基域倾向	标量	直接使用	0.626	0.223	0.64
FineWebEdu	教育价值	列表 1	取列表唯一评分	0.447	0.279	0.24
MB-Prof	专业性	列表 6	期望等级 /5	0.452	0.268	0.69
Fluency	语言流畅度	列表 2	softmax 取 $P(\text{fluent})$	0.477	0.293	0.30
QuRating	综合文本质量	列表 4	四分量分位均值	0.447	0.203	0.39
MB-Clean	洁净度	列表 6	期望等级 /5	0.435	0.283	0.44
MB-Read	可读性	列表 6	期望等级 /5	0.434	0.292	0.38
WordLength	平均词长	标量	直接使用	0.795	0.311	0.31
Numerical	数字字符比例	标量	直接使用	0.461	0.290	0.16
Sentences	句子数	标量	直接使用	0.857	0.270	0.38
WordCount	词数	标量	直接使用	0.858	0.271	0.42
Entropy	一元词熵	标量	直接使用	0.855	0.272	0.40
Top2Gram	二元重复集中度	标量	直接使用	0.420	0.282	0.27
Top3Gram	三元重复集中度	标量	直接使用	0.444	0.306	0.18

注：字段形态中“列表 m ”表示该字段为长度 m 的列表； $\bar{s}$ 与 σ_s 为统一表示 s_{ij} 在 A1 全样本上的均值与标准差； η_j 为指标 j 的领域间方差占比；中心适宜指标在中间 60% 分位区间取满分，其 $\bar{s}$ 相应偏高。表内按信息簇 C1–C9 分组排列。

4.1.2 域均衡层次质量评价

A1 中 book 仅 171 条、arxiv 为 1,419 条，而 c4、github、stackexchange、wikipedia 均接近 10^4 条。若以全样本经验分布作为统一标尺，大样本领域将获得更高权重；若分别在域内归一化，则会抹去域间真实差异。因此，对指标 j 在领域 d 内建立经验分布 F_{jd} ，并令七个领域等权参与公共参考尺度，即

$$F_j^{\text{bal}}(x) = \frac{1}{7} \sum_{d=1}^7 F_{jd}(x). \quad (4.1)$$

在此基础上，将不同方向的指标统一为 $s_{ij} \in [0, 1]$ ，具体形式为

$$s_{ij} = \begin{cases} F_j^{\text{bal}}(x_{ij}), & j \in \mathcal{P}, \\ 1 - F_j^{\text{bal}}(x_{ij}), & j \in \mathcal{N}, \\ \min\left\{\frac{F_j^{\text{bal}}(x_{ij})}{0.20}, \frac{1 - F_j^{\text{bal}}(x_{ij})}{0.20}, 1\right\}, & j \in \mathcal{M}, \end{cases} \quad (4.2)$$

其中 $\mathcal{P}, \mathcal{N}, \mathcal{M}$ 分别表示正向、负向和中心适宜指标集合。中心适宜函数在中间 60% 分位区间取满分，仅对结构极端样本进行惩罚。

统一表征后，以域均衡权重计算 22 项信号的 Spearman 相关矩阵，并以 $1 - |\rho|$ 为距离进行层次聚类。综合轮廓系数和 120 次分层 bootstrap 的配对稳定度，数据驱动选择 $K = 9$ 个信息簇。对第 k 个信息簇 G_k ，以簇内绝对相关矩阵的最大特征向量形成非负权重 a_{jk} ；不同簇之间采用等权，即

$$H_{ik} = \sum_{j \in G_k} a_{jk} s_{ij}, \quad Q_i^{(0)} = \frac{1}{K} \sum_{k=1}^K H_{ik}, \quad K = 9. \quad (4.3)$$

这种层次合成先在同类信号中提取共识，再汇总不同质量语义，从而削弱重复评价对综合分数的影响。图 4.1 表明，域均衡相关矩阵呈明显的簇状结构，顶部色带给出信息簇归属，右侧给出领域间方差占比 η_j 与指标方向。多个 DSIR 与模型评分信号的 η_j 超过 0.60，说明其变化更多来自领域身份而非通用质量，因此这些指标只参与综合评价，不单独解释为领域质量的因果来源。




图 4.1 22 项质量信号的冗余结构与领域异质性

4.1.3 质量评价结果与一致性检验

领域级质量以域内 $Q_i^{(0)}$ 的均值表示，并在固定评价规则下采用分层 bootstrap 构造 95% 置信区间。表 4.4 给出七域点估计、分布中心和同源扩展检验，图 4.2 则展示领域排序及方向假设的主要证据。

表 4.4 七域初始质量评价及同源扩展检验

领域	n	A1 均值	95% CI	ΔQ	W_1
arxiv	1,419	0.7076	[0.7055, 0.7098]	-0.001740	0.002437
commoncrawl	9,640	0.6056	[0.6043, 0.6067]	—	—
stackexchange	10,000	0.6024	[0.6011, 0.6038]	—	—
wikipedia	10,000	0.5950	[0.5934, 0.5968]	—	—
c4	10,000	0.5548	[0.5529, 0.5566]	—	—
book	171	0.4994	[0.4875, 0.5115]	—	—
github	10,000	0.4786	[0.4771, 0.4802]	-0.000054	0.000384
总体		$Q_{\text{micro}} = 0.5707$		$Q_{\text{macro}} = 0.5776$	

注：A1 均值为初始质量 $Q^{(0)}$ 的域内均值，95% CI 由分层 bootstrap 给出； ΔQ 为 A2/A3 全量均值减 A1 对应领域均值， W_1 为 Wasserstein 距离。A2/A3 与 A1 同源，因此该结果用于检验抽样代表性。

arxiv 的平均 $Q^{(0)}$ 最高，github 最低。github 的人工审阅相关仅为 0.071，明显低于其他领域，说明代码和技术文本与现有评价信号之间存在较强的领域失配；因此该排名仅表示统一评价口径下的相对位置，不作语料本身优劣的绝对判断。A1 的微平均与宏平均接近，说明样本量不平衡未改变总体水平判断；book 样本量最小，其置信区间也最宽。冻结 A1 的标量化规则、公共 ECDF、信息簇及簇内权重后应用于 A2/A3，arxiv 和 github 的均值差分别仅为 -1.74×10^{-3} 和 -5.4×10^{-5} ，对应的 Wasserstein 距离也很小，表明 A1 对两类同源扩展集合具有较好的代表性。

方向设定与聚合方式的消融结果见表 4.5。最终“五中心”方案在保持七域排序稳定的同时，将 210 条分层人工复核与 $Q^{(0)}$ 的 Spearman 相关提高到 0.666；全部结构指标均按正向处理时，七域排序相关降至 0.429。等权与 CRITIC 与本文方法的样本排序相关分别为 0.901 和 0.920，说明主要质量结构具有较高共识；全局 PCA 的一致性明显较低，说明直接以单一主成分压缩 22 项信号会损失部分质量语义。

表 4.5 质量评价方案的消融与一致性检验

检验类型	方案	七域排序	样本排序	人工审阅
方向设定	旧八中心方案	1.000	0.880	0.616 [0.54, 0.68]
	最终五中心方案	1.000	1.000	0.666 [0.61, 0.72]
	中心指标减为四个	0.893	0.993	0.656 [0.60, 0.71]
	全部按正向处理	0.429	0.772	0.634 [0.56, 0.70]
聚合基线	等权	0.929	0.901	0.619 [0.55, 0.69]
	CRITIC	0.929	0.920	0.625 [0.55, 0.69]
	全局 PCA	0.750	0.622	0.449 [0.36, 0.53]

注：三列均为 Spearman 相关 ρ_s ；人工审阅列为 210 条分层样本上的 95% 分层 bootstrap 区间，样本按领域与质量层次分层抽取，排序相关均以最终五中心方案为基准。

表 4.5 的人工审阅列同时给出 210 条复核样本上的 95% 分层 bootstrap 区间。最终五中心方案相对 CRITIC、等权和旧八中心方案的审阅相关差值分别为 0.041、0.047 和 0.050，区间分别为 [0.009, 0.073]、[0.013, 0.080] 和 [0.017, 0.083]，均不包含 0，说明方向审计与层次合成带来的提升不是抽样噪声，但幅度有限。相对“中心指标减为四个”的差值为 0.010，区间 [-0.003, 0.022] 包含 0，二者在人工一致性上不可区分，保留中心五指标的意义在于




图 4.2 七域质量评价结果与评价规则可信度

不丢失结构语义；相对“全部按正向处理”的差值区间同样包含 0，该方案的决定性缺陷体现在七域排序相关由 1.000 降至 0.429。

由此得到的 $Q^{(0)}$ 保留了样本间的质量次序和域间差异，可作为下一节冲突校正的基准分数；其数值用于统一评价口径下的相对比较。

4.2 质量冲突消解

$Q^{(0)}$ 的合成默认各项质量证据均可直接使用，但特殊文本可能使个别评价器偏离该领域的常见关系。因此，本文把“正常的多维差异”与“异常的不一致”分开处理。只有当某项观测显著偏离同域相关信号所预测的正常水平时，才记为质量冲突；随后降低该项证据在综合评价中的权重。

4.2.1 质量冲突的域感知识别

以上一节的域均衡相关结构为基础，仅保留 $|\rho| \geq 0.10$ 且在 300 次分层 bootstrap 中稳定率不低于 0.95 的指标关系，共得到 135 条稳定边。对每项指标，用其稳定邻居和领域信息建立 Elastic Net 预测器，并按七域进行 5 折 cross-fitting，使每个样本的条件期望均由未包含该样本的训练折给出。记交叉预测残差为 $e_{ij} = s_{ij} - \hat{s}_{ij}^{(-i)}$ ，并在所属领域内按 MAD 标准化。若异常度进入对应“指标-领域”经验残差分布的上 2.5% 尾部，则置 $I_{ij} = 1$ 。样本级冲突度同时计入异常覆盖范围和异常强度，即

$$\begin{aligned}
 r_{ij} &= \frac{|e_{ij}|}{1.4826 \text{MAD}_{d_i}(e_{\cdot j}) + \varepsilon}, \\
 p_{ij}^{\text{conf}} &= 1 - F_{j, d_i}^R(r_{ij}), \quad I_{ij} = \mathbf{1}\{p_{ij}^{\text{conf}} < 0.025\}, \\
 C_i &= \sqrt{\left(\frac{1}{22} \sum_j I_{ij}\right) \left(\frac{\sum_j I_{ij} r_{ij}}{\sum_j I_{ij} + \varepsilon}\right)}.
 \end{aligned} \tag{4.4}$$

该定义以各指标在各领域中的正常波动为参照，因此不会把代码、公式密集文本等领域特征仅因数值差异而判为冲突。

4.2.2 冲突证据的可靠性重加权

冲突不直接从样本总分中扣除，而是作用于对应证据的可靠度。设 τ_{j,d_i} 为指标 j 在领域 d_i 的冲突阈值，定义

$$R_{ij} = \begin{cases} 1, & I_{ij} = 0, \\ \exp\{-0.5(r_{ij} - \tau_{j,d_i})_+\}, & I_{ij} = 1, \end{cases} \quad Q_i^* = \sum_{k=1}^K v_{ik}^* H_{ik}, \quad v_{ik}^* = \frac{\sum_{j \in G_k} a_{jk} R_{ij}}{\sum_{\ell=1}^K \sum_{h \in G_\ell} a_{h\ell} R_{ih}}. \quad (4.5)$$

各信息簇可靠度的均值记为 U_i 。当不存在冲突时， $v_{ik}^* = 1/K$ ，故 $Q_i^* = Q_i^{(0)}$ ；出现局部异常时，仅相应信息簇的权重发生变化。

4.2.3 冲突消解效果及稳健性

冲突校正后， Q^* 与 $Q^{(0)}$ 的全样本 Spearman 为 0.9992，说明总体质量次序基本保持不变；但修正量明显向高冲突样本集中。Top 10%、Top 5% 和 Top 1% 冲突样本的 $|Q^* - Q^{(0)}|$ 中位数分别为 0.00435、0.00655 和 0.0118，且 Top 10% 样本贡献了 64.8% 的总绝对修正量。图 4.3 中的分箱中位线进一步显示，冲突程度升高后修正幅度呈持续上升趋势。




图 4.3 冲突修正的局部性与异常来源

高严重度冲突主要集中在 Entropy、Sentences、Uppercase、WordCount 和 WordLength 等结构信号，表明异常主要来自文本结构偏离所属领域的常态。最新结果中 GitHub 的平均冲突度最高 (0.180)，Book 最低 (0.138)；这里的领域差异反映评价证据的一致性，而不用于比较领域质量高低。将 A1 学得的关系结构、残差尺度和阈值冻结后应用于 A2/A3，严重冲突仍集中在同类结构信号。作为对照，本文冲突度与“指标方差”和“最大两两差”的 Spearman 仅为 0.132 和 0.172；当显著性阈值在 0.01–0.10、可靠性衰减系数在 0.3–1.0 内变化时， Q^* 排序与主方案的 Spearman 始终不低于 0.994。因此，冲突校正主要影响高冲突尾部，并未改变质量评价的主体结构。第二小问最终输出 (Q_i^*, U_i, C_i) ，分别记录修正后的质量、证据可信度和冲突程度。

4.3 领域配比–Loss 关系

A4/A5 提供 512 组 1M 训练配方及其 13 域验证 Loss；A6/A7 为 1M 同尺度真实检验，A8/A9 和 A10/A11 分别提供 60M、1B 真实检验，A12–A15 为 10B、70B 外推表。17 个训练比例满足 $p_i \geq 0$ 、 $\sum_i p_i = 1$ ，而 13 个验证域的 Loss 基准不同，因此建模时需同时处理单纯形约束、多输出响应和跨尺度迁移。

4.3.1 配比数据标准化及质量先验检验

不同验证域的 Loss 先在 A5 内按验证域进行中位数–MAD 标准化，再定义总体配比表现，即

$$z_{mk} = \frac{L_{mk} - \text{median}(L_{\cdot k})}{1.4826 \text{ MAD}(L_{\cdot k})}, \quad \phi(\mathbf{p}) = -\frac{1}{13} \sum_{k=1}^{13} \hat{z}_k(\mathbf{p}). \quad (4.6)$$

$\phi(\mathbf{p})$ 越大，表示该配方在 13 个验证域上的总体表现越优。

第二小问得到的七域 Q^* 经 A16 映射到 17 个训练域，记为 $\mathbf{Q}^{(17)} = (Q_1^{(17)}, \dots, Q_{17}^{(17)})$ 。由于 $\sum_i p_i Q_i^{(17)}$ 是 $\mathbf{p}$ 的确定函数，直接作为额外线性项会与配比变量共线。因此以指数倾斜 $\tilde{p}_i(\gamma) \propto p_i \exp[\gamma(Q_i^{(17)} - \bar{Q})]$ 检验质量先验。交叉验证的最优值为 $\gamma = 0$ ，且 $\gamma > 0$ 时误差略有增加，说明 A4/A5 无法把“领域身份”与“领域质量”的独立作用分开识别。本小问据此不引入质量先验，质量的独立边际效应转由校准生成的质量变化实验 (B6、B7) 估计；大规模扩展结果 (B8) 仅用于审视外推边界。

4.3.2 配比–Loss 响应的预测与解释模型

为显式刻画领域及领域组合的作用，对第 k 个验证域建立二阶 Scheffé 混合响应

$$\hat{z}_k(\mathbf{p}) = \sum_{i=1}^{17} \beta_{ik} p_i + \sum_{1 \leq i < j \leq 17} \gamma_{ijk} p_i p_j, \quad k = 1, \dots, 13. \quad (4.7)$$

17 个主效应和 136 个交互项在 13 个任务上联合拟合，以组稀疏约束筛选跨任务稳定结构，并用 Ridge 项稳定相关系数；一阶 Scheffé 和 ILR–Ridge 作为对照。1M 真实检验结果见表 4.6。

表 4.6 1M 真实检验集上的配比响应模型比较

模型	平均 RMSE	平均 R^2	MAE	用途
一阶 Scheffé	0.522	0.619	0.435	线性混合基准
多任务稀疏 Scheffé	0.444	0.710	0.361	机制解释
ILR–Ridge	0.420	0.765	0.337	数值预测

注：RMSE、 R^2 、MAE 均为 13 个验证任务的平均值；总体宏观配比指标 G 在 1M 检验集上的 R^2 为 0.391。

ILR–Ridge 的点估计最优；重复 5 折交叉验证下，其相对多任务 Scheffé 的 R^2 差值均值为 0.038，95% CI 为 $[-0.012, 0.081]$ ，区间包含 0。因此后续数值预测采用 ILR–Ridge，领域替换和交互机制采用多任务稀疏 Scheffé 解释，两类模型分别承担预测和机制分析任务。

4.3.3 领域份额替换及互补结构

在单纯形约束下，“增加领域 i ” 必然伴随其他领域份额减少，因此主效应系数不能直接解释为独立边际收益。在参考配比 $\mathbf{p}$ 附近，定义从领域 j 向领域 i 转移份额的边际效应和两领域的总体互补指数，即

$$S_{i \leftarrow j}(\mathbf{p}) = \frac{1}{13} \sum_{k=1}^{13} \left(\frac{\partial \hat{z}_k}{\partial p_i} - \frac{\partial \hat{z}_k}{\partial p_j} \right), \quad C_{ij}^{\text{mix}} = -\frac{1}{13} \sum_{k=1}^{13} \gamma_{ijk}. \quad (4.8)$$

$S_{i \leftarrow j} < 0$ 表示在当前配比附近将份额从 j 转移到 i 有助于降低总体 Loss； $C_{ij}^{\text{mix}} > 0$ 表示两域共同出现时的 Loss 低于线性混合预期。前者描述份额替换，后者描述非加性交互。

为控制稀疏配方造成的大系数伪影，正文只解释同时满足三项条件的关系，即两域训练覆盖充分、bootstrap 符号稳定率不低于 0.95、效应量位于训练支持范围。约 52% 的替换关系和 46% 的互补关系通过该门槛。通过门槛的关系中，DM-Math $\rightarrow$ HackerNews 的替换效应为 -2.68 ，显示稳定的 Loss 改善信号；arXiv-GitHub 则表现出稳定互补。相反，enron_emails 的平均份额仅 0.0022、最大份额 0.026、非零占比 0.31，其大幅替换效应超出充分支持范围，因此不进入机制结论。图 4.4 将替换矩阵和通过资格门槛的互补/冗余关系合并展示，灰色斜线区域表示证据不足。




图 4.4 领域配比的替换机制与互补结构

4.3.4 配比规律的跨尺度迁移边界

同尺度预测精度不能直接代表跨规模可迁移性，因此分别考察配比空间外推和模型规模迁移。在配比空间内，以 Hellinger 距离衡量测试配方到最近训练配方的距离。1M 检验集最近邻距离的中位数为 0.299，90% 分位数为 0.375，且预测误差随距离增大而整体上升，说明模型的机制解释应限制在训练配方支持区域附近。

模型规模迁移通过不同尺度下的配方排序一致性衡量。表 4.7 和图 4.5 显示，60M 和 1B 的 Spearman 相关分别为 0.810 和 0.608，均保持为正，但随规模扩大明显减弱；10B、70B 的 Loss 为较小规模幂律外推结果，其排序相关和预测-观测斜率均转为负值。因此，现有数据支持真实 1M–1B 范围内的有限迁移，不支持将小模型上的配比规律视为尺度不变关系。

问题一最终得到三类后续输入，即冲突修正质量 Q^* 、映射到 17 个训练域的质量描述 $Q^{(17)}$ 以及总体配比效应 $\phi(\mathbf{p})$ 。替换效应 $S_{i \leftarrow j}$ 和互补指数 C_{ij}^{mix} 用于解释领域结构， U 与 C 用于记录质量评价中的不确定性。问题二将在此基础上融合附件 B，建立含参数规模、数据量、质量和领域结构的广义标度关系。

表 4.7 领域配比效应的跨尺度一致性

模型规模	数据性质	样本数	排序相关 ρ_s	两两一致率	回归斜率
60M	真实检验	256	0.810	0.805	0.912
1B	真实检验	64	0.608	0.711	0.348
10B	外推 Loss	63	-0.584	0.293	-0.339
70B	外推 Loss	63	-0.617	0.279	-0.370

注：排序相关为各尺度配方排序与 1M 预测排序的 Spearman 相关，两两一致率为配方两两比较方向一致的比例，回归斜率为预测-观测回归的斜率；10B/70B 的 Loss 来自小规模实验的幂律外推，仅用于识别尺度失效边界，不作为真实大模型训练验证。




图 4.5 配比模型的预测有效域与跨尺度迁移边界

五、 问题二：广义标度律及语料规模-质量、配比替代

5.1 经典标度律的局限与语料规模-质量、配比分析

经典标度律通常将训练 Token 视为同质资源，重点描述参数规模和数据规模对模型损失的影响。然而，随着高质量语料逐渐稀缺，不同数据在信息密度、噪声水平、知识覆盖和任务相关性方面呈现出显著差异，单纯增加参数量或训练 Token 数已不足以准确解释模型能力的增长规律。如果忽略这种数据异质性，模型不仅会高估低质量数据的边际价值，还会掩盖领域结构失衡造成的性能瓶颈，从而难以回答数据质量提升、领域配比调整与模型规模扩张之间能否相互替代这一关键问题。因此，将数据质量和领域配比纳入标度律，是从“规模驱动”转向“规模与数据价值协同驱动”的必要拓展，也是实现有限算力下精细化资源配置的理论基础。

数据结构决定了这一拓展不能简单地用一个质量系数修正训练 Token 数。设训练数据来自 m 个领域，配比 $\mathbf{p}$ 满足 $p_i \geq 0$ 与 $\sum_{i=1}^m p_i = 1$ ，任一来源份额的增加必然挤占其他来源。来源质量 Q_i 由问题一的数据分级给定；在本文的 17 域实例中， $Q_i = Q_i^{(17)}$ ，并在现有配比实验中保持固定。若把完整配比压缩为平均质量 $\sum_i p_i Q_i$ 或单一有效数据量，质量等级相同但知识内容不同的来源将无法区分，跨评估目标的差异化响应也会被掩盖。同时，固定的 Q_i 与来源身份交织，不能仅凭这些实验识别独立提高质量的效应。可观测的模型-数据规模组合较少，不同体系的原始损失又存在尺度偏移，因此盲目增加交互项或

直接混合损失均会削弱参数的可辨识性。

基于上述约束，本文采用“经典规模基线—组成响应—独立质量校准”的分层建模框架。首先，对多来源损失进行尺度归一化，利用自适应结构早停识别稳健的经典标度指数。随后针对任意评估目标，在规模基线上叠加配比响应项，以质量加权份额 $p_i Q_i$ 表示分级质量与投入的联合暴露，以中心化对数比特特征刻画单纯形上的相对组成，并允许响应幅度随 N 、 D 变化。问题一的 $\phi(\mathbf{p})$ 表示越大越优的总体配比表现；为避免混淆，问题二把进入损失式的逐目标组成修正记为 $\varphi(\mathbf{Q}, \mathbf{p})$ ，两者不作数值等同。该设计保留了经典标度律对规模收益递减的解释，同时允许相同质量等级的不同来源产生不同的损失变化。受规模锚点数量限制，扩展模型沿用前述经典指数，而不从配比实验中重新辨识所有规模参数。

5.2 广义标度律设计与参数辨识

5.2.1 经典标度律的参数辨识模型建立与验证

为刻画模型规模、训练数据量与验证损失之间的基本数量关系，本文以真实训练日志 (B1) 辨识经典标度律，并将族外日志、插值轨迹及跨族和文献样本 (B2–B5) 保留为不同层级的检验证据。所采用的经典形式为

$$L(N, D) = E + AN^{-\alpha} + BD^{-\beta}, \quad (5.9)$$

其中， N 表示模型参数量， D 表示训练 Token 数， L 表示验证集交叉熵损失。 E 是规模趋于充分时仍无法消除的不可约损失， A 与 B 分别控制参数规模项和数据规模项的幅度， α 与 β 则刻画两类资源的边际收益衰减速度。为保证模型具有明确的物理含义，估计过程中施加

$$0 \leq E < \min_i L_i, \quad A > 0, \quad B > 0, \quad \alpha > 0, \quad \beta > 0 \quad (5.10)$$

等约束。由式 (5.9) 可知，随着 N 或 D 增大，预测损失单调下降，但改善幅度逐渐减小，因而能够自然描述大模型训练中的收益递减现象。

损失尺度归一化 不同模型体系可能采用不同的分词器、验证语料和损失统计口径，即使其学习曲线具有相似形状，原始 Loss 的位置和尺度也可能存在系统差异。若直接比较原始损失，模型族之间的整体平移或缩放会被误判为标度结构失效。为此，本文将主拟合来源的 Loss 定义为参考尺度，并假设第 j 个外部来源的观测损失满足仿射观测关系

$$L_{ji}^{\text{obs}} = a_j + b_j L_{ji}^{\text{ref}} + \varepsilon_{ji}, \quad b_j > 0, \quad (5.11)$$

其中， a_j 描述损失基线差异， b_j 描述损失单位或动态范围差异， ε_{ji} 为无法由统一尺度解释的结构残差。相应地，将外部观测映射到参考尺度：

$$\tilde{L}_{ji} = \frac{L_{ji}^{\text{obs}} - a_j}{b_j}. \quad (5.12)$$

主拟合来源取 $a_0 = 0$ 、 $b_0 = 1$ ，因此其训练过程保持在原始可解释的 Loss 尺度上。其他来源经式 (5.12) 归一化后再参与验证与结构选择。

为防止利用同一批验证标签完成校准后又原样本上评价，本文采用按训练轨迹或模型族分簇的交叉归一化。对于待评价簇 c ，仅使用其余簇估计

$$(\hat{a}_j^{(-c)}, \hat{b}_j^{(-c)}) = \arg \min_{a \in \mathbb{R}, b > 0} \sum_{i: g(i) \neq c} \left[L_{ji}^{\text{obs}} - \left(a + b \hat{L}_{ji}^{\text{ref}} \right) \right]^2, \quad (5.13)$$

再使用 $\hat{a}_j^{(-c)}$ 和 $\hat{b}_j^{(-c)}$ 归一化留出簇。该处理只消除来源间的仿射尺度差异，不改变留出轨迹的排序、曲率和局部偏差，因而归一化后的剩余误差仍能反映标度规律的跨体系可迁移性。为保持评价透明性，本文同时保留未经校准的原始尺度误差，并将其解释为“结构误差与观测尺度偏移”的合成结果。

可分离非线性最小二乘法 式 (5.9) 对五个参数整体而言是非线性模型，但当指数 (α, β) 给定后， E 、 A 和 B 构成线性参数。令

$$\mathbf{y} = (L_1, \dots, L_n)^\top, \quad \boldsymbol{\theta} = (E, A, B)^\top, \quad (5.14)$$

并构建设计矩阵

$$\mathbf{X}(\alpha, \beta) = \begin{bmatrix} 1 & N_1^{-\alpha} & D_1^{-\beta} \\ 1 & N_2^{-\alpha} & D_2^{-\beta} \\ \vdots & \vdots & \vdots \\ 1 & N_n^{-\alpha} & D_n^{-\beta} \end{bmatrix}. \quad (5.15)$$

于是，在任意候选指数对下，内层问题可写为带物理约束的线性最小二乘

$$\hat{\boldsymbol{\theta}}(\alpha, \beta) = \arg \min_{\boldsymbol{\theta}} \|\mathbf{y} - \mathbf{X}(\alpha, \beta)\boldsymbol{\theta}\|_2^2. \quad (5.16)$$

将内层解析解代回后，原问题被压缩为仅关于两个指数的轮廓残差平方和

$$S(\alpha, \beta) = \left\| \mathbf{y} - \mathbf{X}(\alpha, \beta)\hat{\boldsymbol{\theta}}(\alpha, \beta) \right\|_2^2. \quad (5.17)$$

本文先在指数区间内设置等距节点进行粗网格搜索，再以当前最优点为中心实施局部模式搜索，并逐次将搜索步长减半，直至步长小于 10^{-7} 。相较于同时对五个参数进行无结构的非线性优化，该可分离非线性最小二乘方法将高维耦合问题转化为“外层低维指数搜索 + 内层线性求解”，既降低了初值敏感性，也便于在每个指数候选点严格检查参数正性和不可约损失边界。

自适应结构早停 指数自由度越高，越容易把数据噪声读作真实的标度结构差异，因此本文按由简到繁、以外部验证收益为准的顺序逐层释放指数自由度。第一层令 $\alpha = \beta = s$ ，对共享指数 s 进行一维搜索。第二层以第一层最优值 s^* 为锚点，分别考察“固定 $\beta = s^*$ 、释放 α ”和“固定 $\alpha = s^*$ 、释放 β ”两个并列候选。只有当单方向释放产生稳定的外部收益时，第三层才进入 (α, β) 均自由的二维搜索。每个候选指数点仍由式 (5.16) 估计 E 、 A 和 B ，因此该过程并未引入新的标度律项，而是在同一标准模型内部逐步增加指数自由度。

不同来源的可信度、判别难度与统计稳定性并不相同，因此本文不预先固定其权重。记 r_j 为可信度先验， d_j 为基准模型在该来源上的验证难度， σ_j 为按轨迹或模型族分簇 Bootstrap 得到的分数标准差，则定义稳定性因子和原始权重

$$s_j = \frac{1}{1 + \sigma_j/d_j}, \quad u_j = r_j d_j^\xi s_j, \quad (5.18)$$

并在给定上下限后将 u_j 归一化为 ω_j 。较困难但稳定、且证据可靠的来源因而获得较高权重。高度相关、半合成或波动较大的来源则不会主导结构选择。权重在比较候选结构之前一次确定并冻结，以避免针对某个候选模型事后调整评价标准。

候选结构的最终选择分数定义为

$$J_m = \sum_j \omega_j \text{MedAPE}_{jm} + \lambda \max(0, k_m), \quad (5.19)$$

其中，MedAPE 衡量归一化后的相对预测偏差， k_m 为有效自由参数数目，第二项用于要求新增指数自由度给出足以抵消复杂度增长的外部收益。候选结构首先需要满足主拟合样本上的最低拟合门槛。随后，只有当 $J_m < J_{\text{best}} - \delta$ 时，才将其视为实质改善并更新历史最优结构。

经典标度律的拟合、验证与外推 自适应结构早停最终保留参数项与数据项共享指数的简约结构，得到

$$\hat{L}(N, D) = 1.654679 + 0.425107N^{-0.293183} + 1.205248D^{-0.293183}, \quad (5.20)$$

其决定系数为 0.99938498，RMSE 为 0.00848302。释放参数规模指数仅使选模分数改善 0.000159，低于阈值 $\delta = 0.002$ ，因此不增加指数自由度。图 5.6(a) 表明，增加训练数据量或模型参数量均可降低损失，但边际收益持续递减。将资源投入统一换算为 $C = 6ND$ 后，各规模训练轨迹呈现相近的下降趋势。图 5.6(b) 中的经验下沿包络近似满足 $L = 2.2C^{-0.0665}$ ，刻画了既定计算预算下可达到的效率前沿。




图 5.6 经典标度律的资源标度与计算效率：(a) 参数规模、数据规模与验证损失的标度关系。(b) 不同参数规模下计算量与验证损失的关系，虚线为经验下沿包络。

为检验跨来源迁移能力，本文提取独立训练轨迹的最终收敛点，并采用留一轨迹或留一模型族的仿射尺度校准。表 5.8 与图 5.7(a) 显示，归一化后的四类数据均保持较高秩相关性。公开文献观测的误差相对较高，但考虑数据质量、网络结构与训练策略造成的差异，仍在标准标度律的描述范围内。

表 5.8 经典标度律的多来源样本外验证结果

验证来源	编号	样本数	原始 RMSE	归一化 RMSE	中位相对误差	归一化 R^2	Spearman 系数
独立模型族收敛终点	B2	7	0.855373	0.014636	0.70%	0.9950	1.0000
连续插值训练轨迹	B3	4000	0.011422	0.011445	0.28%	0.9996	0.9998
跨模型族实验	B4	57	0.289767	0.088138	1.57%	0.9240	0.9758
公开文献实验观测	B5	44	0.191785	0.127853	5.24%	0.7647	0.9280

图 5.7(b) 进一步给出百亿参数以上的情景外推。经典标度律在固定数据规模下预测损失随参数量缓慢下降，而大模型样本的离散程度明显更高，表明超大规模区间还受到数据质量与训练配置的显著影响。因此，该图用于界定外推趋势和风险，不作为新的外部验证证据，并为后续引入质量变量与领域配比提供依据。

5.2.2 广义标度律的设计

经典标度律揭示了参数规模与训练数据量的损失衰减规律，但其同质 Token 假设无法区分训练语料的质量和来源组成。为分析这一缺口，首先考察实验的可辨识结构，在模型规模与训练 Token 数均固定的条件下，存在数百种不同的语料配比，因而经典标度律对这




图 5.7 经典标度律的跨来源验证与大模型外推：(a) 损失尺度归一化后的多来源预测一致性，虚线为理想预测，阴影区域表示相对误差不超过 10%；(b) 百亿参数以上模型区间的标度律外推，曲线按中位训练数据量计算。

些实验给出同一预测基线，却无法解释其损失差异。另有 256 组配比在两个模型规模下逐一对应，可比较规模改变后配比响应的形状与幅度。这说明需要在规模基线之外单独建立组成响应，而非仅用总 Token 数代表全部训练数据。与此同时，观测实验仅提供三个不同的 (N, D) 规模锚点，其中较大模型的 N 与 D 同时变化。若连同组成效应重新估计全部规模指数，将产生明显的参数混淆。因此沿用前文估计的 α, β ，将新增参数集中用于刻画组成效应及其跨规模变化。

其次，训练配比属于单纯形，提高某一来源的份额必然压缩其他来源，故各 p_i 不是相互独立的投入量。仅以平均质量 $\sum_i p_i Q_i$ 概括语料，会把质量相近但知识内容不同的来源混为一谈。只用原始份额又难以直接表达来源之间的相对替代。基于这一约束，采用质量加权份额 $p_i Q_i$ 记录各来源的有效投入，并以中心化对数比刻画相对组成。但现有质量评分对每个来源固定， $p_i Q_i$ 与 p_i 在统计上不能区分独立的质量改善效应，因此这一项只表示给定质量分级下的组成暴露，不能作质量因果效应解释。

最后，逐行配对的跨规模配比为检验“响应形状相对稳定、作用幅度随规模改变”的可分离假设提供了依据。用规模幂函数调节组成响应的幅度，既与经典标度律的形式协调，也避免为每个规模重新拟合一套配比函数。以参考规模归一化该幅度，并将组成响应在参考样本上中心化，可减少其与损失截距之间的混淆。由于配比维度随来源数增长，估计时还须施加正则化以控制方差。设训练语料包含任意 m 个来源， $\mathbf{p} = (p_1, \dots, p_m)$ 满足 $p_i \geq 0$ 、 $\sum_i p_i = 1$ ， $\mathbf{Q} = (Q_1, \dots, Q_m)$ 为相应来源质量；本文实例取 $m = 17$ 和 $\mathbf{Q} = \mathbf{Q}^{(17)}$ 。对于任意给定的评估目标，由此提出统一的函数结构

$$L(N, D, \mathbf{p}, \mathbf{Q}) = E + AN^{-\alpha} + BD^{-\beta} + \left(\frac{N}{N_0}\right)^{-\eta} \left(\frac{D}{D_0}\right)^{-\zeta} \varphi(\mathbf{Q}, \mathbf{p}), \quad (5.21)$$

其中 (N_0, D_0) 为首个观测规模锚点。 E, A 和 B 决定损失基线， α, β 为规模指数， η, ζ 刻画组成响应随规模变化的程度。两个规模比值在参考规模均为 1，故 φ 直接表示该规模下的损失修正，其符号方向与问题一的总体表现指标 $\phi(\mathbf{p})$ 不同。为避免平均质量 $\sum_i p_i Q_i$ 抹去同等级、不同知识来源之间的差别，将组成响应展开为

$$\varphi(\mathbf{Q}, \mathbf{p}) = \sum_{i=1}^m w_i (p_i Q_i - \bar{m}_i) + \sum_{i=1}^m w_{\text{clr},i} (\text{clr}_\varepsilon(\mathbf{p})_i - \bar{m}_{\text{clr},i}). \quad (5.22)$$

这里 w_i 与 $w_{\text{clr},i}$ 分别为质量加权份额和相对配比的有效权重。 $\bar{m}_i$ 、 $\bar{m}_{\text{clr},i}$ 是对应特征在参考

规模拟合样本上的均值，使 φ 在该样本上均值为零。其中，中心化对数比定义为

$$\text{clr}_\varepsilon(\mathbf{p})_i = \log(p_i + \varepsilon) - \frac{1}{m} \sum_{j=1}^m \log(p_j + \varepsilon). \quad (5.23)$$

式 (5.22) 中的 $p_i Q_i$ 记录质量加权的来源投入，中心化对数比反映单纯形上的相对结构， $\varepsilon > 0$ 用于处理零占比。拟合时对这两组特征进行标准化与正则化，并将所得系数换算为式 (5.22) 中的有效权重。不同评估目标均采用式 (5.21) 的函数结构，但 E 、 A 、 B 、 η 、 ζ 及组成权重分别估计。

5.2.3 广义标度律的参数辨识模型建立与验证

式 (5.21) 由经典规模基线与受规模因子调制的组成响应相加而成。若联合估计全部参数，仅有三个规模锚点不足以同时辨识经典律指数和组成响应指数。此外，响应形状与幅度可相互吸收，造成参数化不唯一。为此，本文按图 5.8 所示采用“锚定标准律—分阶段参数辨识—因子对比”的递进结构，在保留经典律约束的同时辨识新增的组成项。




图 5.8 广义标度律的三阶段参数辨识：标准律锚定规模指数，分阶段估计组成响应与基线，再由规模因子对比确定响应幅度指数。图中 ϕ 为组成损失修正的示意简写，正文记作 φ 。

锚定标准律 沿用前文由充分规模变化的实验辨识出的共享指数 $\alpha = \beta = 0.293183$ ，只借用指数而不直接移植损失基线参数。由此将广义模型的规模基线限制在 $\{1, N^{-\alpha}, D^{-\beta}\}$ 张成的空间中，避免用稀疏的配比实验重新估计指数。该锚定仅约束资源收益衰减的形状。损失下界及两个规模项的系数仍由当前评估目标的数据确定，从而不强求不同目标共享损失水平。以下 N, D 分别以十亿参数和十亿 Token 计。三个观测锚点依次为 $(10^{-3}, 1)$ 、 $(0.06, 1)$ 和 $(1, 25)$ ，首个锚点记为 (N_0, D_0) 。

分阶段参数辨识 在参考锚点， N, D 保持不变，配比之间的损失差异因而提供组成响应的识别信息。对式 (5.22) 中的两组特征逐维标准化，以岭回归估计该响应，正则强度由调参折选定。将拟合响应在参考训练配比上中心化、换算至损失单位，并规定其幅度 $\kappa_1 = 1$ ：前者使组成项与常数基线在参考样本上分离，后者固定 $\kappa\varphi$ 的尺度规范。令 s 表示锚点、 r 表示该锚点训练折中的配比， $\varphi_{sr} = \varphi(\mathbf{Q}, \mathbf{p}_{sr})$ 。其余幅度是损失对同一响应形状的投影斜率。扣除组成项后得到各锚点的规模基线：

$$\kappa_s = \frac{\sum_r (\varphi_{sr} - \bar{\varphi}_s)(L_{sr} - \bar{L}_s)}{\sum_r (\varphi_{sr} - \bar{\varphi}_s)^2}, \quad s = 2, 3, \quad (5.24)$$

$$b_s = \bar{L}_s - \kappa_s \bar{\varphi}_s, \quad s = 1, 2, 3.$$

这样，原先耦合的形状与幅度被化为参考规模的正则化回归及跨规模的一元投影。再以非负最小二乘将三个 b_s 投影回锚定的经典律基底：

$$(\hat{E}, \hat{A}, \hat{B}) = \arg \min_{E, A, B \geq 0} \sum_{s=1}^3 (b_s - E - AN_s^{-\alpha} - BD_s^{-\beta})^2. \quad (5.25)$$

非负约束保持经典基线项的物理方向。由于组成修正可为负，仍须另行检查预测损失是否低于 E 。各评估目标采用相同的函数结构，但分别估计其基线与组成权重。

因子对比 对正的响应幅度取对数，得到 $\log \kappa_s = -\eta \log(N_s/N_0) - \zeta \log(D_s/D_0)$ 。由于前两个锚点的 D 相同，其幅度比消去了数据量因子，可先辨识 η ，再从第三个锚点的总幅度变化中扣除已知的参数规模效应，条件辨识 ζ ：

$$\eta = -\frac{\log \kappa_2}{\log(N_2/N_1)}, \quad \zeta = \frac{-\log \kappa_3 - \eta \log(N_3/N_1)}{\log(D_3/D_1)}. \quad (5.26)$$

上述对比利用实验设计形成的单因子变化，而不依赖同时搜索两个指数。同一配比在前两个锚点的损失还应满足 $L_2(\mathbf{p}) = a + \lambda L_1(\mathbf{p})$ ，其中 $\lambda = \kappa_2/\kappa_1$ 、 $a = b_2 - \lambda b_1$ 。这一配对关系消去了 φ ，因而可在不依赖其具体函数形式的条件下检验可分离结构。配对回归的训练折 R^2 中位数为 0.9868，留出配比的跨规模预测相对 RMSE 中位数为 1.16%。




图 5.9 广义标度律的留出配比验证：(a) 各评估目标的相对 RMSE、总体 R^2 与配比效应 R^2 ；(b) 三个观测规模的实测与预测损失对比，灰色标记为同一组系数下关闭配比项的预测，实线为理想一致线，阴影表示 $\pm 5\%$ 误差带。

验证 对逐行配对的规模采用相同配比划分，第三个规模独立划分，留出折均不参与拟合或选模。在 13 个评估目标、三个已观测规模的留出配比上，三个规模的相对 RMSE 分别为 5.84%、5.49% 和 4.44%，汇总为 5.54%。中位绝对百分比误差为 2.40%，按评估目标与规模中心化的配比效应 R^2 为 0.9006。留出预测的最小 $\hat{L} - E$ 为 0.2129，未跌破基线下界。图 5.9(a) 表明多数评估目标保持较低误差和较高解释度，但数学目标的误差明显偏大，提示跨目标性能仍有差异。图 5.9(b) 中，三个规模的留出预测总体沿理想一致线分布。关闭配比项后，预测在固定规模与评估目标内不再随配比变化，形成水平带，说明仅靠 N, D 无法解释同规模的损失波动，这些结果支持已观测规模内的配比泛化。

5.3 广义标度律指导下的语料规模-质量、配比替代

前述验证表明，资源规模项能够描述总体损失的衰减趋势，而语料质量与领域组成进一步决定相同 Token 预算下的损失差异。因而，讨论质量对规模的替代，首先需要在明确的工作点和可行配比方向上度量局部收益；不同实验尺度下的收益只有经过一致校准，才能进一步换算为等效 Token 数。

5.3.1 广义标度律各因素边际效用与弹性分析

对标量因素 $x \in \{N, D, Q\}$ ，定义边际降损与损失弹性为

$$g_x = -\frac{\partial L}{\partial x}, \quad \epsilon_x = \frac{\partial \ln L}{\partial \ln x} = \frac{x}{L} \frac{\partial L}{\partial x}. \quad (5.27)$$

其中， N, D 的响应由广义标度律给出；整体质量等级 Q 不同于固定的来源质量 $Q_i^{(17)}$ ，其独立边际效应由质量实验拟合的响应模型估计，而不从广义律中的 $p_i Q_i$ 项直接推断。为使收益具有可解释的扰动尺度，规模因素报告 $L(x) - L(1.01x)$ ，质量因素报告 $L(Q) - L(Q + 0.01)$ 。配比受单纯形约束，增加来源 i 的份额 t 时，令 $p_i(t) = p_i + t$ 、 $p_j(t) = p_j(1 - t/(1 - p_i))$ ($j \neq i$)，并以 $L(\mathbf{p}) - L(\mathbf{p}(0.01))$ 衡量可行方向的降损。

图 5.10(a) 给出固定参考配比下的规模弹性及配比方向收益。在已观测的 $N = 10^9$ 、 $D = 2.5 \times 10^{10}$ 工作点，13 个评估目标的弹性中位数分别为 $\epsilon_N = -0.0345$ 、 $\epsilon_D = -0.0868$ 。这表明在该点数据量的相对增益具有更高的损失敏感度，但尚不能据此比较参数与 Token 的算力效率。图中的百亿参数点仅是模型外推，不作为观测证据。图 5.10(b) 显示质量收益随 Q 提高而递减：在 $Q = 0.6$ 时，质量分增加 0.01 的预测降损约为 2.15×10^{-3} 。主组 450 组与对照组 360 组存在包含关系，后者仅检验子集一致性。质量实验与广义律的损失基准尚未统一，故不能将两组导数直接相除，解释为质量提升所等效的 Token 增量。




图 5.10 资源与质量因素的局部响应：(a) 参数量和数据量的损失弹性，以及配比份额增加 1 个百分点的方向收益分布；区间表示跨评估目标的四分位范围，百亿参数点仅为外推。(b) 独立质量实验中质量分增加 0.01 的降损及损失弹性；对照组为主组子集。




图 5.11 领域配比的方向异质性与份额依赖：(a) 不同来源增配 1 个百分点时，各评估目标的预测降损，红色表示降损、蓝色表示增损，空白表示不满足可行方向条件；(b) 在观测支撑域内扫描来源份额所得的方向收益与弹性，色带反映跨评估目标的分布范围。两图均为模型敏感度分析，不作因果解释。

配比的边际效用不具有统一符号。图 5.11(a) 表明，同一来源的增配方向可能降低某些评估目标的损失，却提高另一些目标的损失；在参考配比下，117 个位于观测支撑域内的可行方向中，仅 53.8% 获得正收益。图 5.11(b) 进一步显示，收益还随来源份额改变，不能把单点导数延伸为全区间的固定排序。因此，配比调整应被视为面向目标和当前配方的局部资源重分配。

5.3.2 广义标度律指导下的语料规模-质量、配比替代




图 5.12 两种示例评估领域的质量-Token 等损失曲线。各曲线对应同一组观测配比，纵轴为保持参考目标损失所需的 Token 数； $Q_0 = 0.6$ 与 $Q_1 = 0.7$ 为质量比较点。离开 $N = 10^9$, $D_* = 250$ 亿 Token 观测工作点后的需求量属于模型情景推算。

为将上一节的局部降损量转换为等损失的 Token 需求，以已辨识的广义标度律为主体，




图 5.13 同一组观测配比在两种示例评估领域中的等损失 Token 需求。各行配比保持一致，实心与空心标记分别对应 $Q_0 = 0.6$ 和 $Q_1 = 0.7$ ；横向差异表征模型预测的配比依赖性，并非配比干预的因果效应。

对数据受限项引入整体质量等级的外部标定：

$$L(N, D, Q, \mathbf{p}) = E + AN^{-\alpha} + \left(\frac{Q}{Q_0}\right)^{-\gamma_Q} [BD^{-\beta} + M(N, D)\varphi(\mathbf{Q}^{(17)}, \mathbf{p})]. \quad (5.28)$$

其中， $Q_0 = 0.6$ 是整体质量的校准点， $\mathbf{Q}^{(17)}$ 为问题一映射得到并在配比实验中固定的来源质量向量； $M(N, D) = (N/N_0)^{-\eta}(D/D_0)^{-\zeta}$ 为前述规模调制因子。质量指数 $\gamma_Q = 0.1085$ 由独立质量实验标定，其余参数均不重估。故 $Q = Q_0$ 时，式 (5.28) 严格退化为原广义律。主口径使质量同时作用于规模项与配比修正项；仅作用于 $BD^{-\beta}$ 的口径作为结构敏感性对照。主口径下，固定配比的精确局部等损失斜率为

$$\left. \frac{d \ln D}{d \ln Q} \right|_{L, \mathbf{p}} = -\gamma_Q \frac{BD^{-\beta} + M\varphi}{\beta BD^{-\beta} + \zeta M\varphi}, \quad (5.29)$$

其中 $M \propto D^{-\zeta}$ ， $\varphi = \varphi(\mathbf{Q}^{(17)}, \mathbf{p})$ 。因此 $-\gamma_Q/\beta$ 仅在忽略配比项或两项具有相同数据量指数时成立，有限幅度的替代量须逐目标数值求解。

固定 $N = 10^9$ 、替代工作点 Token 数 $D_* = 250$ 亿及参考配比 $\mathbf{p}_0$ ，将 $L(N, D_*, Q_0, \mathbf{p}_0)$ 作为各评估目标的基准损失，求满足该目标损失时 Q 与 $\mathbf{p}$ 对应的最小所需 D 。这里 D_* 不同于广义律的规模归一化锚点 D_0 。配比调整仅考虑观测支撑域内的方向：单一来源份额增加 1 个百分点，其余来源按比例缩减。图 5.12 展示两种示例评估领域的等损失曲线；在相同配比下提高质量使所需 Token 下降，而同一质量水平下不同配比对应不同的需求基线。图 5.13 用同一组真实配比进一步表明，这种配比效应的幅度具有明显的评估目标依赖性。

逐目标先对可行配比方向取节省量中位数，再对 13 个评估目标等权汇总：质量由 0.6 提至 0.7 时，固定配比的 Token 节省中位数为 13.97 亿，叠加可行的 1 个百分点配比调整后为 14.06 亿；仅缩放规模项的敏感性口径分别为 13.30 亿和 13.59 亿。因而，小幅配比调整的总增益有限，但图中的完整观测配比差异可显著改变所需 Token 水平，两种比较尺度不可混同。模型在 Q_0 的锚定误差小于 5×10^{-16} ，可行求根的最大损失残差为 2.33×10^{-13} 。

5.3.3 广义标度律的质量、配比替代边界

上述等损失换算由 $L(N, D, Q, \mathbf{p}) = L^*$ 隐式定义，并非跨工作点通用的 Token 汇率。对式 (5.28)，只有在 $BD^{-\beta} + M\varphi > 0$ 且 $\beta BD^{-\beta} + \zeta M\varphi > 0$ 时，提高质量和增加 Token 才同时具有降损效应，式 (5.29) 的负斜率方可解释为局部替代。由于组成修正 φ 可正可负，这些条件须按评估目标、配比和工作点分别核查。识别边界同样重要：配比实验中的来源质

量 $Q_i^{(17)}$ 固定，不能由 $p_i Q_i^{(17)}$ 单独辨识质量提升效应。整体质量指数来自独立实验，其与组成项的乘性耦合是外部标定的结构假设，尚缺少同时独立改变质量与配比的实验验证。

独立改变整体质量等级的实验为局部质量响应提供了直接依据：在 45 组固定 (N, D) 的比较中，验证损失对 Q 的线性趋势斜率均为负。包含 450 条记录的拟合及其 360 条记录的子集对照分别得到 $R^2 = 0.9568$ 和 0.9535 ；二者是包含关系，不能视为独立重复验证。在 $Q = 0.6$ 的工作点，质量提高 0.01 的预测降损约为 2.15×10^{-3} ，质量弹性约为 -0.0482 ，与负向的经验响应一致，但其边际收益随 Q 提高而递减。相比之下，向更大模型和语料规模延伸的扩展结果在 150 组固定 (N, D) 的比较中给出全部为正的质量-损失斜率，并有 362 条记录被截断于损失下界 0.5。这一方向冲突和截断现象表明，该扩展结果不能验证质量响应的外推，也不宜用于重标定质量指数；它并不构成“大模型中质量提升会增损”的实验证据。

因此，本文仅在观测支撑域内调整配比，并在独立质量实验标定的范围附近解释质量边际效用与弹性；质量与组成的联合替代仍须以两种耦合口径及逐目标差异进行敏感性检验。当等损失求解所需的 D 偏离已观测规模，或将关系推广至更大模型时，所得节省量应视为模型情景推算，而非已实现的训练收益或因果效应。

六、问题三：算力约束下的联合资源配置

6.1 问题分析与联合资源模型

问题三包含三个相互衔接的任务：在总算力约束下联合配置模型规模、训练数据量、领域配比和数据治理质量；比较不同质量成本与上下文长度对配置结果的影响；识别预算变化是否引起质量状态、配方支持或资源份额的结构性转移。本文把前两问的输出固定为响应模型参数，把问题三写成一个可复算的条件优化问题。总体接口见图 6.14。




图 6.14 质量、配方及规模响应的衔接与联合求解流程

6.1.1 数据接口与变量定义


A4 的 512 行真实训练配方给出领域配比的可行范围；第二问交付的 13 个评测域响应给出配比、规模和质量的 Loss 映射；C7 的五个上下文长度作为外生情景；B7 提供整体治理质量的条件响应。A6–A11 用于复算交接响应在检验配方上的一致性，A12–A15 保留为外推情景的边界参考。问题三的数值结论均指向这套已交接的响应函数。

问题一得到的 17 域质量向量记为 $\mathbf{q} = \mathbf{Q}^{(17)}$ 。它是固定的领域属性，其中只有 6 个不同取值；问题三另设标量 Q 表示整体治理后的质量等级，并将其同时放入质量响应和治理成本。17 域治理提升不单独设变量，统一由 Q 表示。定义


$$n = \frac{N}{10^9}, \quad d = \frac{D}{10^9}, \quad q_{\text{mix}} = \sum_{i=1}^{17} p_i q_i, \quad Q_{\text{base}} = \frac{1}{17} \sum_{i=1}^{17} q_i = 0.6219326581. \quad (6.30)$$

其中 N 为参数量, D 为训练 Token 数, $\mathbf{p} = (p_1, \dots, p_{17})$ 为训练配方, $Q \in [Q_{\text{base}}, 1]$ 为治理质量。训练平均配方加权基线 0.6193580512 作为基线敏感性情景; B7 的校准点 $Q_0 = 0.6$ 只用于第二问标尺, 和本问的 Q_{base} 分开记账。

A4 覆盖三个直接观测尺度, 问题三在配方方向上使用 A4 的有限凸包; N 和 D 的计算范围为 $[10^6, 10^{11}]$ 与 $[10^9, 10^{13}]$ 。因此, 表中结果表示在交接响应下的条件配置, 预算、上下文和质量成本的变化均可以由公式复算。



(a) 直接支持尺度与联合配置



(b) 三种质量成本的增量曲线

6.1.2 配方响应与质量桥接

为适应配比的组成数据结构, 对 p_i 加入 $\delta = 0.001$ 后作中心化对数比变换, 并将质量加权配比与配方结构拼接为 34 维特征:

$$\text{clr}_\delta(p)_i = \ln(p_i + \delta) - \frac{1}{17} \sum_{j=1}^{17} \ln(p_j + \delta), \quad \delta = 0.001. \quad (6.31)$$

$$x = (p \odot \mathbf{q}, \text{clr}_\delta(p)), \quad z = \frac{x - \mu}{\sigma}, \quad \Phi_k = s_k(\beta_{0k} + \boldsymbol{\theta}_k^\top z - c_k). \quad (6.32)$$

其中 $k = 1, \dots, 13$ 对应评测域, $\mu, \sigma, \beta_{0k}, \boldsymbol{\theta}_k, s_k, c_k$ 均取第二问交接文件的全精度参数。规模项与第 k 个评测域的基础响应为

$$S_k = (n/0.001)^{-\eta_k} (d/1)^{-\zeta_k}, \quad L_{2,k} = E_k + A_k n^{-\alpha} + B_k d^{-\beta} + S_k \Phi_k, \quad (6.33)$$

其中 $\alpha = \beta = 0.2931826439$ 。为把 B7 质量标尺接入 13 域响应, 先写出

$$F_7(n, d, Q) = 0.9654077057 + 0.5307187920 n^{-0.2825} + 1.6157571765 (dQ)^{-0.108}. \quad (6.34)$$

主模型采用比值桥接, 并用加性桥接做成本和桥接形式的敏感性检验:

$$L_k^{(r)} = L_{2,k} \left[\frac{F_7(n, d, Q)}{F_7(n, d, Q_{\text{base}})} \right]^\kappa, \quad (6.35)$$

$$L_k^{(a)} = L_{2,k} + \kappa [F_7(n, d, Q) - F_7(n, d, Q_{\text{base}})].$$

两种桥接在 $Q = Q_{\text{base}}$ 时都回接第二问响应; 主强度为 $\kappa = 1$, 并取 0.5、1.5 做正收益敏感性, $\kappa = 0$ 做零收益对照。固定 N, D, Q 时桥接项不改变配方排序, 联合收益来自质量治理、配比、规模对同一预算的重新分配。

6.1.3 成本函数与完整优化模型

单位 Token 的质量治理成本取题面给出的三种形式：

表 6.9 质量成本函数及题给参数

形式	$g(Q)$	单位与说明
指数	$10^7 \exp(6Q)$	FLOPs/Token, 随质量凸增
幂函数	$5 \times 10^9 Q^4$	FLOPs/Token, 四次幂
对数	$2 \times 10^9 \ln(1 + 10Q)$	FLOPs/Token, 上界处有限

令 L_{ctx} 为 C7 给出的外生上下文长度，质量治理只计算相对于基线的增量，则

$$a = 6 + \eta_{\text{attn}} L_{\text{ctx}}, \quad h(Q) = [g(Q) - g(Q_{\text{base}})]_+, \quad \eta_{\text{attn}} = 2 \times 10^{-4}. \quad (6.36)$$

三项算力成本合并为

$$C_{\text{used}} = C_{\text{train}} + C_{\text{attn}} + C_Q = 6ND + \eta_{\text{attn}} ND L_{\text{ctx}} + Dh(Q) = D[aN + h(Q)]. \quad (6.37)$$

设 $A \in \mathbb{R}^{m \times 17}$ 为选用的真实训练锚点矩阵， w 为锚点权重， $p = A^T w$ 。问题三的联合资源配置模型写为

$$\begin{aligned}
\min_{N, D, Q, w} \quad & J(N, D, Q, w) = \frac{1}{13} \sum_{k=1}^{13} L_k(N, D, Q, A^T w), \\
\text{s.t.} \quad & D[(6 + \eta_{\text{attn}} L_{\text{ctx}})N + h(Q)] \leq C, \quad (\text{C1}) \\
& Q_{\text{base}} \leq Q \leq 1, \quad (\text{C2}) \\
& 10^6 \leq N \leq 10^{11}, \quad 10^9 \leq D \leq 10^{13}, \quad (\text{C3}) \\
& p = A^T w, \quad w \geq 0, \quad \mathbf{1}^T w = 1, \quad (\text{C4}) \\
& L_k(N, D, Q, p) \geq 10^{-6}, \quad k = 1, \dots, 13. \quad (\text{C5})
\end{aligned} \quad (6.38)$$

约束 (C1) 是 FLOPs 预算，(C2) 是质量可行域，(C3) 给出计算范围，(C4) 把配比限制在 A4 真实配方的凸包内，(C5) 保证响应值为正且可用于比较。主域使用 25 个锚点，随后用全部 512 行 A4 配方作方向复核；这样既保留了可计算的低维权重，又检查了缩减锚点是否遗漏真实改善方向。

上下文的影响可由成本比直接读出：

$$\frac{C_{\text{attn}}}{C_{\text{train}}} = \frac{\eta_{\text{attn}} L_{\text{ctx}}}{6}, \quad L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta_{\text{attn}}} = 30000. \quad (6.39)$$

C7 中的 32768 和 131072 已超过临界长度，故本问对 2048、4096、8192、32768、131072 五档全部计算。固定上下文时，该成本比与预算无关。

模型小结：问题三的决策变量为 (N, D, Q, w) ，其中 $p = A^T w$ 是 17 域配比， $\mathbf{q} = \mathbf{Q}^{(17)}$ 是固定域质量， Q 是统一治理等级；总成本由训练、注意力和治理三项组成。随着上下文从 2048 增至 131072，注意力成本成为主要约束，表中 N 、 D 和 J 的变化与式 (6.37) 一致。

6.2 求解方法与实验设计

6.2.1 资源替代关系

预算约束活跃时，固定 N 和上下文后有 $D = C/[aN + h(Q)]$ 。质量提高带来直接 Loss 改善，同时增加每个 Token 的治理成本，因此质量方向的边际判据为

表 6.10 原 25 锚点联合解的上下文配置比较

L_{ctx}	注意力/训练比	N (十亿)	D (十亿)	Q	J
2048	0.06827	2.8157	448.44	1.0000	1.69176
4096	0.13653	2.7163	439.08	1.0000	1.69523
8192	0.27307	2.5438	422.26	1.0000	1.70169
32768	1.09227	1.9152	353.43	1.0000	1.73153
131072	4.36907	1.1338	245.24	1.0000	1.79558

$$D = \frac{C}{aN + h(Q)}, \quad \frac{dD}{dQ} = -\frac{Dg'(Q)}{aN + h(Q)}, \quad T_Q = J_Q - \frac{J_D D g'(Q)}{aN + h(Q)}. \quad (6.40)$$

当 $T_Q < 0$ 时，提高质量仍能降低总目标， $T_Q = 0$ 给出质量内点， $T_Q > 0$ 时最优点停留在质量下界。 N, D 的驻点条件为

$$J_N + \lambda a D = 0, \quad J_D + \lambda(aN + h) = 0. \quad (6.41)$$

由此得到规模弹性关系和治理成本份额

$$\varepsilon_N = -\frac{NJ_N}{J}, \quad \varepsilon_D = -\frac{DJ_D}{J}, \quad \frac{\varepsilon_N}{\varepsilon_D} = \frac{aN}{aN + h} = 1 - s_Q, \quad (6.42)$$

$$s_Q = \frac{C_Q}{C_{\text{used}}} = \frac{h(Q)}{aN + h(Q)}, \quad \left. \frac{\partial s_Q}{\partial N} \right|_{Q, L_{\text{ctx}}} = -\frac{ah(Q)}{[aN + h(Q)]^2}. \quad (6.43)$$

式 (6.40) 回答质量治理何时值得投入，式 (6.42) 回答训练规模和数据规模如何分享剩余预算，式 (6.43) 解释了治理份额和治理绝对成本可能呈现不同趋势。

6.2.2 数值求解与可行域复核

为减小 N, D 跨数量级带来的数值尺度差异，采用对数坐标参数化：

$$\begin{aligned} Q_{\text{hi}} &= \max\{Q \in [Q_{\text{base}}, 1] : D_{\min}[aN_{\min} + h(Q)] \leq C\}, \\ N &= \exp\{\ln N_{\min} + u \ln(N_{\text{cap}}/N_{\min})\}, \\ D &= \exp\{\ln D_{\min} + v \ln(D_{\text{cap}}/D_{\min})\}, \quad u, v \in [0, 1]. \end{aligned} \quad (6.44)$$

主求解使用 SLSQP，设置三个确定性起点；保留满足预算、质量边界、凸组合和 13 域正 Loss 条件的最优候选。对照使用 COBYQA，在 30 个共同配置上复算。完整 A4 配方复核沿

$$p(t) = (1 - t)p + ta_r, \quad r = 1, \dots, 512, \quad t \in \{10^{-4}, 10^{-3}\} \quad (6.45)$$

逐点扫描；发现改善配方后加入候选库并重新求解。图 6.16 给出从真实锚点、方向扫描到候选复核的流程。

6.2.3 实验矩阵

主实验覆盖 11 档预算、5 档上下文、3 种成本函数和 4 种决策方式。四种方式逐步释放 N, D 、配比 p 和治理质量 Q ，用来分离规模、配比、治理和联合配置的贡献；成本归一化、桥接形式、收益强度、锚点集合、零收益和预算加密实验用于检验结论的稳定性。




图 6.16 真实锚点扩展与参考解检验流程

表 6.11 四组消融与条件实验矩阵

类别	自由变量或变化因素	数量及用途
规模基线	N, D ；固定平均配方与基础质量	联合配置的基准
配比组	N, D, p ；固定基础质量	分离配比调整收益
质量组	N, D, Q ；固定平均配方	分离治理收益及成本
联合组	N, D, p, Q	评价联合资源配置
主矩阵	11 预算、5 上下文、3 成本、4 组	660 项
成本对照	统一 Q_{base} 至 1 的端点增量价格	检验价格尺度影响
桥接对照	2 种桥接、3 种强度、2 种基线质量	检验接口影响
搜索敏感性	49/97 锚点、6 起点、边界扰动	检验求解稳定性
零收益与预算加 密	$\kappa = 0$ ；41 档预算	检验治理收益与阈值
算法对照	5 预算、2 上下文、3 成本、2 求解器	60 项

实验小结：求解层面由预算约束、正 Loss 检查、凸组合复核和多起点比较共同构成；实验层面由四组消融、五档上下文和三种成本函数共同回答“资源如何分配”和“结论是否依赖某一设定”两个问题。

6.3 资源配置结果与结构性转移

6.3.1 联合收益与逐域代价

以同预算、同上下文、同成本的规模基线为配对参照，定义平均改善率及非加性项

$$G = 100 \frac{J_{\text{base}} - J_{\text{joint}}}{J_{\text{base}}}, \quad H = J_{\text{quality}} + J_{\text{mixture}} - J_{\text{base}} - J_{\text{joint}}. \quad (6.46)$$

指数成本、上下文 4096 的四组轨迹见图 6.17。165 个原联合场景的平均改善率为 4.1603%–5.8086%，说明在本响应模型中同时释放配比和治理变量具有配置价值。 H 在 71 组为正、47 组为负、47 组接近零，联合收益随预算和响应曲率变化，并非固定的加法收益。

均值改善伴随领域间的重新分配。165 组中有 162 组至少一个评测域的 Loss 上升，最多涉及 2 个领域；最大绝对退步为 0.0867182 nats，出现在 $C = 3 \times 10^{20}$ 、上下文 2048、幂成本的 dm mathematics。图 6.18 展示三种成本和三档预算下的 13 域变化。




图 6.17 指数成本、上下文 4096 时 11 档预算的四组消融；各组均联动优化 N/D




图 6.18 典型配置的逐域代价；热力图保留 13 个评测域和 9 组预算–成本组合，颜色表示相对原配方的 Loss 变化

6.3.2 配方支持域与典型配置

对全部 A4 配方作方向扫描后，165 个原联合配置均发现 25 锚点域外的改善方向。上下文 4096 的 33 组扩域实验最终使用 39–42 个锚点，较原联合解进一步改善 0.8383%–2.5512%，配比 L_1 变化为 0.5280–0.6468%。图 6.19 呈现扩域收益，表 6.12 给出有限候选库中的典型配置。




图 6.19 33 个 4096 上下文配置的扩域结果相对原 25 锚点联合解的变化

表 6.12 同合同有限候选库中的典型条件配置

C (FLOPs)	成本	N (十亿)	D (十亿)	Q	J	候选来源
10^{19}	指数	0.0678	21.64	0.6219	2.38753	扩展锚点
10^{19}	幂	0.0678	21.64	0.6219	2.38753	扩展锚点
10^{19}	对数	0.0678	21.64	0.6219	2.38753	扩展锚点
10^{22}	指数	2.5115	491.40	0.9829	1.66994	扩展锚点
10^{22}	幂	2.6199	452.13	1.0000	1.67192	扩展锚点
10^{22}	对数	2.2175	626.41	1.0000	1.66062	97 锚点
10^{24}	指数	21.9273	6529.84	1.0000	1.46600	97 锚点
10^{24}	幂	22.0068	6480.02	1.0000	1.46612	97 锚点
10^{24}	对数	21.5744	6758.48	1.0000	1.46547	97 锚点


幂成本、上下文 4096 下的三档典型配方见表 6.13。低预算时三种成本均停留在 Q_{base} ；预算提高后，质量治理与配比调整开始共同占用新增算力。

表 6.13 幂成本条件下典型有限候选的完整领域配方 (%)

领域	10^{19}	10^{22}	10^{24}
arxiv	3.45	2.62	1.79
freelaw	7.67	7.44	5.25
nih exporter	0.02	0.01	4.88
pubmed central	2.93	1.46	3.63
wikipedia en	6.84	7.74	19.69
dm mathematics	4.73	5.06	0.84
github	11.40	12.92	12.12
philpapers	<0.005	<0.005	<0.005
stackexchange	14.07	13.10	3.83
enron emails	0	<0.005	0.08
gutenberg pg 19	6.55	9.03	15.90
pile cc	17.87	28.14	11.49
ubuntu irc	5.10	5.13	14.81
europarl	<0.005	<0.005	0.09
hackernews	6.16	4.63	5.22
pubmed abstracts	9.81	0.05	<0.005
uspto backgrounds	3.41	2.67	0.36

6.3.3 上下文、成本与结构状态

图 6.20a表明，质量治理的绝对成本可随预算增加，而其在总成本中的份额未必增加。以扩域幂成本案例为例，预算从 10^{22} 增至 10^{24} 时，治理份额从 19.2241% 降至 2.6935%，治理绝对成本却从 1.9224×10^{21} 增至 2.6935×10^{22} FLOPs。图 6.20b给出规模与数据的局部资源平衡复核，165 个原联合解的最大归一化残差为 2.04434×10^{-6} 。





为区分价格尺度和函数形状，将三类成本在 $Q = 1$ 处作端点归一化：

$$\lambda_f = \frac{g_{\text{exp}}(1) - g_{\text{exp}}(Q_{\text{base}})}{g_f(1) - g_f(Q_{\text{base}})}, \quad h_f^{\text{norm}}(Q) = \lambda_f [g_f(Q) - g_f(Q_{\text{base}})]_+. \quad (6.47)$$

原价与归一化价格在 55 个预算–上下文组中有 19 组最优成本形式发生变化，说明成本曲线的价格量级和曲率都影响资源选择。相应轨迹见图 6.21a和图 6.21b。

将结构性转移定义为最优状态的持续变化，而不是单个预算点的数值跳变。质量状态由 Q 到质量上下界的距离确定；配方支持集与支持距离为



$$S_\tau(p) = \{i : p_i > \tau\}, \quad d_J(S_0, S_1) = 1 - \frac{|S_0 \cap S_1|}{|S_0 \cup S_1|}, \quad \tau = 0.01. \quad (6.48)$$

配方变化同时满足 $d_J \geq 0.2$ 与 $\|p_1 - p_0\|_1 \geq 0.02$ ，并在后续预算点和加密预算中保持，才记为有效支持转移。机制方向、桥接形式、收益强度、随机种子、边界和锚点扰动共同构成情景检验；主支持比例门槛设为 70%。

表 6.14 结构转移识别与阈值敏感性

项目	实际结果	判断
固定配方质量启动	指数成本、上下文 131072 出现一个下界至内点事件	质量治理由下界进入内点
预算区间 (FLOPs)	粗: $[3 \times 10^{19}, 10^{20}]$; 细: $[7.49894 \times 10^{19}, 10^{20}]$	两个区间属于同一事件
情景支持比例	16/21, 即 76.19%	通过 70% 门槛, 未通过 80% 门槛
质量方向容差	10^{-4} 通过, 10^{-5} 不通过	阈值会影响事件识别
联合配置	70% 门槛下没有稳定事件	联合策略未形成稳定结构转移
光滑配方负对照	全部占比保持正值仍可跨 1% 阈值	配方支持变化具有连续性

结果小结：联合优化在平均 Loss 上取得 4.16%–5.81% 的改善，但改善由领域间让渡伴随而来；扩展 A4 支持域后，配置仍可进一步改善。上下文变长持续挤压 N 和 D ，成本函数的价格尺度与曲率都会改变治理轨迹。结构检验在固定配方、指数成本、最长上下文条件下发现一个质量启动事件；在联合配置的多情景检验中，没有形成稳定的结构转移。

6.4 稳健性检验与问题三结论

6.4.1 有限情景的稳健配置


对同一组候选在两种桥接和三种正收益强度下进行六情景复算。设 X 为共同可行候选集，定义

$$J_s^{\text{best}} = \min_{x \in X} J_s(x), \quad R_s(x) = \frac{J_s(x) - J_s^{\text{best}}}{|J_s^{\text{best}}|}. \quad (6.49)$$

以最小化最大后悔值选择稳健候选：

$$x_{\text{rob}} \in \arg \min_{x \in X} \max_s R_s(x), \quad v_{\text{rob}} = \min_{x \in X} \max_s R_s(x). \quad (6.50)$$

165 组的最大相对后悔值为 1.5465%，零收益压力情景下为 2.5946%。这说明推荐配置对已登记桥接和收益强度具有有限幅度的稳定性；稳健性结论随候选库和情景集合一并定义。



6.4.2 求解器复算与适用范围

SLSQP 与 COBYQA 在相同 25 锚点、相同 3 起点和相同配置上进行 30 对复算。60 个结果均满足基本可行条件，扰动检查通过 59 个；SLSQP 为 30/30，COBYQA 为 29/30，最大均值 Loss 差为 0.000168474。求解器复算、有限后悔和零收益对照共同表明，推荐结果不是某一个局部搜索设置的单点产物。

本问计算的是第二问响应函数下的条件配置，质量桥接沿用 B7 标尺，配方支持来自 A4，实际上下文来自 C7。后续实证步骤是：先以表 6.12 选择预算和上下文下的候选，再在同一数据治理流水线上记录真实治理 FLOPs，并用 13 域评测 Loss 对 Q 、 $g(Q)$ 和桥接强度重新校准。

问题三结论：

1. 在总成本 $C = D[(6 + \eta_{\text{attn}} L_{\text{ctx}})N + h(Q)]$ 下，联合优化变量为 N, D, Q, w ，配比由 $p = A^T w$ 生成；这同时满足算力预算、质量上下界、尺度范围和真实配方支持约束。
2. 在当前响应模型中，联合释放配比和治理质量使平均 Loss 改善 4.1603%–5.8086%，但 165 组中 162 组至少有一个评测域退步，实际部署应根据领域优先级增加逐域约束。
3. 上下文长度通过注意力成本直接改变可用于 N 和 D 的预算； $L_{\text{ctx}}^{\text{crit}} = 30000$ ，C7 中的 32768 和 131072 已进入注意力成本高于训练成本的区间。成本函数的价格尺度和曲率都会改变治理质量轨迹。
4. 结构检验在固定配方、指数成本、上下文 131072 下发现一次质量由下界进入内点的事件；联合配置未形成通过 70% 情景门槛的稳定结构转移。有限候选最大相对后悔值为 1.5465%，求解器复算的合格率为 59/60。

七、 问题四：技术演进分解及能力前沿预测

问题四需要解决的核心识别问题，是将前三问给出的 Loss 机制与现实模型的 Benchmark 表现统一到可比较的能力尺度。前三问依次刻画数据质量与领域配比、广义标度关系及算力约束下的最优资源配置，由此形成从预算到最优损失的机制映射 $L^*(C)$ ；现实样本则提供综合能力前沿 F_t 和训练算力前沿 C_t 。对两类前沿分别实施时间回归，既不能

从回归系数中识别规模效应，也无法构造算力增速放缓的结构反事实。为此，本文引入 Loss-Benchmark 桥接函数 H 作为观测映射，并建立统一状态方程

$$F_t - F_{t_0} = \underbrace{H[L^*(C_t)] - H[L^*(C_{t_0})]}_{\text{规模机制项}} + \underbrace{T_t}_{\text{非规模技术综合项}} \quad (7.1)$$

其中， T_t 表示前三问规模机制不能解释的锚定残差，综合反映架构、优化方法、数据工程、后训练及未观测因素，不再将其归属于某项单一技术。图 7.1 给出从前三问机制输出到能力度量、桥接、贡献分解与预测的完整链路。历史分解与未来预测共用式 (7.1)，桥接误差和支持边界亦沿同一链路传播。后续分析依次识别 F_t 、估计 H 、构造 $B(C) = H[L^*(C)]$ ，并据此分解历史增长与推演未来前沿。




图 7.1 前三问机制输出与能力前沿分析的统一框架

7.1 开放权重模型综合能力度量

本节首先确定现实能力的观测状态及其可靠性，再将该状态传递给后续桥接与贡献分解。具体而言，先建立可比较的综合能力坐标，再以滚动高分位提取时间前沿，并从任务维度、指标口径和模型族依赖三个层面检验其稳健性。

7.1.1 开放权重模型的多维能力统一表征

能力口径首先满足“对象可比、时间可追溯、任务完整”。主样本限定为开放权重的 chat 或领域微调模型，以 Open LLM Leaderboard 的 Submission Date 作为能力出现时间，并要求 IFEval、BBH、MATH Lvl 5、GPQA、MUSR、MMLU-PRO 六项得分完整。pretrained 模型只作为类型对照；许可证字段另按 Apache、MIT、BSD、CC-BY、OpenRAIL 及可研究模型族许可证构造严格子样本，但该文本规则不解释为法律合规认证。各数据源的角色和时间合同见表 7.1。

六项指标分别刻画指令遵循、综合推理、数学、研究生层次问答、多步软推理与专业知识。为避免由样本方差替研究目标赋权，主分析采用等权均值 $Y_i = \frac{1}{6} \sum_{k=1}^6 S_{ik}$ ，使结果仍保持 0–100 分的直观解释。等权并不意味着六项完全同质：其作用是构造稳定、透明的共同能力坐标，PCA 和任务内标准化均值只用于检验该坐标是否被单项量纲支配。

六项原始得分的 Cronbach $\alpha = 0.826$ ，达到较好的内部一致性 [1]；标准化 PCA 的第

表 7.1 问题四的数据口径、时间合同与证据角色

数据	主筛选与变量	时间轴	样本量	证据角色
C1/C2	开放权重、六项完整、chat/finetuned	Submission Date	231	能力主前沿
C8	最新可解析快照、六项任务得分	评测时间	1854	逐任务诊断
C4	Language、LM/QA、可信 reported compute	Publication date	326	算力主前沿
C6	High 与 Medium 分层保留	不进入时间轴	7+68	Loss-能力 桥接
Q3	主情景、context 4096、三档预算	算力预算	3 个锚点	规模机制

注：C8 共审计 1860 个唯一模型，其中 1854 个六维完整；C4 的 6ND 估计仅进入敏感性分析。

一主成解释率为 65.1%，等权得分与第一主成分、任务内标准化均值的相关系数分别为 0.960 和 0.977。三种能力口径的前沿净变化方向均为正，说明等权指标既保留可解释性，也未偏离数据中的主要共同变化方向。

7.1.2 基于滚动分位的能力前沿构建

单个榜首模型易受偶然提交、测试噪声和同族微调影响，月均值又会被大量普通提交拖动。本文在每个月末向前取三个月，以综合能力的 90% 分位定义开放权重能力前沿：

$$F_t = Q_{0.90}\{Y_i | t - 3\text{月} < t_i \leq t\}. \quad (7.2)$$

该定义衡量当期可稳定达到的高能力区域，而非单一最高值。主样本在 2024 年 6 月至 2025 年 3 月形成 10 个有效月度点，前沿从 30.754 升至 39.062，观测净增长为 8.307 分。图 7.2a 同时保留全部模型散点和 2/3/4 个月、Q90/Q95 六种方案的包络，主曲线始终处于敏感性范围内。




图 7.2 开放权重模型综合能力前沿与逐任务演进广度

7.1.3 能力前沿的逐任务与多口径检验

图 7.2b 显示，首末窗口的六项任务中有五项提高：MATH Lvl 5、IFEval、MMLU-PRO、BBH、MUSR 分别增加 18.807、8.825、6.355、3.853 和 2.116 分，GPQA 下降 1.174 分。月度任务改善广度的中位数为 4/6。因此，8.307 分增长具有较广的任务基础，但并不表明各维能力同步改善。C8 中 MATH 的 154 个精确零值保留为困难任务的有效得分；未发现重复模型、重复结果文件或集中性快照故障。

进一步控制重复提交后，按基础架构正则识别模型族，无法识别时退回 Hugging Face 组织名；每个模型族每月经保留最高能力模型，54 个“族-月”单元的前沿仍增长 8.238

分。按“月份 × 模型族”进行 2000 次块 Bootstrap，净增长为正的的比例为 93.8%，中位数 6.804 分，2.5%–97.5% 分位为 $[-2.201, 15.732]$ 。该结果排除了热门模型族重复提交对主增长的完全解释，但仍保留 6.2% 重采样不增长这一不确定性。类型对照中，pretrained 前沿提高 5.731 分，小于 chat/finetuned 的 8.307 分，提示后训练可能参与能力推进；由于两类样本构成不同，本文不把差值解释为后训练的因果贡献。

表 7.2 综合能力指标与能力前沿的多层稳健性检验

检验层次	统计量或对照	结果	证据含义
内部一致性	Cronbach α	0.826	六项任务具有较好可合成性
共同因子	第一主成分解释率	65.1%	存在占主导的共同能力方向
口径一致性	等权与 PCA/标准化均值相关	0.960/0.977	结论不受单一量纲支配
前沿口径	等权、PCA、标准化均值	净变化均为正	上升方向不依赖合成方法
模型族平衡	每族每月仅留最优模型	+8.238 分	重复提交不能解释主增长
相关性重采样	族-月块 Bootstrap 2000 次	93.8% 为正	方向稳健，但保留 6.2% 反例
模型类型	pretrained 与 chat/finetuned	5.731/8.307 分	异质性提示，不作因果归因

注：主模型始终采用等权能力口径；PCA、标准化均值及类型拆分仅用于稳健性检验。

表 7.2 依次检验指标的可合成性、方向一致性、重复提交影响及模型类型异质性。由此得到统一状态方程中的观测状态 F_t ；后续以 8.307 分作为历史增长事实，并将模型族依赖纳入 Bootstrap。下一节进一步估计连接 Loss 与该能力状态的观测映射 H 。

7.2 Loss–Benchmark 能力映射

能力前沿给出了现实模型的观测尺度，但尚未回答前三问的最优损失如何进入该尺度。本节利用分层桥接样本估计 H ，重点处理来源水平差异、单调机制约束及小样本验证误差，并将桥接结果作为规模能力函数的唯一观测接口。

7.2.1 桥接样本的可比性分层

前三问输出的是验证 Loss，式 (7.1) 左侧却是 Benchmark 得分，两者不能直接相减。C6 桥接样本共 75 条，其中 7 条 High 样本具有较强同协议可比性且均来自 Pythia，68 条 Medium 样本覆盖更多模型族，但验证集、训练阶段或 Loss 定义存在差异。若将两层数据直接混合，来源的绝对水平差会被误当成能力响应；若只用 7 条 High 数据，又无法稳定辨识非线性形状。因此，本文让 High 提供水平锚点、Medium 提供形状信息，并显式分离来源截距与残差方差。

7.2.2 来源偏差不变的单调能力桥接

记 I_i^M 为 Medium 指示变量，在 Loss 分位点 κ_j 上构造铰链基函数，建立

$$Y_i = \alpha + \delta_M I_i^M + \sum_{j=1}^J \beta_j (\kappa_j - L_i)_+ + \varepsilon_i, \quad \beta_j \geq 0, \quad \text{Var}(\varepsilon_i) = \sigma_{g(i)}^2. \quad (7.3)$$

非负约束保证 $H'(L) \leq 0$ ，即 Loss 降低不会预测出能力下降。High/Medium 分别估计残差尺度；考虑 High 仅 7 条，本文以 5 个先验自由度向总体方差作经验收缩，避免小样本方差过小而在加权拟合中占据不合理权重。相邻铰链系数的一阶差分惩罚控制局部斜率突变，惩罚强度由分层留出交叉验证确定为 10。

估计的 Medium 来源截距为 $\hat{\delta}_M = 11.824$ 分。绝对截距用于吸收跨来源 Loss 水平差异，而历史分解只使用同一桥接层内的差值 $H(L_1) - H(L_0)$ ，故固定来源偏差严格抵消。该“来源截距可变、能力差分不变”的设定适应了当前多源小样本条件，且无需假定不同来源具有统一的绝对 Loss 基准。图 7.3a 仅在 C6 观测范围 $[1.65, 2.84]$ 内绘制桥接曲线，灰色边缘不参与拟合外推。




图 7.3 来源分层的 Loss–Benchmark 单调桥接与留出预测校准

7.2.3 分层留出验证与映射误差评估

四类桥接统一采用“Medium 留一模型族、High 留一观测”的交叉验证，结果见表 7.3。pooled 线性模型的 RMSE 最低，主模型的 MAE 最低；主模型并非在所有误差指标上占优。本文仍选择来源校准单调样条，是因为贡献分解要求同时满足机制方向、来源偏差显式分离和差分不变性，不能只依据单一 RMSE 选模。

表 7.3 四类 Loss–Benchmark 桥接的统一留出验证

桥接模型	RMSE	MAE	结构性质
pooled 线性	11.815	9.817	无来源校准、无形状约束
High-only 线性	17.620	13.455	同协议但样本仅 7 条
无来源校准保序回归	13.190	10.318	单调但混合来源水平
来源校准单调样条（主模型）	12.766	9.650	单调、分层方差、差分不变

注：四类模型均在同一 75 条留出预测上比较；加粗只表示对应误差指标的最小值。

全样本 Loss 与能力的 Spearman 相关为 -0.549 ，方向符合机制预期，但图 7.3b 显示绝对映射仍有明显离散。逐一删去 7 个 Pythia 观测后，末端斜率保持在 -24.61 至 -24.99 分/Loss，后续规模份额上界仅在 8.431% – 8.561% 间变化，表明固定样本结论不由单个 High 观测主导。桥接误差仍是问题四的重要不确定性，须在后续条件模拟中完整传播。本节由此得到观测映射 H ，下一节将其与问题三的 $L^*(C)$ 复合，形成规模能力函数 $B(C)$ 。

7.3 规模扩张与非规模技术进步贡献分解

在获得能力状态 F_t 、桥接函数 H 及问题三的最优损失曲线 $L^*(C)$ 后，本节考察历史能力增长中可由算力机制解释的部分。分析顺序为先构造与能力前沿同尺度的算力前沿，再形成 $B(C) = H[L^*(C)]$ ，最后在共同支持边界约束下给出贡献的部分识别集合。

7.3.1 基于滚动分位的训练算力前沿构建

为与能力前沿保持相同时间平滑尺度，训练算力前沿定义为开放权重 Language 域、language modeling 或 question answering 任务中，Confident/Likely 且真实报告训练 FLOPs 模型的三个月滚动 Q90。共有 617 个模型满足基础元数据筛选，342 个报告 compute，其中 326 个进入可信主样本；72 个仅能由 6ND 估计，203 个缺失算力。主结果只使用 reported compute，6ND 仅构造敏感性曲线。

图 7.4a 显示，2023 年 6 月至 2024 年 6 月的 Theil–Sen 斜率为每月 $0.0812 \log_{10}$ FLOPs，2024 年 7 月至 2025 年 3 月转为 -0.0429 。这表明 2024 年中跃升后进入平台/回落阶段；负的短窗口斜率不等于长期算力必然下降，故预测主情景将未来算力增速保守截为 0。reported

compute 与加入 6ND 后的前沿走势接近，结论不依赖估算值。




图 7.4 训练算力演进与 Q3–C6 共同支持边界

7.3.2 机制锚定的规模能力反事实

问题三主情景固定为 context 4096、指数质量成本、ratio 桥接与 $\kappa = 1$ ，在 10^{19} , 10^{22} , 10^{24} FLOPs 三档预算下得到最优平均 Loss 2.4500、1.6932、1.4803。本文仅在 $\log C$ – $\log L$ 空间对三锚点分段连接，形成继承前三问机制的 $L^*(C)$ ，而不使用历史能力数据重新拟合“规模趋势”。由此定义规模能力函数

$$B(C) = H[L^*(C)], \quad \Delta F_t = \Delta B(C_t) + T_t. \quad (7.4)$$

其中 $B(C)$ 回答“在前三问配置机制与桥接关系保持不变时，仅改变算力预算应获得多少能力”。这一反事实直接连接问题三，而 T_t 只承接剩余变化，从而避免把时间回归系数直接命名为技术进步。

图 7.4b 将 $L^*(C)$ 与 C6 Loss 范围叠加。Level A 为较强机制支持区，Level B 依赖响应形状延伸， $C > 10^{24}$ FLOPs 的 Level C 超出 Q3 预算。观测窗口起点和终点的算力分别为 1.729×10^{24} 与 3.399×10^{24} FLOPs，均位于 Level C；对应 L^* 为 1.457 和 1.428，又低于 C6 最小 Loss 1.65。因此，历史分解同时越过 Q3 和 C6 边界，规模贡献在现有数据下不可点识别。

7.3.3 支撑边界感知的贡献部分识别与稳健性

边界之外若直接延长末端斜率，相当于将未经观测的局部响应视为确定关系；完全饱和和假设则对应规模贡献的保守下界。为涵盖两种具有明确含义的边界情形，令尾部延续强度 $\theta \in [0, 1]$ ： $\theta = 0$ 表示到达 C6 边界后饱和， $\theta = 1$ 表示完整延续末段斜率。对低于观测下界 $L_{\min}$ 的 Loss 定义

$$H_\theta(L) = H(L_{\min}) + \theta\{H(L) - H(L_{\min})\}, \quad L < L_{\min}, \quad \theta \in [0, 1]. \quad (7.5)$$

该构造不声称 θ 具有可估计概率，而是用两个可解释边界形成部分识别集合 [2]。将观测增长 8.307 分代入式 (7.1)，得到

$$0 \leq \Delta F_{\text{scale}} \leq 0.708, \quad 7.599 \leq \Delta F_{\text{tech}} \leq 8.307,$$

即固定样本下规模份额为 0%–8.52%，非规模技术综合残差为 91.48%–100%。这是一组由结构边界产生的识别集合，不是置信区间； $\theta = 0$ 对应的“技术项 100%”只是下端边界，不能作为唯一分解结论。

图 7.5a 进一步给出逐月识别路径。深色曲线为观测能力相对起点的净变化；橙色带表示规模机制可解释区间 $[0, \Delta B_t^{(1)}]$ ；青色带表示由此反推的非规模综合项 $[\Delta F_t - \Delta B_t^{(1)}, \Delta F_t]$ 。




图 7.5 能力增长的动态贡献分解与终点部分识别集合

2024 年 7 月的短暂负值来自滚动窗口样本更替，此后观测能力持续上升。规模上界随算力前沿波动，最高约 1.576 分，期末收敛至 0.708 分；非规模综合项则随观测增长逐步累积，并在绝大多数月份承担主要变化。图 7.5b 报告期末识别集合，从动态路径与终点结构两个层面呈现同一分解结果。

为检验识别集合上端点对样本构成的敏感性，进一步分层重采样能力窗口、算力窗口和 C6 两层样本，并切换 Q3 三种成本形式，共实施 1000 次 Bootstrap。表 7.4 区分固定样本识别集合与上端点的重采样稳定性，后者不构成贡献率的置信区间。970 次重采样产生有限份额；30 次因能力净增长非正而比值不定义，24 个有限上界超过 100%，均予以保留。有限上界中位数为 12.73%，97.5% 分位为 85.34%；上界低于 10%、25%、50% 的比例分别为 42.5%、70.4%、88.4%。这表明“规模上界低于一半”在多数重采样中成立，而“规模上界低于 10%”的稳定性相对有限。

表 7.4 历史贡献识别集合及其上端点稳定性

证据层次	数值结果	统计含义
观测能力净增长	8.307 分	不依赖贡献分解假设的历史事实
固定样本规模贡献	0-0.708 分； 0-8.52%	共同支持边界下的部分识别集合
固定样本非规模贡献	7.599-8.307 分； 91.48%-100%	与规模贡献互补的锚定残差集合
上端点 Bootstrap 中位数	12.73%	识别集合上端点的重采样中心
上端点 Bootstrap 高分位	97.5% 分位为 85.34%	极端样本构成下的尾部敏感性
阈值稳定性	42.5% / 70.4% / 88.4%	上端点低于 10%/25%/50% 的比例
有效性审计	970 有限；30 未定 义；24 超过 100%	未删除不利或极端结果

注：Bootstrap 考察识别集合上端点的稳定性，不应解释为规模贡献率的置信区间。

作为独立方向核验，C1-C4 有 128 条可靠实体匹配，其中 49 条同时具备 compute 与能力得分， $\log_{10}\text{compute}$ 与能力的 Spearman 相关为 0.578， $p = 1.35 \times 10^{-5}$ 。该结果支持规模作用方向为正，但不能消除发布时点、架构和数据质量的混杂，故不用于估计贡献率。由此获得了支持边界约束下的历史部分识别路径；下一节沿用同一状态方程，将算力路径与非规模状态共同推进至未来。

7.4 算力放缓下的能力前沿预测

历史分解确定了规模项与非规模状态项的接口，预测阶段不再引入独立的时间序列结构，而是沿用同一状态方程推进两条路径。本节先给出算力平台与技术漂移的情景设定，再报告条件模拟、不确定性来源及滚动起点回测。

7.4.1 算力平台-技术漂移的双状态演化

历史残差由 $T_t = F_t - F_{t_0} - [B(C_t) - B(C_{t_0})]$ 锚定。对其采用带漂移随机游走 $T_{t+1} = T_t + b + \eta_t$ ，其中 b 用 Theil-Sen 稳健斜率估计 [3]，得到每月 1.191 分；创新标准差为 2.663 分。该漂移描述短期非规模综合项的延续速度，不解释为某项技术的因果效应。算力主情景令未来 $\log_{10} C$ 增速为 0；无放缓反事实则延续早期每月 0.0812 的增速。

将两种状态代回统一方程， h 个月后的前沿为

$$F_{t+h} = F_t + \{B(C_{t+h}) - B(C_t)\} + bh + \sum_{j=1}^h \eta_{t+j}. \quad (7.6)$$

式 (7.6) 不是独立的时间序列模型：第一项承接现实能力，第二项仍由问题三机制和桥接决定，后两项延续式 (7.1) 中的同一非规模状态。因而历史解释、反事实和预测不会因更换模型而失去可比性。

7.4.2 历史-预测统一的能力前沿推演

表 7.5 给出算力路径与技术漂移的 2×2 有限情景。主情景“算力平台 + 当前漂移”的 12 个月点预测为 53.358。保持技术漂移不变、将算力改为无放缓，只提高 1.127 分；保持算力平台、将技术漂移减半，则降低 7.148 分。由此，当前支持边界下的中期预测主要受非规模技术路径假设影响，而不是算力路径的细微差别。

表 7.5 12 个月能力前沿的算力-技术情景矩阵

算力路径	非规模技术路径	预测前沿	相对主情景
平台（主情景）	当前 Theil-Sen 漂移	53.358	0
平台	半漂移	46.210	-7.148
延续早期增速	当前 Theil-Sen 漂移	54.484	+1.127
延续早期增速	半漂移	47.336	-6.021

注：情景矩阵用于结构反事实，不赋予四种路径主观发生概率。

条件模拟共 2000 次，逐次传播七类不确定性：终点能力窗口、模型族依赖、终点算力窗口、Q3 成本形式、High/Medium 桥接样本、支持边界后斜率，以及技术漂移和随机游走创新。图 7.6 以 50%、80%、95% 三层色带连接起点与 12/24 月模拟端点。12 个月模拟中位数为 51.203，95% 条件区间为 [24.220, 78.336]；该区间刻画给定情景与重采样规则下的不确定性传播，不属于频率学置信区间。

24 个月点预测为 67.654，中位数 66.296，95% 区间为 [16.336, 100]，上端触及量表边界。该结果表明现有证据在这一期限已不足以约束分布上尾，并不意味着能力必然达到量表上限。因此，12 个月作为主预测期限，13–24 个月仅作为压力测试，并在图中以灰色背景降低其证据等级。

7.4.3 预测不确定性的来源归因

条件区间的宽度不仅取决于随机游走创新，还受到能力样本、模型族结构和跨问题机制接口的共同影响。为识别主要来源，本文采用单因素方差缩减实验：在保持其余来源随机的条件下，将第 j 类不确定性固定为主设定值，并在同一模拟抽样批次下重新估计 12 个




图 7.6 算力平台情景下开放权重模型能力前沿的条件预测

月预测。定义

$$R_j = 1 - \frac{\text{Var}(F_{12} | U_j = \bar{U}_j)}{\text{Var}(F_{12})}. \quad (7.7)$$

R_j 衡量固定单一来源后总方差的相对缩减。由于各来源存在非线性交互且预测值受 0–100 边界截断，该指标不具可加性，也不解释为 Sobol 指数。

完整模拟的 12 个月预测方差为 187.300，对应标准差 13.686。图 7.7 显示，固定技术漂移与创新后方差缩减 93.79%，显著高于模型族依赖的 3.71% 和能力窗口抽样的 1.72%；支撑域外斜率、算力前沿、Q3 成本形式及桥接样本的单因素影响均接近 0。Q3 成本形式和桥接样本出现 -0.00% 与 -0.01% 的微小负值，源于非线性交互、量表截断及有限模拟误差，不表示其产生“负不确定性”。因此，预测区间的主要宽度来自非规模技术状态的未来延续，而非对算力路径的局部扰动；该发现也与情景矩阵中技术漂移变化造成更大预测位移相互印证。




图 7.7 12 个月能力预测不确定性的单因素方差缩减

7.4.4 条件模拟传播与滚动起点回测

采用 rolling-origin 方式，在每个历史起点只使用此前信息预测未来 1、2、3 个月，共得到每种方法 12 个预测。对照包括最后值保持和直接对 F_t 作 Theil–Sen 外推。图 7.8a 显示统一模型 95% 条件区间覆盖率为 91.7%，各期限覆盖率为 80%、100%、100%；平均宽度随期限由 10.237 增至 16.438，符合随机游走不确定性随时间累积的方向。

图 7.8b 与表 7.6 表明，最后值保持在三个期限均取得最小 MAE，统一状态模型的短期点预测精度未优于简单基线。直接 Theil–Sen 与统一模型在本回测窗口内完全重合，原因




图 7.8 能力前沿预测的滚动起点回测与简单基线比较

表 7.6 统一状态模型与简单基线的滚动起点回测

方法或区间指标	1 个月 ($n = 5$)	2 个月 ($n = 4$)	3 个月 ($n = 3$)	总体 ($n = 12$)
统一状态模型 MAE	2.934	2.767	3.493	3.018
最后值保持 MAE	1.952	2.678	2.923	2.437
直接 Theil-Sen MAE	2.934	2.767	3.493	3.018
共同 95% 覆盖率	80.0%	100.0%	100.0%	91.7%
共同平均区间宽度	10.237	14.212	16.438	13.112

注：三种方法共用历史残差尺度，故区间指标相同；加粗值表示同期限最小 MAE。

在于各训练折的算力机制项在域外饱和边界下为 0；在无放缓算力反事实中，两者不再等价。由于三种方法共享同一残差尺度，其区间覆盖率与平均宽度相同，不能据此判断统一状态模型具有更优的概率校准。

点预测精度与结构反事实效用属于不同评价维度。对于一至三个月的短期点预测，最后值保持具有更低误差；对于算力增速继续放缓如何影响能力前沿这一结构性问题，统一状态模型能够分离算力路径与非规模技术路径，因而具有简单预测基线不具备的反事实解释功能。

本问小结 问题四得到四项主要结论。第一，开放权重 chat/finetuned 模型的能力前沿提高 8.307 分，指标信度、多口径和模型族平衡检验均支持总体上升方向，但 GPQA 并未同步改善。第二，来源校准单调桥接显式处理了跨来源水平偏差，绝对映射误差仍作为不确定性进入后续分析。第三，现实算力与映射 Loss 均超出共同支持域，规模贡献仅能部分识别；固定样本识别集合为 0%–8.52%，不支持唯一的点分解比例。第四，算力平台情景下的 12 个月点预测为 53.358，区间宽度主要由非规模技术状态的延续决定，且短期点预测精度未优于保持基线。综上，本文形成了**支持边界感知、来源截距不变、历史分解与情景预测统一**的能力前沿状态框架，使“能力如何度量、Loss 如何映射、历史增长如何识别及算力放缓后如何演化”构成闭合证据链。

八、结论、局限与推广

问题四通过来源偏差不变的 Loss-Benchmark 桥接，将前三问最优损失映射到现实能力尺度；在共同支持边界外采用部分识别而非点外推，并在统一状态方程下分析算力放缓时的未来能力前沿及其不确定性来源。该处理将历史贡献分解与情景预测置于同一机制接口之下，同时保留桥接误差、样本依赖和支持域外推带来的不确定性。

参考文献

- [1] Cronbach L J, Coefficient Alpha and the Internal Structure of Tests, *Psychometrika*, 16: 297-334, 1951.
- [2] Manski C F, *Partial Identification of Probability Distributions*, New York: Springer, 2003.
- [3] Sen P K, Estimates of the Regression Coefficient Based on Kendall's Tau, *Journal of the American Statistical Association*, 63(324):1379-1389, 1968.

附录 A 完整数据审计表

附录 B 关键参数与敏感性结果

附录 C 程序代码