

问题一：基于结构质量画像与成分几何的领域配比-Loss 建模

摘要

问题一同时要求把 22 个异质质量指标变成可比较信号，识别指标关系中的质量冲突，并建立 17 个训练域配比与 13 个验证域 Loss 的响应模型。本文首先对列表型 logits、概率和标量指标分别压缩，在七个质量域合并去重得到 261086 条唯一记录；以五组等权稳健画像构造无人工标签的基础质量指数，并用域内五折交叉拟合的 Ledoit-Wolf 马氏距离描述结构冲突。结果表明，基础指数的样本范围为 $Q_{\text{base}} \in [0.0290, 0.8728]$ ，全量结构冲突率为 5.19%，多组结构冲突率为 1.58%。

在配比侧，先把 17 维比例投影到单纯形并作固定 Helmert 等距对数比变换。A4/A5 的 512 组训练配方只在五折 Aitchison 空间几何交叉验证中选择模型，六个实际候选中最终锁定 16 维 ilr 独立多输出 Ridge ($\alpha = 10$)。A6/A7 同尺度主检验的宏平均 MAE、RMSE、 R^2 和 Spearman 分别为 0.3082、0.4000、0.6729 和 0.8311；A8/A9、A10/A11 的 R^2 明显下降而排序相关性仍为 0.8273/ 0.7839，说明跨尺度主要存在截距漂移，不能直接把绝对 Loss 当作零样本预测。A12-A15 仅作为 10B、70B 的基础估算压力排序，不作为真实外部验证。

本文的可复现实践创新是：在域样本极不平衡时保持全局质量锚定并输出区间；把冲突定义为 22 维正常关系的结构偏离而非简单相反指标；用成分几何避免 17 个比例的闭合约束和共线性。由于缺少独立人工审计标签，冲突只作为复核优先级，不能被解释为低质量概率；七域到十七域映射也仅按证据分级使用。

关键词：多指标质量评价；结构冲突；等距对数比；岭回归；Loss 响应；跨尺度检验

1 问题重述

题目第一问包含三个紧密但不能混为一谈的任务。第一，A1–A3 给出 22 个质量信号，需在不同量纲、不同输出形式和不同来源域之间建立可比较的质量评价。第二，题目中的质量冲突应理解为多指标结构偏离正常关系，而不能简化为一高一低；模型需要给出异常结构、成因线索和综合评价中的处理边界。第三，A4–A15 给出 17 域配比和 13 个 Loss，需估计领域及其组合的实际作用，使用 A6–A11 检验并将 A12–A15 限定为外推压力测试。

本文将 A1–A3 的质量画像和 A4–A15 的配比响应作为两个模型体系，用七域到十七域的文本画像映射作为解释桥梁。映射不能把没有 22 个指标的训练域伪装成有质量观测的域；配比主模型也不把固定域质量分乘入配比矩阵，以避免不可识别的质量–配比混淆。

2 基本假设与符号说明

2.1 基本假设

1. A1–A3 中相同 ID 的扩展记录代表同一文本；重复信号一致时只保留一份，正文只用于可用性和结构冲突参考。
2. 所有列表型指标先按其输出语义压缩为标量；缺失值仅用于结构画像的中位数插补，并保留缺失字段计数。
3. 22 个字段按五组等权聚合，组内先作稳健标准化；无人工标签时不把基础指数解释为语义真值。
4. 配比是闭合成分向量；行和误差来自千分位舍入，归一化和零替换使用同一规则，训练与检验不改变该规则。
5. A4/A5 是唯一模型选择数据，A6/A7 是同尺度主检验，A8–A11 是冻结模型跨尺度检验，A12–A15 仅为估算压力测试。

主要符号见表 1。

符号	含义	单位
x_{ij}	第 i 条文本的第 j 个原始质量信号	无量纲或题面单位
Q_i^{base}	五组等权基础质量画像指数	0–1
C_i	结构冲突的未平方马氏距离	无量纲
$\tilde{C}_i$	交叉拟合经验秩冲突严重度	0–1
$\mathbf{p}_i$	17 域配比向量	比例
$\mathbf{u}_i$	16 维 Helmert ilr 坐标	无量纲
L_{ik}	第 k 个验证域的 Loss	Loss
α	Ridge 正则化系数	无量纲

表 1: 主要符号说明。

3 数据说明与预处理

3.1 数据结构与数据隔离

质量侧三文件去重后为 261086 条唯一文本，22 个字段在五组中恰好覆盖一次。域样本量从 book 的 171 条到 github 的 203752 条不等，因而质量信号的共享位置和尺度采用各域平衡子样本估计；最终域均值仍保留原始样本量，并用 200 次记录级 Bootstrap 给出区间。配比侧训练表有 512 组、17 个成分域和 13 个 Loss 输出；A6/A7、A8/A9、A10/A11 分别代表 1M、60M 和 1B 尺度。

七个质量域的数量、基础质量和冲突结果汇总见表 2。

质量域	n	Q 均值	95% 区间	冲突率	结构冲突率
arxiv	17523	0.6567	[0.6558,0.6575]	4.66%	0.74%
book	171	0.4939	[0.4802,0.5092]	2.34%	1.17%
c4	10000	0.4696	[0.4668,0.4724]	5.02%	1.87%
commoncrawl	9640	0.4814	[0.4787,0.4842]	4.85%	1.82%
github	203752	0.3975	[0.3971,0.3980]	5.29%	1.60%
stackexchange	10000	0.4991	[0.4968,0.5013]	4.97%	1.66%
wikipedia	10000	0.3991	[0.3972,0.4017]	4.98%	1.90%

表 2: 七个质量域的样本量、质量指数与冲突率。

图 1 将质量与配比两条证据链分开，只有在映射证据足够时才做解释性联系。图 2 展示问题一实际代码中的训练、冻结和检验顺序。




图 1: 从数据合同、质量画像、冲突识别到配比响应的总体建模流程。




图 2: 问题一的质量画像、冲突、映射与配比响应流程。

3.2 质量信号工程

四个六分类 ModernBERT 输出用稳定 softmax 的期望等级压缩；两个二分类字段取指定正类概率；四维 qurater 取均值，单元素教育字段取其唯一值。该压缩口径与公开数据卡的输出结构一致 [3]。五个明确的高值不利字段统一反向，随后对 22 列做 1%-99% 截尾、稳健中位数-MAD 标准化。19 个缺失单元不删除样本，使用字段中位数完成结构画像，并写入缺失字段计数和质量证据列。

五组质量信号的字段归属见表 3。

质量组	字段数	结构含义
教育/知识	5	fineweb_edu, qurater, dsir_books, dsir_math, dsir_wiki
流畅/可读	5	fluency_en, modernbert_readability, 3 个 RPS 字段
推理/专业	2	modernbert_reasoning, modernbert_professionalism
清洁/广告	5	modernbert_cleanliness, ad_en, 3 个 RPS 字段
重复/格式/密度	5	2 个重复率、唯一词率、句数、词数

表 3: 五组质量信号及其结构含义。

图 3 展示 22 个信号的输出结构和七个质量域的样本量；图 4 用压缩后的信号相关矩阵检查指标冗余与潜在冲突关系。




图 3: 22 个质量信号的结构分布与质量域样本量。




图 4: 压缩后的质量信号相关结构；相关不等于因果。

3.3 配比数据预处理

对每行配比先除以行和，使千分位舍入不改变总质量；零值以 $\delta = 10^{-6}$ 替换，另以 10^{-8} 与 10^{-4} 检查有限性。固定 Helmert 子矩阵 $\mathbf{H}$ 后，

$$\mathbf{u}_i = \text{ilr}(\mathbf{p}_i) = \mathbf{H} \log(\mathbf{p}_i^{(\delta)}), \quad \mathbf{u}_i \in \mathbb{R}^{16}. \quad (1)$$

原始 17 列比例存在闭合约束，直接回归会产生完全共线性；ilr 坐标将其转成可回归的 16 维欧氏坐标。该处理遵循组成数据分析框架 [1]，配比在 Aitchison 空间的分布见图 5。

4 问题一的求解：质量评价、冲突与配比建模

4.1 质量评价模型

令 z_{ij} 为稳健标准化后的第 j 个信号， I_m 为第 m 个质量组，则组画像和基础指数分别定义为

$$g_{im} = \frac{1}{|I_m|} \sum_{j \in I_m} z_{ij}, \quad Q_i^{\text{base}} = \frac{1}{5} \sum_{m=1}^5 \Phi \left(\frac{g_{im} - \tilde{g}_m}{1.4826 \text{MAD}(g_m) + 10^{-8}} \right). \quad (2)$$

其中 $\tilde{g}_m$ 和尺度由各域平衡子样本确定。该构造有三个作用：首先让不同输出形式进入同一标量尺度；其次以五组等权避免某个字段数量多的组机械占优；最后保留全局锚




图 5: 17 域配方在前两条 ilr 坐标上的几何分布。

定，使 github 的大量记录不会把 book 的质量结构当作无关噪声。它是数据结构画像而非经人工语义标签校准的最终质量真值。

图 6 显示五组画像的域间差异。图 7 给出了七域的全局均值和 Bootstrap 区间：arxiv 均值最高，为 0.6567；github 均值为 0.3975；wikipedia 均值为 0.3991。这里的“高”仅表示在固定结构规则下的相对画像位置，不表示文本真实可训练性已经被人工验证。

4.2 质量冲突识别与消解边界

题目中的冲突被定义为：在域内正常指标关系下，样本的 22 维残差结构仍然显著偏离参考结构。设交叉拟合得到的残差向量为 $\mathbf{r}_i$ ，域内收缩协方差为 $\hat{\Sigma}_d$ ，则

$$C_i = \sqrt{\mathbf{r}_i^T \hat{\Sigma}_d^{-1} \mathbf{r}_i}, \quad \tilde{C}_i = \hat{F}_d(C_i). \quad (3)$$

实际代码在 A1 可回连正文的数据上做域内五折旋转拟合，用相邻校准折的经验秩得到 $\tilde{C}_i$ ；Ledoit–Wolf 收缩协方差的统计动机见文献 [2]。扩展记录沿用域内参考分布。 $\tilde{C}_i \geq 0.95$ 标记为高严重度冲突，五组残差同时有相反方向时再标记为多组结构冲突。图 8 展示冲突严重度校准，图 9 展示各域冲突率。

全量冲突标记率为 5.19%，多组结构冲突率为 1.58%。由于没有独立人工审计标签，不能检验冲突是否等价于内容不可靠，也不估计冲突惩罚 λ_{conf} ；冲突列只作为复核优先级，基础质量指数不被事后压低。这样既回答了“质量冲突如何识别”，又避免把无




图 6: 五组基础质量画像在不同质量域的均值。




图 7: 质量域全局质量指数与 Bootstrap 95% 区间。

标签结构异常伪装成语义质量校正。




图 8: 域内交叉拟合的冲突严重度经验校准。

4.3 七域到十七域的跨体系映射

七个质量域与十七个训练域不是一一对应关系。已知关系按 direct、near_direct 和 inferred 分级；文本画像使用长度、字符/数字比例、代码和数学符号比例、词汇多样性等七个可计算特征。单次标准化距离转成软权重，输出最近质量域、置信度、熵和是否恢复已知关系。本轮 17 个训练域中 direct=3、near_direct=3、inferred=11，已知映射恢复 5/6；pile_cc 的最近质量域为 c4，因而不把 commoncrawl 直接写成已恢复的质量域。inferred 域只保留宽解释，不向配比模型拼接虚假质量标签。

映射证据分级与用途见表 4。

映射类型	数量	主证据用途
direct	3	恢复成功时作质量解释
near_direct	3	需检查最近域是否恢复
inferred	11	仅作宽先验/限制说明

表 4: 七域到十七域映射的证据分级。




图 9: 质量域冲突率与多组结构冲突率。

4.4 17 域配比-Loss 响应模型

以 A4/A5 的 512 组配方为唯一选择数据，使用 5 折几何交叉验证比较六个实际候选。候选形式与公开 RegMix 回归工作流的配比-Loss 建模问题相呼应 [4]，但本轮只报告实际执行的六个候选。候选包含均值、 $\alpha \in \{0.1, 1, 10\}$ 的 ilr Ridge 和两个二次 Ridge。最优模型为 `ilr_ridge_a10`，其 CV RMSE=0.4212，原始 Loss RMSE=0.4600。最终对每个验证域单独拟合 Ridge，预测方程为

$$\hat{L}_{ik} = \hat{\beta}_{0k} + \hat{\beta}_k^T \mathbf{u}_i, \quad k = 1, \dots, 13. \quad (4)$$

六个候选模型的交叉验证结果见表 5。

候选模型	CV RMSE	折间标准差	原始 RMSE
ilr_ridge_a10	0.4212	0.0253	0.4600
ilr_ridge_a1	0.4213	0.0253	0.4600
ilr_ridge_a0.1	0.4213	0.0253	0.4600
quadratic_ridge_a10	0.4576	0.0474	0.5077
quadratic_ridge_a1	0.4583	0.0476	0.5085
mean	0.7023	0.0336	0.8502

表 5: A4/A5 几何交叉验证的候选模型比较。

图 10 对应表中的候选模型比较，说明最终模型只由 A4/A5 选择数据确定。




图 10: A4/A5 几何交叉验证的候选模型比较。

4.5 模型检验、有限扰动与外推边界

同尺度 A6/A7 的宏平均指标见表。MAE=0.3082、RMSE=0.4000、 $R^2 = 0.6729$ 和 Spearman=0.8311，说明冻结的配比形状在 1M 尺度有可用的留出预测能力。A8/A9 的宏 $R^2 = -8.0913$ 、A10/A11 的宏 $R^2 = -643.4639$ ，而 Spearman 分别为 0.8273 和 0.7839，说明排序形状部分保留，但绝对截距随模型尺度变化，不能直接部署为跨尺度绝对 Loss 预测。图 11 是同尺度预测-参考值散点。

各尺度的宏平均检验结果见表 6。

数据集	阶段	MAE	RMSE	R^2	Spearman	Kendall
A6_A7_1m	same_scale	0.3082	0.4000	0.6729	0.8311	0.6265
A8_A9_60m	cross_scale	1.5212	1.6254	-8.0913	0.8273	0.6225
A10_A11_1b	cross_scale	3.0092	3.0765	-643.4639	0.7839	0.6083

表 6: 冻结模型在不同尺度数据上的宏平均检验指标。

$$\Delta L_k(a \leftarrow b; \rho) = \hat{L}_k(\mathbf{p} + \rho \mathbf{e}_a - \rho \mathbf{e}_b) - \hat{L}_k(\mathbf{p}). \quad (5)$$

有限成分转移严格保持单纯形约束，因而比单独解释一个原始比例系数更接近可执行决策。当前扰动结果是模型响应而非因果效应，没有计算其 Bootstrap 区间。预测配方在同尺度检验中选出的候选索引为 219；A10/A11 和 10B/70B 压力测试的索引变化只能作为迁移风险提示。




图 11: A6/A7 同尺度冻结模型的预测与参考 Loss。

模型选中配方与参考/估算最佳配方的差异见表 7。

数据集	阶段	模型选中索引	参考/估算最佳索引	标准化 Regret	Top10% 命中
A6_A7_1m	same_scale	219	219	0.0000	是
A8_A9_60m	cross_scale	219	219	0.0000	是
A10_A11_1b	cross_scale	17	21	2.1642	否
A12_A13_10b_pressure	extrapolation_pressure	46	32	1.7110	否
A14_A15_70b_pressure	extrapolation_pressure	46	32	1.7966	否

表 7: 配方选择与参考/估算最佳配方的差异。

5 模型评价与适用边界

5.1 模型优点

第一，质量侧没有把 22 个字段粗暴相加，而是分别处理 logits、概率和标量，并用五组等权保留教育、可读、推理、清洁和重复结构。第二，冲突层使用域条件、交叉拟合和收缩协方差，避免把样本规模大的域当作唯一参考。第三，配比侧使用 ilr 坐标，模型输入维度为 16 而不是在 17 个闭合比例上直接回归；A4/A5 选择与 A6–A11 检验严格分开。

5.2 局限与回退

当前质量指数没有独立人工语义标签，因此不能声称质量分与原文可靠性存在已验证的一一对应关系；冲突只供复核排序使用。七域到十七域映射只有单次文本画像距离，且 pile_cc 未恢复，inferred 域不能获得点质量分。配比模型的实际实现是独立多输出 Ridge，不包含尚未运行的 Huber、组稀疏、LightGBM 或二阶稳定性结论。跨尺度检验的绝对误差明显失稳，A12–A15 还来自估算值，所以外推只保留压力排序和风险提示。

6 结论

1. 22 个指标可通过语义压缩、统一方向、稳健标准化和五组等权聚合形成可复现的 Q_i^{base} ；全量范围为 0.0290–0.8728，七域差异和区间见图 7。
2. 质量冲突应定义为 22 维残差结构相对于域内正常关系的偏离。交叉拟合马氏距离给出冲突优先级；全量标记率为 5.19%，多组结构冲突率为 1.58%，没有人工标签时不把它们解释为低质量概率。
3. 17 域配比经单纯形归一化和 ilr 变换后，A4/A5 选出 $\alpha = 10$ 的独立多输出 Ridge；A6/A7 宏 $R^2 = 0.6729$ 、Spearman=0.8311，说明同尺度排序和绝对预测均有实证支持。
4. 跨到 60M 和 1B 时排序相关性仍为 0.8273 和 0.7839，但绝对 R^2 下降为 -8.0913 和 -643.4639；因此应把配比结论限定为同尺度或排序迁移，不把 A12–A15 的估算压力排序当作真实实验验证。

参考文献

参考文献

- [1] John Aitchison. *The Statistical Analysis of Compositional Data*. Chapman and Hall, 1986.
- [2] Olivier Ledoit and Michael Wolf. A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411, 2004.
- [3] OpenDataLab. Slimpajama-meta-rater dataset card. Hugging Face, 2024. <https://huggingface.co/datasets/opendatalab/SlimPajama-Meta-rater>.

- [4] SAIL-SG. Regmix official regression notebook. GitHub repository, 2024. <https://github.com/sail-sg/regmix>.

A 字段与运行说明

本研究使用的完整 22 个质量字段、五组归属、方向和列表压缩器见：

`results/q1_signal_contract.json`

可运行入口为项目根目录的问题 1_ 求解.py，权威环境为 `llm_gnn`。附录仅用于说明变量清单和复现实验边界，不替代正文中的模型解释。